

Optimisation numérique

Hamza Ennaji

Univ. Grenoble Alpes, CNRS, Grenoble INP*, LJK

`hamza.ennaji@univ-grenoble-alpes.fr`

May 11, 2026

Abstract

Ce document constitue les notes de cours du module "Optimisation numérique" en 2A à l'ENSIMAG. Après quelques rappels essentiels sur les ensembles, les fonctions et l'optimisation convexes, il aborde les conditions d'optimalité pour les problèmes sous contraintes (notamment les conditions KKT). Il introduit ensuite les outils de l'analyse convexe non lisse à travers le calcul sous-différentiel et l'opérateur proximal, pour enfin présenter les principaux algorithmes d'optimisation modernes, en particulier les méthodes de gradient proximal.

Contents

1.	Rappels et préliminaires	2
1.1	Normes et distances	2
1.2	Topologie	3
1.3	Calcul différentiel	4
1.4	Structure affine de $\mathbb{R}^n$	6
1.5	Vecteurs et valeurs propres	8
1.6	Classification des matrices	9
1.7	Limites supérieures et inférieures de suites	10
2.	Ensembles convexes	11
2.1	Définitions	11
2.2	Opérations et propriétés topologiques préservant la convexité	12
2.3	Enveloppe convexe	14
2.4	Cônes convexes	17
3.	Fonctions convexes	20
3.1	Caractérisations des fonctions convexes différentiables	24
3.2	Continuité et différentiabilité des fonctions convexes	26
3.3	Sous-ensembles de niveau de fonctions convexes:	27
3.4	Fonctions à valeurs réelles étendues	29
3.5	Inégalités et convexité	31
4.	Introduction à l'optimisation convexe	33
4.1	Conditions d'optimalité pour la minimisation sans contraintes	33
4.2	Optimisation convexe	37
4.3	Projection orthogonale	40
4.4	Théorèmes de séparation par un hyperplan affine	41
5.	Algorithmes d'optimisation	45
5.1	Directions de descente	45
5.2	Analyse de convergence	48
5.3	Méthode de Newton	51
5.4	Méthode de gradient projeté	53
6.	Conditions KKT	56
6.1	Contraintes linéaires	56
6.2	Applications et exemples	59

7.	Introduction au calcul sous-différentiel	62
7.1	Définitions et propriétés	62
7.2	Règles de calcul	65
7.3	Sous-différentiel et optimisation	66
8.	Méthodes proximales	69
8.1	L'opérateur proximal	69
8.2	Règles de calcul	70
8.3	Retour à la projection	71
8.4	Méthode du gradient proximal	72
	Références Bibliographiques	75

Ces notes constituent le support de cours pour l'UE *Optimisation numérique* dispensée en 2^e année à l'ENSIMAG. L'équipe pédagogique est composée de : Hamza Ennaji et Florian Vincent.

Ce polycopié s'appuie principalement sur les références bibliographiques suivantes :

- [1, 2] pour l'analyse variationnelle et convexe ;
- [3, 4] et [5] pour l'optimisation convexe ;
- [4, 6] pour les algorithmes et les aspects numériques.

Les chapitres 1, 2 et 3 (que l'on retrouve également dans [7]) constituent des rappels du cours BACO.

Ces notes sont régulièrement mises à jour. N'hésitez pas à me signaler toute coquille, erreur ou suggestion d'amélioration.

Rappels et préliminaires

Tout au long de ce cours, on travaillera sur $\mathbb{E} = \mathbb{R}^n$ avec $n \in \mathbb{N}$.

1.1 Normes et distances

Définition 1 (Norme). Une norme sur $\mathbb{R}^n$ est une application $N : \mathbb{R}^n \rightarrow \mathbb{R}^+$ vérifiant

1. $N(x) = 0$ ssi $x = 0$,
2. $N(\lambda x) = |\lambda|N(x)$ pour tout $\lambda \in \mathbb{R}$ et $x \in \mathbb{R}^n$,
3. $N(x + y) \leq N(x) + N(y)$ pour tout $x, y \in \mathbb{R}^n$.

Exemple 1. On définit la norme euclidienne sur $\mathbb{R}^n$ (notée $\|\cdot\|$ ou $\|\cdot\|_2$) par

$$\|x\| = \left(\sum_{i=1}^n x_i^2 \right)^{1/2}.$$

Plus généralement, pour $1 \leq p < \infty$, on définit la norme l_p par

$$\|x\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{1/p}.$$

Pour $p = \infty$:

$$\|x\|_\infty = \max_{i=1, \dots, n} |x_i|.$$

Définition 2 (Métrique). Soit N une norme sur $\mathbb{R}^n$. On note par $d_N : \mathbb{R}^n \times \mathbb{R}^n \rightarrow \mathbb{R}^+$ la distance induite par N , qui est définie par

$$d_N(x, y) = N(x - y), \quad \forall x, y \in \mathbb{R}^n,$$

et vérifie

1. $d_N(x, y) = 0$ ssi $x = y$,
2. $d_N(x, y) = d_N(y, x)$, $\forall x, y \in \mathbb{R}^n$,
3. $d_N(x, y) \leq d_N(x, z) + d_N(z, y)$, $\forall x, y, z \in \mathbb{R}^n$.

Définition 3 (Produit scalaire). Soient $x, y \in \mathbb{R}^n$. On note par $\langle x, y \rangle$ le produit scalaire usuel de x et y , défini par

$$\langle x, y \rangle = \sum_{i=1}^n x_i y_i.$$

On dira que x et y sont orthogonaux si $\langle x, y \rangle = 0$.

Remarque 1. On notera que $\|x\|_2 = \langle x, x \rangle^{1/2}$.

Définition 4 (Boules). Soit N une norme sur $\mathbb{R}^n$ et $r \geq 0$. On note $B_N(x, r)$ la boule fermée de centre x et de rayon r pour la norme N .

Définition 5 (Ensemble borné). On dira que $\Omega \subset \mathbb{R}^n$ est borné s'il existe $R > 0$ tel que $\Omega \subset B_N(0, R)$.

Remarque 2. Dans toute la suite, sauf mention contraire, les boules sont définies pour la norme euclidienne.

Définition 6 (Somme de Minkowski). Soit $A, B \subset \mathbb{R}^n$ et $\lambda \in \mathbb{R}$ on définit

$$\lambda A := \{\lambda a : a \in A\}.$$

La somme de Minkowski de A et B est définie par

$$A + B := \{a + b : a \in A, b \in B\}.$$

1.2 Topologie

Définition 7 (Ensemble ouvert, Ensemble fermé). Soient N une norme sur $\mathbb{R}^n$. Un ensemble $U \subset \mathbb{R}^n$ est un ouvert par rapport à la norme N si pour tout $x \in U$ il existe $r > 0$ tel que $B_N(x, r) \subset U$.

Un ensemble $F \subset \mathbb{R}^n$ est fermé si son complémentaire $F^c := \mathbb{R}^n \setminus F$ est un ouvert.

Théorème 1. 1. Les ensembles $\emptyset$ et $\mathbb{R}^n$ sont à la fois ouverts et fermés.

2. Toute union d'ouverts est toujours un ouvert. Toute intersection finie d'ouverts est un ouvert.
3. Toute union finie de fermés est un fermé. Toute intersection de fermés est un fermé.

Proposition 1. Un ensemble $F \subset \mathbb{R}^n$ est fermé si et seulement si $\forall (x_n)_n \in F^{\mathbb{N}}$

$$\left(\lim_{n \rightarrow \infty} x_n = x \right) \Rightarrow x \in F.$$

Définition 8. Soit $\Omega \subset \mathbb{R}^n$.

1. On dit que $x \in \Omega$ est un point intérieur à Ω s'il existe $\varepsilon > 0$ tel que $B_N(x, \varepsilon) \subset \Omega$.
L'ensemble des points intérieurs à Ω est noté $\text{int}(\Omega)$ ou $\overset{\circ}{\Omega}$.
2. On dira que Ω est ouvert si $\text{int}(\Omega) = \Omega$.
3. L'adhérence de Ω , noté $\text{cl}(\Omega)$ ou $\overline{\Omega}$ est l'ensemble $\mathbb{R}^n \setminus \text{int}(\mathbb{R}^n \setminus \Omega)$.
4. Le bord de Ω est $\partial\Omega = \overline{\Omega} \setminus \text{int}(\Omega)$.

Définition 9 (Ensemble compact). On dira que $\Omega \subset \mathbb{R}^n$ est compact s'il est fermé borné dans $\mathbb{R}^n$.

Théorème 2. Soit $\Omega \subset \mathbb{R}^n$ un compact. Alors de toute suite $(x_n)_n \in \Omega^{\mathbb{N}}$ on peut extraire une sous-suite convergente.

Théorème 3 (Weierstrass). Soit $f : \Omega \subset \mathbb{R}^n \rightarrow \mathbb{R}$ une fonction continue avec Ω un compact. Alors f est bornée et atteint ses bornes, i.e., $\exists x_*, x^* \in \Omega$ tels que

$$f(x^*) = \sup_{x \in \Omega} f(x) \text{ et } f(x_*) = \inf_{x \in \Omega} f(x).$$

1.3 Calcul différentiel

1.3.1 Fonctions dérivables, fonctions différentiables

Définition 10. Une fonction $f : \mathbb{R} \rightarrow \mathbb{R}$ est dite dérivable en un point $a \in \mathbb{R}$ s'il existe $l_a \in \mathbb{R}$ tel que

$$\frac{f(a+h) - f(a)}{h} \rightarrow l_a, \text{ lorsque } h \rightarrow 0.$$

Cela revient à dire que

$$f(a+h) = f(a) + hl_a + \varepsilon_a(h)|h|,$$

avec $\varepsilon_a(h) \rightarrow 0$ quand $h \rightarrow 0$.

Définition 11. Soit $f : U \subset \mathbb{R}^n \rightarrow \mathbb{R}^p$ avec U un ouvert. On dit que f est différentiable en $a \in U$ s'il existe une application linéaire $L_a : \mathbb{R}^n \rightarrow \mathbb{R}^p$ telle que, pour tout $h \in \mathbb{R}^n$ tel que $a+h \in U$

$$f(a+h) = f(a) + L_a(h) + \varepsilon_a(h)\|h\|_{\infty}.$$

De façon équivalente

$$\forall \varepsilon > 0, \exists \delta_{\varepsilon} > 0 : \|h\|_{\infty} \leq \delta_{\varepsilon} \Rightarrow \|f(a+h) - f(a) - L_a(h)\| \leq \varepsilon \|h\|_{\infty}$$

Remarque 3. Rappelons les résultats suivants:

1. Une fonction différentiable en un point $a \in U$ est continue en a .
2. La différentiabilité d'une fonction vectorielle en un point équivaut à celle de toutes ses fonctions composantes.
3. Quand $n = p = 1$, les notions de différentiabilité et dérivabilité coïncident.

1.3.2 Dérivées partielles

Définition 12. Soit $f : U \subset \mathbb{R}^n \rightarrow \mathbb{R}^p$ avec U un ouvert et fixons $k \in \{1, \dots, n\}$. On dit que f admet une dérivée partielle par rapport à sa k ème variable en $a \in U$ si

$$\frac{f(a + te_k) - f(a)}{t}$$

admet une limite quand $t \rightarrow 0$. On note cette limite $\frac{\partial f}{\partial x_k}(a)$. Ici, $\{e_1, \dots, e_n\}$ est la base

canonique de $\mathbb{R}^n$.

1.3.3 Jacobienne et Gradient

Définition 13. Soit $f : U \subset \mathbb{R}^n \rightarrow \mathbb{R}^p$ avec U un ouvert. Supposons que f admet en $a \in U$ des dérivées partielles par rapport à toutes ses variables. La matrice Jacobienne de f en a s'écrit

$$J_f(a) = \left(\frac{\partial f}{\partial x_1}(a), \dots, \frac{\partial f}{\partial x_n}(a) \right) = \begin{pmatrix} \frac{\partial f_1}{\partial x_1}(a) & \frac{\partial f_1}{\partial x_2}(a) & \cdots & \frac{\partial f_1}{\partial x_n}(a) \\ \frac{\partial f_2}{\partial x_1}(a) & \frac{\partial f_2}{\partial x_2}(a) & \cdots & \frac{\partial f_2}{\partial x_n}(a) \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_p}{\partial x_1}(a) & \frac{\partial f_p}{\partial x_2}(a) & \cdots & \frac{\partial f_p}{\partial x_n}(a) \end{pmatrix}.$$

Si $p = 1$, on définit le gradient de f en a par

$$\nabla f(a) = \left(\frac{\partial f}{\partial x_1}(a), \dots, \frac{\partial f}{\partial x_n}(a) \right)^T.$$

1.3.4 Fonctions de classe C^1

Définition 14. Soit $f : U \subset \mathbb{R}^n \rightarrow \mathbb{R}^p$ avec U un ouvert. On dit que f est de classe C^1 sur U , et on note $f \in C^1(U; \mathbb{R}^p)$ si pour tout $a \in U$, f admet en a des dérivées partielles par rapport à toutes ses variables et toutes les applications $a \mapsto \frac{\partial f}{\partial x_k}(a)$ sont continues sur U pour tout $k = 1, \dots, n$.

On rappelle le résultat fondamental suivant.

Théorème 4. Soit $f \in C^1(U; \mathbb{R}^p)$ avec $U \subset \mathbb{R}^n$ un ouvert. Soit $a \in U$, $r > 0$ tel que $B(a, r) \subset U$. Pour tout $h \in B(a, r)$

$$f(a + h) = f(a) + J_f(a)h + \varepsilon_a(h)\|h\|_\infty,$$

avec $\varepsilon_a : B(a, r) \rightarrow \mathbb{R}^p$ telle que $\varepsilon_a(h) \rightarrow 0$ quand $h \rightarrow 0$.

Remarque 4. Rappelons que $f \in C^1$ implique que f est différentiable. La différentiabilité de f implique la continuité de f et l'existence des dérivées partielles.

Remarque 5. Rappelons que pour tout $a \in U$ et $h \in \mathbb{R}^n$

$$J_f(a)h = \langle \nabla f(a), h \rangle,$$

i.e., $\nabla f(a) = J_f^T(a)$.

1.3.5 Composition

Théorème 5. Soit $U \subset \mathbb{R}^n, V \subset \mathbb{R}^m$ deux ouverts et $f : U \rightarrow V, g : V \rightarrow \mathbb{R}^p$ deux fonctions de classe C^1 . Alors $g \circ f \in C^1(U; \mathbb{R}^p)$ et on a, pour tout $a \in U$ et $j \in \{1, \dots, n\}$

$$\frac{\partial}{\partial x_j}(g \circ f)(a) = \sum_{k=1}^m \frac{\partial g}{\partial y_k}(f(a)) \frac{\partial f_k}{\partial x_j}(a).$$

Cela s'exprime aussi de manière plus compacte comme

$$\forall a \in U, J_{g \circ f}(a) = J_g(f(a))J_f(a).$$

1.3.6 Dérivées partielles d'ordre deux:

Définition 15. Soit $f \in C^1(U; \mathbb{R})$ avec U un ouvert de $\mathbb{R}^n$. On dit que f admet des dérivées partielles d'ordre deux en $a \in U$ si $\partial_{x_1}f, \dots, \partial_{x_n}f$ admettent des dérivées partielles en a . On a

$$\frac{\partial^2}{\partial x_i \partial x_j} f(a) := \frac{\partial}{\partial x_i} \left(\frac{\partial}{\partial x_j} f \right) (a).$$

Supposons que f est de classe C^2 . On appelle matrice Hessienne de f en a , notée $H_f(a)$ ou $\nabla^2 f(a)$ la matrice des dérivées partielles de f en a . On a

$$\nabla^2 f(a) := \left(\frac{\partial^2}{\partial x_i \partial x_j} f(a) \right)_{i,j=1,\dots,n}.$$

Définition 16. On dit que $f : U \rightarrow \mathbb{R}$ est de classe C^2 si f est C^1 admettant des dérivées partielles d'ordre deux et pour tout $i, j = 1, \dots, n$, l'application

$$a \in U \mapsto \frac{\partial^2}{\partial x_i \partial x_j} f(a),$$

est continue.

On rappelle le résultat fondamental suivant.

Théorème 6. Soit $f \in C^2(U; \mathbb{R})$. Alors pour tout $i, j = 1, \dots, n$ et $a \in U$

$$\frac{\partial^2}{\partial x_i \partial x_j} f(a) = \frac{\partial^2}{\partial x_j \partial x_i} f(a).$$

Corollaire 1. Soit $f \in C^2(U; \mathbb{R})$. Alors pour tout $a \in U$, $\nabla^2 f(a)$ est symétrique, i.e.,

$$\nabla^2 f(a) = (\nabla^2 f(a))^T.$$

1.4 Structure affine de $\mathbb{R}^n$

1.4.1 Plans

Définition 17 (Plan). On dit que $A \subset \mathbb{R}^n$ est un plan s'il s'écrit de la forme

$$A = a + V = \{a + v : v \in V\},$$

avec $a \in \mathbb{R}^n$ et V un sous-espace de $\mathbb{R}^n$.

Remarque 6. La Définition 17 nous dit qu'une partie A de $\mathbb{R}^n$ est un plan si elle est une translation d'un sous-espace vectoriel. Évidemment $\mathbb{R}^n$ est un plan. Par convention, $\emptyset$ est un plan. Dans la littérature, on rencontre souvent d'autres terminologies comme, ensemble affine, espace affine, variété affine etc.

Si $A \subset \mathbb{R}^n$ est un plan non-vide, et $a \in \mathbb{R}^n$. On considère

$$V = \{x - y : x, y \in A\}.$$

Théorème 7. Tout plan non-vide $A \subset \mathbb{R}^n$ est la translation d'un unique sous-espace vectoriel $V \subset \mathbb{R}^n$ donné par

$$V = \{x - y : x, y \in A\} := A - A.$$

De plus, pour $a \in \mathbb{R}^n$, $A = a + V$ si et seulement si $a \in A$. En particulier, A est un sous-espace si et seulement si $0 \in A$.

Notation. On notera par o , 0_n , $0_{\mathbb{R}^n}$ (ou tout simplement 0 s'il n'y a pas de confusion) le vecteur nul $\mathbb{R}^n$.

Définition 18 (Espace vectoriel associé et dimension). Soit $A \subset \mathbb{R}^n$ un plan non-vide. Le sous-espace $V := A - A$ est appelé le sous-espace vectoriel associé à A (ou sous-espace caractéristique de A) et est noté $\text{lin}(A)$. La dimension de A , notée $\dim(A)$ est définie comme la dimension (au sens des espaces vectoriels) de son espace associé V .

Remarque 7. Par convention $\dim(A) = -1$ si $A = \emptyset$. On appellera points (resp. droites) les plans de dimension 0 (resp. 1).

1.4.2 Droites et segments

Définition 19 (Droite). Soient $x, y \in \mathbb{R}^n$ distincts. La droite passant par x et y , notée par $D(x, y)$ ou $\langle x, y \rangle$ est définie par

$$\langle x, y \rangle = \{(1 - \lambda)x + \lambda y : \lambda \in \mathbb{R}\}. \quad (1.1)$$




Figure 1.1: Droite passant par x et y .

D'après [Théorème 7](#) et [Remarque 7](#), une droite de $\mathbb{R}^n$ est la translation d'un sous-espace de dimension 1. En vue de (1.1), on voit que

$$\langle x, y \rangle = x + \{\lambda(y - x) : \lambda \in \mathbb{R}\},$$

i.e., $\langle x, y \rangle$ est la translation du sous-espace engendré par $y - x$.

Définition 20 (Segments). Soient $x, y \in \mathbb{R}^n$ distincts. Le segment fermé $[x, y]$, ouvert (x, y) et les segments semi-ouverts $(x, y]$ et $[x, y)$ sont définis par

$$\begin{aligned} [x, y] &= \{(1 - \lambda)x + \lambda y : 0 \leq \lambda \leq 1\}, \\ [x, y) &= \{(1 - \lambda)x + \lambda y : 0 \leq \lambda < 1\}, \\ (x, y] &= \{(1 - \lambda)x + \lambda y : 0 < \lambda \leq 1\}, \\ (x, y) &= \{(1 - \lambda)x + \lambda y : 0 < \lambda < 1\}. \end{aligned}$$

1.4.3 Combinaisons affines

Définition 21. Une combinaison affine des points $x_1, \dots, x_m \in \mathbb{R}^n$ est une combinaison linéaire de la forme $\sum_{i=1}^m \lambda_i x_i$ avec $\sum_{i=1}^m \lambda_i = 1$.

Exemple 2. L'ensemble des combinaisons affines de deux points distincts x et y est la droite passant par x et y . En effet, l'application $\lambda \mapsto (1 - \lambda)x + \lambda y$ est une bijection de $\mathbb{R}$ vers $\langle x, y \rangle$.

Théorème 8. Une partie non vide A de $\mathbb{R}^n$ est un plan si et seulement si elle contient tous les points de la forme $(1 - \lambda)x + \lambda y$ pour tout $x, y \in A$ et $\lambda \in \mathbb{R}$.

Preuve. Laissée en exercice. □

Plus généralement, on a

Théorème 9. Une partie non vide A de $\mathbb{R}^n$ est un plan si et seulement si elle contient toutes les combinaisons affines de points de A .

1.4.4 Espace affine engendré ou Enveloppe affine

Définition 22. Soit $A \subset \mathbb{R}^n$. On appelle sous-espace affine engendré par A , note $\text{aff}(A)$, l'intersection de tous les plans contenant A .

Le résultat suivant décrit $\text{aff}(A)$ en terme des combinaisons affines de points de A .

Théorème 10. Soit A une partie non-vide de $\mathbb{R}^n$.

1. L'enveloppe affine de A est l'ensemble de toutes les combinaisons affines de point de A , i.e.,

$$\text{aff}(A) = \left\{ \sum_{i=1}^m \lambda_i x_i : m \geq 1, x_1, \dots, x_m \in A, \text{ et } \sum_{i=1}^m \lambda_i = 1 \right\}.$$

2. $\text{aff}(A)$ est le plus petit sous-espace affine contenant A .
3. Pour $x_1, \dots, x_m \in \mathbb{R}^n$:

$$\text{aff}(\{x_1, \dots, x_m\}) = \left\{ \sum_{i=1}^m \lambda_i x_i : \sum_{i=1}^m \lambda_i = 1 \right\}$$

1.4.5 Indépendance affine

Définition 23. On dit que des points $x_1, \dots, x_m \in \mathbb{R}^n$ avec $m \geq 2$, sont affinement dépendants s'il existe des scalaires $\lambda_1, \dots, \lambda_m$ non tous nuls tel que

$$\sum_{i=1}^m \lambda_i x_i = 0 \text{ et } \sum_{i=1}^m \lambda_i = 0.$$

On dira que la famille $\{x_1, \dots, x_m\}$ est affinement indépendante si elle n'est pas affinement dépendante.

1.5 Vecteurs et valeurs propres

Définition 24. Soit $A \in \mathbb{R}^{n \times n}$ et $0 \neq v \in \mathbb{R}^n$. On dit que v est un vecteur propre de A s'il existe $\lambda \in \mathbb{C}$ tel que $Av = \lambda v$. On appelle λ la valeur propre associée à v . L'ensemble des valeurs propres de A est appelé spectre de A et est souvent noté par $\sigma(A)$.

Soit $A \in \mathbb{R}^{n \times n}$, en général $\sigma(A) \subset \mathbb{C}$. Si A est symétrique, alors ses valeurs propres sont réelles. On note alors

$$\lambda_{\max}(A) := \lambda_1(A) \geq \dots \geq \lambda_{\min}(A) := \lambda_n(A),$$

les valeurs propres de A où $\lambda_{\max}$ (respectivement $\lambda_{\min}$) est la plus grande (respectivement la plus petite) valeur propre de A .

Théorème 11 (Décomposition spectrale). Soit $A \in \mathbb{S}^n$. Il existe alors $U \in O(n)$ (i.e., $U^t U = U U^t = \text{Id}$) et une matrice diagonale $D = \text{diag}(\alpha_1, \dots, \alpha_n)$ tels que $U^t A U = D$.

Remarque 8. Les colonnes de U représentent les vecteurs propres de A tandis que les éléments diagonaux de D sont les valeurs propres associées.

Corollaire 2. Soit $A \in \mathbb{S}_n$, alors $\text{trace}(A) = \sum_{i=1}^n \lambda_i(A)$ et $\det(A) = \prod_{i=1}^n \lambda_i(A)$.

1.6 Classification des matrices

On rappelle ici quelques résultats concernant la classification de matrices qui seront utiles pour les conditions d'optimalité dans la [Section 4.1](#).

Définition 25. Soit $A \in \mathbb{S}^n$.

1. A est dite semi-définie positive, et on note $A \succeq 0$, si $\langle Ax, x \rangle \geq 0$ pour tout $x \in \mathbb{R}^n$.
2. A est dite définie positive, et on note $A \succ 0$, si $\langle Ax, x \rangle > 0$ pour tout $x \in \mathbb{R}^n \setminus \{0\}$.
3. A est dite semi-définie négative, et on note $A \preceq 0$, si $\langle Ax, x \rangle \leq 0$ pour tout $x \in \mathbb{R}^n$.
4. A est dite définie négative, et on note $A \prec 0$, si $\langle Ax, x \rangle < 0$ pour tout $x \in \mathbb{R}^n \setminus \{0\}$.
5. A est dite non-définie s'il existe $x, y \in \mathbb{R}^n$ tels que

$$\langle Ax, x \rangle < 0 \text{ et } \langle Ay, y \rangle > 0.$$

Proposition 2. 1. Soit $A \in \mathbb{S}_+^n$ (respectivement dans $\mathbb{S}_{++}^n$). Alors les éléments diagonaux de A sont positifs (respectivement strictement positifs).

2. Soit $A \in \mathbb{S}_-^n$ (respectivement dans $\mathbb{S}_{--}^n$). Alors les éléments diagonaux de A sont négatifs (respectivement strictement négatifs).

Preuve. Exercice. □

Pour les matrices non-définies, on a le résultat suivant.

Proposition 3. Soit $A \in \mathbb{S}^n$. Si A possède des éléments diagonaux strictement négatifs et positifs, alors A est non-définie.

Preuve. Exercice. □

Le résultat suivant permet de classer les matrices à partir de l'information spectrale.

Théorème 12. Soit $A \in \mathbb{S}^n$. Alors

1. $A \in \mathbb{S}_{++}^n$ ssi $\sigma(A) \subset \mathbb{R}_+^*$.
2. $A \in \mathbb{S}_+^n$ ssi $\sigma(A) \subset \mathbb{R}_+$.
3. $A \in \mathbb{S}_{--}^n$ ssi $\sigma(A) \subset \mathbb{R}_-^*$.
4. $A \in \mathbb{S}_-^n$ ssi $\sigma(A) \subset \mathbb{R}_-$.
5. $A \in \mathbb{S}_\pm^n$ ssi il existe $\lambda, \mu \in \sigma(A)$ tels que $\lambda > 0$ et $\mu < 0$.

Preuve. Laissée en exercice (utiliser [Théorème 11](#)). □

Remarque 9. Dans toute la suite, on s'intéressera principalement aux matrices symétriques réelles.

1.7 Limites supérieures et inférieures de suites

Étant donnée une suite $(u_n)_n$ de réels, la quantité $\lim_{n \rightarrow \infty} u_n$ n'a aucune raison d'exister. L'exemple typique est celui de $u_n = (-1)^n$. Quand la suite $(u_n)_n$ est bornée, le théorème de Bolzano-Weierstrass assure l'existence d'une sous-suite convergente $(u_{n_k})_k$, i.e., $\lim_{k \rightarrow \infty} u_{n_k} = l \in \mathbb{R}$.

Définition 26. Soit $(u_n)_{n \in \mathbb{N}}$ une suite à valeurs dans $\overline{\mathbb{R}}$. Les suites $(\inf_{k \geq n} u_k)_{n \in \mathbb{N}}$ et $(\sup_{k \geq n} u_k)_{n \in \mathbb{N}}$ sont monotones (la première est croissante, la seconde décroissante). On définit alors

$$\begin{aligned} \liminf u_n &= \lim_{n \rightarrow +\infty} \left(\inf_{k \geq n} u_k \right) = \sup_{n \in \mathbb{N}} \left(\inf_{k \geq n} u_k \right), \\ \limsup u_n &= \lim_{n \rightarrow +\infty} \left(\sup_{k \geq n} u_k \right) = \inf_{n \in \mathbb{N}} \left(\sup_{k \geq n} u_k \right). \end{aligned}$$

Après cette définition formelle, la proposition suivante donne une caractérisation plus intuitive de ces deux quantités $\limsup u_n$ et $\liminf u_n$.

Proposition 4. Soit $(u_n)_{n \in \mathbb{N}}$ une suite à valeurs dans $\overline{\mathbb{R}}$. Alors $\liminf u_n$ est la plus petite valeur d'adhérence de $(u_n)_n$ et $\limsup u_n$ est la plus grande valeur d'adhérence de $(u_n)_n$. De plus

$$\liminf u_n \leq \limsup u_n,$$

avec égalité si et seulement si $(u_n)_n$ converge vers $l = \liminf u_n = \limsup u_n$.

Ensembles convexes

2.1 Définitions

2.1.1 Ensembles convexes

Définition 27. Soit $C \subset \mathbb{R}^n$. On dit que C est convexe si pour tout $x, y \in C$ et tout $\lambda \in [0, 1]$, $\lambda x + (1 - \lambda)y \in C$.

Remarque 10. Cette définition est équivalente à dire que le segment $[x, y]$ est inclus dans C (i.e., $[x, y] \subset C$). La Fig. 2.1 illustre quelques exemples d'ensembles convexes et non convexes.




Figure 2.1: La Fig. 2.1a: des ensembles convexes de $\mathbb{R}^2$. Fig. 2.1b: ensembles non convexes.

Exemple 3. Voici quelques exemples d'ensembles convexes :

- Dans $\mathbb{R}$, les seuls exemples d'ensembles convexes sont les intervalles : (a, b) , $[a, b]$, $(-\infty, a]$, etc.
- Les boules (ouvertes, fermées) :

$$B(a, r) = \{x \in \mathbb{R}^n : \|x - a\| < r\} \quad \text{et} \quad \bar{B}(a, r) = \{x \in \mathbb{R}^n : \|x - a\| \leq r\},$$

avec $a \in \mathbb{R}^n$ et $r > 0$.

- Les hyperplans :

$$H = \{x \in \mathbb{R}^n : a^T x = b\}, \quad \text{avec } a \in \mathbb{R}^n, b \in \mathbb{R}.$$

- Les demi-espaces (ou demi-plans), les ellipsoïdes.
- Soit $\mathcal{S}^n = \{A \in \mathbb{R}^{n \times n} : A^T = A\}$ l'ensemble des matrices symétriques. On rappelle que $\mathcal{S}^n$ est un espace vectoriel de dimension $n(n+1)/2$. Les ensembles $\mathcal{S}_+^n = \{A \in \mathcal{S}^n : A \succeq 0\}$ (matrices semi-définies positives) et $\mathcal{S}_{++}^n = \{A \in \mathcal{S}^n : A \succ 0\}$ (matrices définies positives) sont des ensembles convexes.

2.1.2 Ensembles affines

Définition 28. Soit $C \subset \mathbb{R}^n$. On dit que C est affine si pour tout $x, y \in C$ et tout $\lambda \in \mathbb{R}$, $\lambda x + (1 - \lambda)y \in C$.

Évidemment, tout ensemble affine est convexe. La réciproque n'est pas vraie.

Exemple 4. • L'ensemble des solutions $S = \{x \in \mathbb{R}^n : Ax = b\}$ d'un système linéaire est un ensemble affine.

- Soit E un sous-espace vectoriel de $\mathbb{R}^n$ et $a \in \mathbb{R}^n$. L'ensemble

$$a + E := \{a + x : x \in E\}$$

est un sous-espace affine (ou ensemble affine).

2.2 Opérations et propriétés topologiques préservant la convexité

Le résultat suivant récapitule quelques opérations préservant la convexité.

Théorème 13. 1. Soit $(C_i)_{i \in I}$ une famille d'ensembles convexes de $\mathbb{R}^n$. Alors $C := \bigcap_{i \in I} C_i$ est convexe.

2. Soient $C_1, \dots, C_m$ des convexes de $\mathbb{R}^n$ et $\lambda_1, \dots, \lambda_m \in \mathbb{R}$. Alors les ensembles

$$\sum_{i=1}^m \lambda_i C_i = \left\{ \sum_{i=1}^m \lambda_i x_i : x_i \in C_i, i = 1, \dots, m \right\}$$

et

$$\prod_{i=1}^m C_i = \left\{ (x_1, \dots, x_m) : x_i \in C_i, i = 1, \dots, m \right\}$$

sont convexes.

3. Si $C \subset \mathbb{R}^n$ est convexe et $\Phi : \mathbb{R}^n \rightarrow \mathbb{R}^m$ est une application affine définie par $\Phi(x) = Ax + b$ (avec $A \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m$), alors l'image de C

$$\Phi(C) = \{Ax + b : x \in C\}$$

est convexe. De même, si $D \subset \mathbb{R}^m$ est convexe, alors l'image réciproque

$$\Phi^{-1}(D) = \{x \in \mathbb{R}^n : \Phi(x) \in D\}$$

est convexe.

Preuve. 1. Soient $x, y \in C$ et $\lambda \in [0, 1]$. Alors $x, y \in C_i$ pour tout $i \in I$. Par convexité des C_i , on a $z := \lambda x + (1 - \lambda)y \in C_i$ pour tout $i \in I$. Donc $z \in C$.

2. Voir TD.

3. Soient $y_1, y_2 \in \Phi(C)$ et $\lambda \in [0, 1]$. Montrons que $y := \lambda y_1 + (1 - \lambda)y_2 \in \Phi(C)$. Par définition, il existe $x_1, x_2 \in C$ tels que $y_1 = \Phi(x_1)$ et $y_2 = \Phi(x_2)$ (i.e., $y_1 = Ax_1 + b$ et $y_2 = Ax_2 + b$). Donc $y = A(\lambda x_1 + (1 - \lambda)x_2) + b$. Par convexité de C , le point $x_\lambda = \lambda x_1 + (1 - \lambda)x_2$ appartient à C , et donc $y = \Phi(x_\lambda) \in \Phi(C)$.

De même, soient $x_1, x_2 \in \Phi^{-1}(D)$. Alors $\Phi(x_1) \in D$ et $\Phi(x_2) \in D$. Soit $x = \lambda x_1 + (1 - \lambda)x_2$ avec $\lambda \in [0, 1]$. On a

$$\Phi(x) = A(\lambda x_1 + (1 - \lambda)x_2) + b = \lambda(Ax_1 + b) + (1 - \lambda)(Ax_2 + b) = \lambda\Phi(x_1) + (1 - \lambda)\Phi(x_2).$$

Comme D est convexe, cette combinaison convexe appartient à D . Ainsi $\Phi(x) \in D$, ce qui signifie que $x \in \Phi^{-1}(D)$. □

Remarque 11. Dans le [Théorème 13-1](#), l'ensemble d'indices I est quelconque, i.e., il peut être infini.

Exemple 5. Soient $A \in \mathbb{R}^{m \times n}$ et $b \in \mathbb{R}^m$. L'ensemble suivant, appelé polyèdre (ou polytope),

$$P = \{x \in \mathbb{R}^n : Ax \leq b\},$$

est convexe. En effet, on peut voir que

$$P = \bigcap_{i=1}^m H_i, \quad \text{avec} \quad H_i = \{x \in \mathbb{R}^n : l_i(A)x \leq b_i\},$$

où $l_i(A)$ est la i -ème ligne de A . Les ensembles H_i sont des demi-espaces fermés, donc ils sont convexes (pourquoi ?). Ainsi, P est convexe comme intersection d'ensembles convexes.







Figure 2.2: Exemples de polytopes.

Théorème 14. Soit $C \subset \mathbb{R}^n$ un ensemble convexe. Alors $\overline{C}$ est convexe.

Preuve. Soient $x, y \in \overline{C}$ et $\lambda \in [0, 1]$. Montrons que $\lambda x + (1 - \lambda)y \in \overline{C}$. Il existe deux suites $(x_n)_n$ et $(y_n)_n$ d'éléments de C telles que $x_n \rightarrow x$ et $y_n \rightarrow y$ quand $n \rightarrow \infty$. Comme C est convexe, il vient que $\lambda x_n + (1 - \lambda)y_n \in C$. En passant à la limite quand $n \rightarrow \infty$, on obtient $\lambda x_n + (1 - \lambda)y_n \rightarrow \lambda x + (1 - \lambda)y$, i.e., $\lambda x + (1 - \lambda)y \in \overline{C}$. □

Preuve. (bis) Il suffit de remarquer que

$$\overline{C} = \bigcap_{\varepsilon > 0} (C + B(0, \varepsilon)),$$

et de conclure par le [Théorème 13-1](#) (sachant que la somme de deux convexes est convexe). □

Théorème 15. Soit $C \subset \mathbb{R}^n$ un convexe. Alors $\text{int}(C)$ est convexe.

Avant de démontrer ce résultat, on introduit le lemme suivant.

Lemme 1. Soit $C \subset \mathbb{R}^n$ un convexe d'intérieur non vide. Soit $x \in \text{int}(C)$ et $y \in \overline{C}$. Alors $\lambda x + (1 - \lambda)y \in C$ pour tout $\lambda \in (0, 1)$.

Preuve. Comme $x \in \text{int}(C)$, il existe $\varepsilon > 0$ tel que $B(x, \varepsilon) \subset C$. Soit $\lambda \in (0, 1)$ et posons $z = (1 - \lambda)x + \lambda y$. Montrons que $B(z, \eta) \subset C$ pour un certain $\eta > 0$. Soit w tel que $\|z_1 - z\| < \varepsilon(1 - \lambda)$. Comme $y \in \overline{C}$, il existe $u \in C$ tel que $\|u - y\| < (\varepsilon(1 - \lambda) - \|w - z\|)\lambda^{-1}$. On pose $v = (w - \lambda u)/(1 - \lambda)$. Comme $(1 - \lambda)x = z - \lambda y$, il vient que

$$\begin{aligned} \|v - x\| &= \frac{1}{1 - \lambda} \|(w - z) + \lambda(y - u)\| \\ &\leq \frac{1}{1 - \lambda} (\|w - z\| + \varepsilon(1 - \lambda) - \|w - z\|) < \varepsilon. \end{aligned} \quad (2.1)$$

On en déduit que $v \in C$ car $B(x, \varepsilon) \subset C$ et par la suite $w = (1 - \lambda)v + \lambda u \in C$. Finalement, pour $\eta = (1 - \lambda)\varepsilon$, on a $B(z, \eta) \subset C$, ce qui termine la preuve. $\square$

Preuve. du [Théorème 15](#). Si $\text{int}(C) = \emptyset$ rien à démontrer. Sinon, soient $x, y \in \text{int}(C)$ et soit $z = (1 - \lambda)x + \lambda y$ avec $\lambda \in (0, 1)$. Il existe $\varepsilon > 0$ tel que $B(x, \varepsilon) \subset C$. On a

$$B(z, (1 - \lambda)\varepsilon) = \lambda y + (1 - \lambda)B(x, \varepsilon) \subset C,$$

et donc $z \in \text{int}(C)$. $\square$

Le résultat suivant se démontre facilement grâce au [Lemme 1](#).

Proposition 5. Soit $C \subset \mathbb{R}^n$ un convexe d'intérieur non vide. Alors

1. $\overline{\text{int}(C)} = \overline{C}$.
2. $\text{int}(\overline{C}) = \text{int}(C)$.

On termine cette partie par le résultat suivant.

Proposition 6. Soit $X \subset \mathbb{R}^n$ un compact. Alors $\text{Conv}(X)$ est compact.

Remarque 12. En général, le passage par l'enveloppe convexe ne préserve pas le caractère fermé. Cela peut être vu avec l'exemple suivant. Soit


$$X = \left\{ \begin{pmatrix} 0 \\ 0 \end{pmatrix} \right\} \cup \left\{ \begin{pmatrix} x \\ y \end{pmatrix} \in \mathbb{R}_+^2 : xy \geq 1 \right\}.$$

On vérifie facilement que X est fermé, tandis que $\text{Conv}(X) = \left\{ \begin{pmatrix} 0 \\ 0 \end{pmatrix} \right\} \cup \mathbb{R}_{++}^2$ n'est ni ouvert ni fermé.

2.3 Enveloppe convexe

Définition 29. Soient $x_1, \dots, x_m \in \mathbb{R}^n$. Une combinaison convexe des x_i est un vecteur de la forme $\sum_{i=1}^m \lambda_i x_i$ avec $\lambda_i \geq 0$ pour tout $i = 1, \dots, m$ et $\sum_{i=1}^m \lambda_i = 1$. On écrit $\lambda = (\lambda_1, \dots, \lambda_m) \in \Delta_m$ où

$$\Delta_m = \left\{ \lambda = (\lambda_1, \dots, \lambda_m) \in \mathbb{R}^m : \lambda_i \geq 0, \forall i = 1, \dots, m \text{ et } \sum_{i=1}^m \lambda_i = 1 \right\}.$$

Figure 2.3: Simplexes dans $\mathbb{R}^3$.

Théorème 16. Soit $C \subset \mathbb{R}^n$ un ensemble convexe et $x_1, \dots, x_m \in C$. Alors pour tout $\lambda \in \Delta_m$, on a $\sum_{i=1}^m \lambda_i x_i \in C$.

Preuve. On procède par récurrence. Pour $m = 1$, il n'y a rien à démontrer. Supposons que pour tous vecteurs $x_1, \dots, x_m \in C$ et $\lambda \in \Delta_m$, on a $\sum_{i=1}^m \lambda_i x_i \in C$.

Soient maintenant $x_1, \dots, x_{m+1} \in C$ et $\lambda \in \Delta_{m+1}$. Montrons que $z := \sum_{i=1}^{m+1} \lambda_i x_i \in C$.

Si $\lambda_{m+1} = 1$, on a $\lambda_1 = \dots = \lambda_m = 0$, donc $z = x_{m+1} \in C$.

Supposons donc que $\lambda_{m+1} < 1$. On peut écrire :

$$z = \sum_{i=1}^{m+1} \lambda_i x_i = \sum_{i=1}^m \lambda_i x_i + \lambda_{m+1} x_{m+1} = (1 - \lambda_{m+1}) \underbrace{\sum_{i=1}^m \frac{\lambda_i}{1 - \lambda_{m+1}} x_i}_y + \lambda_{m+1} x_{m+1}.$$

On remarque que les coefficients $\mu_i = \frac{\lambda_i}{1 - \lambda_{m+1}}$ sont positifs et vérifient $\sum_{i=1}^m \mu_i = 1$ (car $\sum_{i=1}^m \lambda_i = 1 - \lambda_{m+1}$). Par hypothèse de récurrence, il s'ensuit que $y \in C$.

Enfin, comme $z = (1 - \lambda_{m+1})y + \lambda_{m+1}x_{m+1}$ est une combinaison convexe de deux points de C (y et x_{m+1}), on conclut par définition de la convexité que $z \in C$. $\square$

Définition 30. Soit $S \subset \mathbb{R}^n$. On appelle enveloppe convexe de S , notée $\text{Conv}(S)$, l'ensemble des combinaisons convexes de points de S :

$$\text{Conv}(S) = \left\{ \sum_{i=1}^m \lambda_i x_i : m \geq 1, x_i \in S, \lambda \in \Delta_m \right\}.$$

Remarque 13. 1. Dans la Définition 30, l'entier m est quelconque.

2. L'enveloppe convexe d'un ensemble S est le plus petit ensemble convexe contenant S : si $S \subset U$ avec U convexe, alors $\text{Conv}(S) \subset U$.

Proposition 7. Soit $S \subset \mathbb{R}^n$. Si $S \subset U$ avec U convexe, alors $\text{Conv}(S) \subset U$.

Preuve. La preuve est immédiate. Si $z \in \text{Conv}(S)$, alors $z = \sum_{i=1}^m \lambda_i x_i$ avec $x_i \in S$ et $\lambda = (\lambda_i)_{i=1}^m \in \Delta_m$. Comme $S \subset U$, alors les x_i appartiennent aussi à U . Ce dernier étant convexe, il contient $\sum_{i=1}^m \lambda_i x_i$, i.e., $z \in U$. Donc $\text{Conv}(S) \subset U$. $\square$

Le résultat suivant affirme que tout vecteur x dans l'enveloppe convexe d'un sous-ensemble S de $\mathbb{R}^n$ peut s'écrire comme combinaison convexe d'au plus $n + 1$ vecteurs de S .

Théorème 17 (Carathéodory). Soit $S \subset \mathbb{R}^n$ et $x \in \text{Conv}(S)$. Alors il existe $x_1, \dots, x_{n+1} \in S$ tels que $x \in \text{Conv}(\{x_1, \dots, x_{n+1}\})$.





Figure 2.4: Exemple d'un ensemble non-convexe et son enveloppe convexe.

Figure 2.5: Dans cet exemple on a $x \in \text{Conv}(\{x_1, \dots, x_5\})$. Par le théorème de Carathéodory x peut s'exprimer comme combinaison d'au plus 3 vecteur. Ici, on voit bien que $x \in \text{Conv}(\{x_1, x_2, x_5\})$.

Preuve. Soit $x \in \text{Conv}(S)$. Il existe, par définition, $x_1, \dots, x_m \in S$ et $\lambda \in \Delta_m$ tels que $x = \sum_{i=1}^m \lambda_i x_i$. Supposons que $\lambda_i > 0$ pour tout $i = 1, \dots, m$. Si $m \leq n+1$, il n'y a rien à démontrer. Sinon, supposons $m > n+1$.

Considérons la famille de vecteurs $(v_i)_{i=2, \dots, m}$ définie par $v_i = x_i - x_1$. On remarque que cette famille est liée puisqu'elle contient $m-1$ vecteurs et que $m-1 > n$. Il existe donc des réels $\mu_2, \dots, \mu_m$ non tous nuls tels que $\sum_{i=2}^m \mu_i v_i = 0$, i.e., $\sum_{i=2}^m \mu_i (x_i - x_1) = 0$.

On définit $\mu_1 = -\sum_{i=2}^m \mu_i$. On a par construction :

$$\sum_{i=1}^m \mu_i x_i = 0 \quad \text{et} \quad \sum_{i=1}^m \mu_i = 0,$$

où les μ_i ne sont pas tous nuls. En particulier, il existe $i \in \{1, \dots, m\}$ tel que $\mu_i < 0$. Pour tout $\eta \geq 0$, on a :

$$x = \sum_{i=1}^m \lambda_i x_i = \sum_{i=1}^m \lambda_i x_i + \eta \sum_{i=1}^m \mu_i x_i = \sum_{i=1}^m \beta_i x_i,$$

avec $\beta_i = \lambda_i + \eta \mu_i$ et $\sum_{i=1}^m \beta_i = 1$. L'écriture $\sum_{i=1}^m \beta_i x_i$ est une combinaison convexe si et seulement si $\beta_i \geq 0$ pour tout $i = 1, \dots, m$. Comme les $\lambda_i > 0$, cela est vrai pour $\eta \in [0, \varepsilon]$ avec $\varepsilon = \min_{\{i: \mu_i < 0\}} \frac{-\lambda_i}{\mu_i}$.

Pour $\eta = \varepsilon$, on obtient que $\lambda_{i^*} + \eta \mu_{i^*} = 0$ pour un certain $i^* \in \{1, \dots, m\}$. Cela annule le coefficient devant x_{i^*} et fournit une combinaison convexe de x avec $m-1$ vecteurs. On répète le processus jusqu'à obtenir une combinaison convexe avec au plus $n+1$ vecteurs. $\square$

Exemple 6. On considère $S = \{x_1, x_2, x_3, x_4\} \subset \mathbb{R}^2$ avec

$$x_1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad x_2 = \begin{pmatrix} 1 \\ 2 \end{pmatrix}, \quad x_3 = \begin{pmatrix} 2 \\ 1 \end{pmatrix}, \quad x_4 = \begin{pmatrix} 2 \\ 2 \end{pmatrix}.$$

Soit $x \in \text{Conv}(S)$ donné par $x = 1/8x_1 + 1/4x_2 + 1/2x_3 + 1/8x_4 = \frac{1}{8} \begin{pmatrix} 13 \\ 11 \end{pmatrix}$. Par le [Théorème 17](#),

on peut représenter x par trois vecteurs de S (car $n = 2$). On procède comme dans la preuve du théorème.

Les vecteurs $u = (x_2 - x_1)$, $v = (x_3 - x_1)$ et $w = (x_4 - x_1)$ sont linéairement dépendants (trois vecteurs dans $\mathbb{R}^2$). On a $\mu_2 u + \mu_3 v + \mu_4 w = 0$ avec $\mu_2 = \mu_3 = 1$ et $\mu_4 = -1$. Donc $\mu_1 = -(\mu_2 + \mu_3 + \mu_4) = -1$. La relation de dépendance affine s'écrit $-x_1 + x_2 + x_3 - x_4 = 0$. On a, pour $\eta \geq 0$:

$$\begin{aligned} x &= (1/8 + \eta\mu_1)x_1 + (1/4 + \eta\mu_2)x_2 + (1/2 + \eta\mu_3)x_3 + (1/8 + \eta\mu_4)x_4 \\ &= (1/8 - \eta)x_1 + (1/4 + \eta)x_2 + (1/2 + \eta)x_3 + (1/8 - \eta)x_4, \end{aligned} \quad (2.2)$$

et pour assurer que l'écriture ci-dessus est une combinaison convexe, on impose que $1/8 - \eta \geq 0$, $1/4 + \eta \geq 0$ et $1/2 + \eta \geq 0$, soit $\eta \in [0, 1/8]$. Pour $\eta = 1/8$, on obtient

$$x = \frac{3}{8}x_2 + \frac{5}{8}x_3 \quad (\text{cf. Fig. 2.6}).$$




Figure 2.6: Illustration de l'Exemple 6.

2.4 Cônes convexes

Définition 31 (Cône). Soit $S \subset \mathbb{R}^n$. On dit que S est un cône si pour tout $x \in S$ et $\lambda \geq 0$, on a $\lambda x \in S$.

Le résultat suivant donne une caractérisation d'un cône convexe.

Proposition 8. Un ensemble $S \subset \mathbb{R}^n$ est un cône convexe si et seulement si

1. $x \in S, \lambda \geq 0 \Rightarrow \lambda x \in S$,
2. $x, y \in S \Rightarrow x + y \in S$.

Preuve. Supposons que S vérifie 1 and 2. Soient $x, y \in S$ et $\lambda \in [0, 1]$. On sait déjà par 1 que S est un cône. D'autre part, comme $\lambda \geq 0$ et $(1 - \lambda) \geq 0$, les vecteurs λx et $(1 - \lambda)y$ appartiennent à S (toujours d'après 1). On déduit alors par 2 que leur somme $\lambda x + (1 - \lambda)y$ appartient à S , d'où la convexité.

Réciproquement, supposons que S est un cône convexe. La propriété 1 découle directement de la définition d'un cône. Soient $x, y \in S$. Par convexité de S , on a $\frac{1}{2}x + \frac{1}{2}y = \frac{1}{2}(x + y) \in S$. Comme S est un cône, il est stable par multiplication scalaire positive, donc $x + y = 2\left(\frac{1}{2}(x + y)\right) \in S$, d'où 2. $\square$

Voici quelques exemples de cônes convexes.

Exemple 7. 1. Tout sous-espace vectoriel de $\mathbb{R}^n$ (en particulier, l'espace $\mathbb{R}^n$ lui-même et $\{0\}$).

2. L'orthant positif $\mathbb{R}_+^n = \{(x_1, \dots, x_n) \in \mathbb{R}^n : x_1 \geq 0, \dots, x_n \geq 0\}$. Ou plus généralement, un ensemble de la forme

$$S = \{x \in \mathbb{R}^n : Ax \leq 0\},$$

avec $A \in \mathbb{R}^{m \times n}$ (c'est un cône polyédrique). On remarque que pour $A = -I_n$, on obtient $\mathbb{R}_+^n$.

3. Le cône de Lorentz (ou cône du second ordre) :

$$L^n = \{(x, t) \in \mathbb{R}^n \times \mathbb{R} : \|x\|_2 \leq t\}.$$




Figure 2.7: Le cône de Lorentz L^2 .

2.4.1 Points extrémaux (ou sommets)

Définition 32. Soit $S \subset \mathbb{R}^n$. On dit que $x \in S$ est un point extrémal de S s'il n'existe pas de $y, z \in S$ avec $y \neq z$ et de $\lambda \in (0, 1)$ tels que $x = \lambda y + (1 - \lambda)z$. On note $\text{ext}(S)$ l'ensemble des points extrémaux de S .

Remarque 14. Une autre définition équivalente est la suivante. Soit $x \in S$. Alors $x \in \text{ext}(S)$ si et seulement s'il n'existe pas de $y, z \in S$ distincts tels que $x = \frac{y+z}{2}$.




Figure 2.8: Exemple d'un point extrémal x' car il n'existe pas $x'_1 \neq x'_2 \in C$ tels que $x' = \frac{x'_1 + x'_2}{2}$, tandis que x n'est pas un point extrémal.

Étant donné un convexe $C \subset \mathbb{R}^n$, on cherche en pratique un ensemble $S \subset \mathbb{R}^n$ tel que $C = \text{Conv}(S)$. On a le résultat suivant.

Théorème 18. Soit $C = \text{Conv}(S)$ avec $S \subset \mathbb{R}^n$ et soit $x \in S$. Alors $x \in \text{ext}(C)$ si et seulement si $x \notin \text{Conv}(S \setminus \{x\})$.

Preuve. Soit $x \in \text{Conv}(S \setminus \{x\})$. Montrons que $x \notin \text{ext}(C)$, i.e., qu'il existe $y, z \in C$ distincts tels que $x \in [y, z]$. Comme $x \in \text{Conv}(S \setminus \{x\})$, il vient que $x = \sum_{i=1}^k \lambda_i x_i$ avec $x_i \in S \setminus \{x\}$ pour tout $i = 1, \dots, k$ et $\lambda \in \Delta_k$ (avec $\lambda_i > 0$). Comme $x \neq x_i$ pour tout i , on a nécessairement $k > 1$.

Posons $y = x_k$ et $z = \sum_{i=1}^{k-1} \frac{\lambda_i}{1-\lambda_k} x_i$. On remarque que z est une combinaison convexe bien définie (car $\sum_{i=1}^{k-1} \lambda_i = 1 - \lambda_k$). Avec ce choix, on a bien

$$x = \lambda_k y + (1 - \lambda_k) z.$$

Puisque $\lambda_k \in (0, 1)$, x est une combinaison convexe stricte de y et z , donc $x \notin \text{ext}(C)$.

Inversement, supposons que $x \notin \text{ext}(C)$, i.e., $x = (y + z)/2$ avec $y, z \in C$ et $y \neq z$. On peut écrire $y = \sum_{i=1}^k \lambda_i x_i$ et $z = \sum_{i=1}^k \mu_i x_i$ avec $x_i \in S$ pour tout $i = 1, \dots, k$ (quitte à compléter avec des coefficients nuls pour avoir les mêmes indices).

Si $x \neq x_i$ pour tout i , on a

$$x = \frac{y + z}{2} = \sum_{i=1}^k \frac{\lambda_i + \mu_i}{2} x_i.$$

Les coefficients sont positifs et leur somme vaut 1, donc $x \in \text{Conv}(S \setminus \{x\})$.

Sinon, supposons que $x = x_i$ pour un certain i , disons $x = x_k$. Comme $x \neq y$ et $x \neq z$, il vient que $\lambda_k < 1$ et $\mu_k < 1$ (sinon, par exemple si $\lambda_k = 1$, alors $y = x_k = x$, ce qui impliquerait $z = x$ et donc $y = z$, une contradiction). On a

$$\sum_{i=1}^{k-1} \frac{\lambda_i + \mu_i}{2} x_i = \frac{y + z}{2} - \frac{\lambda_k + \mu_k}{2} x_k = \left(1 - \frac{\lambda_k + \mu_k}{2}\right) x.$$

En divisant par le coefficient de droite (qui est non nul car $\lambda_k + \mu_k < 2$), on obtient :

$$x = \sum_{i=1}^{k-1} \frac{\lambda_i + \mu_i}{2 - \lambda_k - \mu_k} x_i.$$

Ceci est une combinaison convexe d'éléments de $S \setminus \{x\}$, donc $x \in \text{Conv}(S \setminus \{x\})$. □

Le résultat ci-dessus affirme en particulier que si $C = \text{Conv}(S)$ et $x \in \text{ext}(C)$, alors nécessairement $x \in S$ (i.e., S contient $\text{ext}(C)$). Mais en général, on ne peut pas affirmer que $C = \text{Conv}(\text{ext}(C))$, comme le montrent les exemples suivants : $C = \mathbb{R}_+^n$ dont le seul point extrémal est 0, ou encore la boule ouverte $C = B(0, 1)$ qui n'a pas de points extrémaux. Le premier exemple n'est pas borné, tandis que le deuxième n'est pas fermé. Le résultat suivant, dit de Krein-Milman (ou Minkowski), assure qu'un compact convexe est égal à l'enveloppe convexe de ses points extrémaux.

Théorème 19 (Krein-Milman). Soit $C \subset \mathbb{R}^n$ un compact convexe. Alors $C = \text{Conv}(\text{ext}(C))$.

Preuve. Admise. □

Fonctions convexes

Dans cette section, on considère un ensemble convexe C de $\mathbb{R}^n$.

Définition 33. On dit qu'une fonction $f : C \rightarrow \mathbb{R}$ est convexe si

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y), \quad \forall x, y \in C, \forall \lambda \in [0, 1].$$

On dit que f est strictement convexe si

$$f(\lambda x + (1 - \lambda)y) < \lambda f(x) + (1 - \lambda)f(y), \quad \forall x, y \in C, x \neq y, \forall \lambda \in (0, 1).$$

On dit que f est concave si $-f$ est convexe.




Figure 3.1: Illustration de l'inégalité de convexité dans la Définition 33: la corde liant les deux points $(x, f(x))$ et $(y, f(y))$ est au-dessus du graphe de f .

Exemple 8. Voici quelques exemples de fonctions convexes :

- Les normes : $f(x) = \|x\|$ sur $\mathbb{R}^n$.
- Les fonctions affines : $f(x) = a^T x + b$, avec $a \in \mathbb{R}^n$ et $b \in \mathbb{R}$.
- La fonction $f(x) = -\log(x)$ est convexe sur $\mathbb{R}_+^*$.
- La fonction $f(x) = e^{\lambda x}$ est convexe sur $\mathbb{R}$ pour tout $\lambda \in \mathbb{R}$.
- La fonction $f(x) = |x|^p$ est convexe sur $\mathbb{R}$ pour tout $p \geq 1$.

D'après la Définition 33, une fonction f est convexe si l'image par f d'une combinaison convexe de deux points x et y est plus petite que la combinaison convexe des valeurs $f(x)$ et $f(y)$. Cette propriété s'étend à la combinaison convexe de n'importe quel nombre de vecteurs.

Théorème 20 (Inégalité de Jensen). Soit $f : C \rightarrow \mathbb{R}$ une fonction convexe. Alors pour tout

$x_1, \dots, x_m \in C$ et $\lambda \in \Delta_m$:

$$f\left(\sum_{i=1}^m \lambda_i x_i\right) \leq \sum_{i=1}^m \lambda_i f(x_i).$$

Preuve. Par récurrence. Laissée en exercice. $\square$

Remarque 15. L'inégalité de convexité dans la Définition 33 est parfois appelée inégalité de Jensen. Historiquement, le résultat démontré par Jensen était $f\left(\frac{x+y}{2}\right) \leq \frac{f(x)+f(y)}{2}$. On rencontre d'autres versions de l'inégalité de Jensen en probabilités et en théorie de la mesure et de l'intégration. Typiquement, si f est une fonction convexe définie sur un convexe C de $\mathbb{R}^n$ et X une variable aléatoire à valeurs dans C telle que l'espérance $\mathbb{E}(X)$ existe, alors $f(\mathbb{E}(X)) \leq \mathbb{E}(f(X))$. Un autre exemple est le suivant : si $(X, \mathcal{M}, \mu)$ est un espace probabilisé (où μ est une mesure positive avec $\mu(X) = 1$), I un intervalle non vide de $\mathbb{R}$, $\phi : I \rightarrow \mathbb{R}$ une fonction convexe et $f : X \rightarrow I$ une fonction dans $\mathcal{L}_\mu^1$, alors

$$\phi\left(\int_X f d\mu\right) \leq \int_X \phi \circ f d\mu.$$

Le résultat suivant est une conséquence immédiate du Théorème 20.

Corollaire 3. Soit $f : \mathbb{R}^n \rightarrow \mathbb{R}$ une fonction convexe. Pour toute combinaison convexe $x = \sum_{i=1}^m \lambda_i x_i$, avec $\lambda_i \geq 0$, $\sum_{i=1}^m \lambda_i = 1$ et $x_1, \dots, x_m \in \mathbb{R}^n$, on a

$$f(x) \leq \max_{i=1, \dots, m} f(x_i).$$

Preuve. D'après l'inégalité de Jensen, on a

$$f(x) = f\left(\sum_{i=1}^m \lambda_i x_i\right) \leq \sum_{i=1}^m \lambda_i f(x_i) \leq \max_{i=1, \dots, m} f(x_i) \sum_{i=1}^m \lambda_i = \max_{i=1, \dots, m} f(x_i).$$

$\square$

Le résultat suivant récapitule quelques opérations préservant la convexité de fonctions.

- Théorème 21.**
1. Soit f une fonction convexe sur C et $\alpha \in \mathbb{R}^+$. Alors αf est convexe sur C .
 2. Soient $f_1, \dots, f_m$ des fonctions convexes sur C . Alors $f = \sum_{i=1}^m f_i$ est convexe sur C .
 3. Soient $f_1, \dots, f_m$ des fonctions convexes sur C . Alors $f = \max_{i=1, \dots, m} f_i$ est convexe sur C .
 4. Soit $f : C \rightarrow \mathbb{R}$ une fonction convexe, $A \in \mathbb{R}^{n \times m}$ et $b \in \mathbb{R}^n$. Alors la fonction g définie par $g(y) = f(Ay + b)$ est convexe sur

$$D = \{y \in \mathbb{R}^m : Ay + b \in C\}.$$

Preuve. 1. Immédiat.

2. Soient $x, y \in C$ et $\lambda \in [0, 1]$. Comme les f_i sont convexes, on a pour tout $i = 1, \dots, m$:

$$f_i(\lambda x + (1 - \lambda)y) \leq \lambda f_i(x) + (1 - \lambda)f_i(y).$$

En sommant ces inégalités, on obtient :

$$\sum_{i=1}^m f_i(\lambda x + (1 - \lambda)y) \leq \sum_{i=1}^m \left(\lambda f_i(x) + (1 - \lambda)f_i(y)\right) = \lambda \sum_{i=1}^m f_i(x) + (1 - \lambda) \sum_{i=1}^m f_i(y),$$

soit

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y),$$

donc f est convexe.

3. Soient $x, y \in C$ et $\lambda \in [0, 1]$. On a :

$$f(\lambda x + (1 - \lambda)y) = \max_{i=1, \dots, m} f_i(\lambda x + (1 - \lambda)y) \leq \max_{i=1, \dots, m} (\lambda f_i(x) + (1 - \lambda)f_i(y)).$$

Rappelons que si $(\alpha_i)_{i=1}^m$ et $(\beta_i)_{i=1}^m$ sont deux suites de réels, alors $\max_i (\alpha_i + \beta_i) \leq \max_i \alpha_i + \max_i \beta_i$. Donc :

$$f(\lambda x + (1 - \lambda)y) \leq \lambda \max_{i=1, \dots, m} f_i(x) + (1 - \lambda) \max_{i=1, \dots, m} f_i(y) = \lambda f(x) + (1 - \lambda)f(y).$$

4. Tout d'abord, remarquons que D est convexe (c'est l'image réciproque du convexe C par une application affine). Soient $y_1, y_2 \in D$ et définissons $x_i = Ay_i + b$ pour $i = 1, 2$. Par définition de D , on a $x_1, x_2 \in C$. Soit $\lambda \in [0, 1]$. Par convexité de f , on a :

$$f(\lambda(Ay_1 + b) + (1 - \lambda)(Ay_2 + b)) \leq \lambda f(Ay_1 + b) + (1 - \lambda)f(Ay_2 + b),$$

ce qui s'écrit aussi (par linéarité de l'application $y \mapsto Ay$) :

$$f(A(\lambda y_1 + (1 - \lambda)y_2) + b) \leq \lambda g(y_1) + (1 - \lambda)g(y_2),$$

c'est-à-dire

$$g(\lambda y_1 + (1 - \lambda)y_2) \leq \lambda g(y_1) + (1 - \lambda)g(y_2),$$

d'où la convexité de g .

□




Figure 3.2: Convexité de la fonction sup de trois fonctions f_1, f_2, f_3 .

Exemple 9. Soit $f(x) = \frac{\|Ax+b\|^2}{c^T x + d}$ avec $A \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^n, c \in \mathbb{R}^n \setminus \{0\}$ et $d \in \mathbb{R}$. Alors f est convexe sur $D = \{x : c^T x + d > 0\}$. En effet, on remarque que $f(x) = g(Ax + b, c^T x + d)$ avec $g(x, t) = \frac{\|x\|^2}{t}$ qui est convexe sur $\left\{\begin{pmatrix} x \\ t \end{pmatrix} \in \mathbb{R}^{m+1} : y \in \mathbb{R}^m, t > 0\right\}$ puisque $g(x, t) = \sum_{i=1}^m g_i(x, t)$ avec $g_i(x, t) = \frac{y_i^2}{t}$ qui est convexe sur $\mathbb{R} \times \mathbb{R}_+^*$ (voir TD).

Théorème 22. Soit $f : C \rightarrow \mathbb{R}$ une fonction convexe et $g : I \subset \mathbb{R} \rightarrow \mathbb{R}$ une fonction convexe croissante. Supposons que $f(C) \subset I$. Alors $\phi(x) = g(f(x))$ est convexe sur C .

Preuve. Soient $x, y \in C$ et $\lambda \in [0, 1]$. On a

$$\begin{aligned} \phi(\lambda x + (1 - \lambda)y) &= g(f(\lambda x + (1 - \lambda)y)) \\ &\leq g(\lambda f(x) + (1 - \lambda)f(y)) \text{ par convexité de } f \text{ et monotonie de } g \\ &\leq \lambda g(f(x)) + (1 - \lambda)g(f(y)) \text{ par convexité de } g \\ &= \lambda \phi(x) + (1 - \lambda)\phi(y). \end{aligned} \tag{3.1}$$

□

Exemple 10. La fonction $\phi(x) = e^{\|x\|^2}$ est convexe sur $\mathbb{R}^n$. En effet $\phi(x) = g(f(x))$ avec $f(x) = e^x$ qui est croissante et $f(x) = \|x\|^2$ qui est convexe. Plus généralement, pour toute fonction convexe f , $e^{f(x)}$ est convexe.

Soient $C \subset \mathbb{R}^d$ et $D \subset \mathbb{R}^k$ deux convexes et $f : C \times D \rightarrow \mathbb{R}$ une fonction convexe. Le résultat suivant montre la préservation de la convexité de f avec la minimisation partielle.

Théorème 23. La fonction $g(x) = \inf_{y \in D} f(x, y)$ est convexe sur C .

Preuve. Soient $x_1, x_2 \in C$ et $\varepsilon > 0$. Il existe $y_1, y_2 \in D$ tel que $f(x_i, y_i) \leq g(x_i) + \varepsilon, i = 1, 2$. Soit $\lambda \in [0, 1]$. On a

$$\begin{aligned} g(\lambda x_1 + (1 - \lambda)x_2) &\leq \inf_{y \in D} f(\lambda x_1 + (1 - \lambda)x_2, y) \\ &\leq f(\lambda x_1 + (1 - \lambda)x_2, \lambda y_1 + (1 - \lambda)y_2) \\ &\leq \lambda f(x_1, y_1) + (1 - \lambda)f(x_2, y_2) \\ &\leq \lambda g(x_1) + (1 - \lambda)g(x_2) + \varepsilon. \end{aligned} \tag{3.2}$$

L'inégalité étant vraie pour tout $\varepsilon > 0$, on obtient $g(\lambda x_1 + (1 - \lambda)x_2) \leq \lambda g(x_1) + (1 - \lambda)g(x_2)$. Ce qui termine la preuve. □

On termine cette section par ce lemme qui nous sera utile par la suite.

Lemme 2. Une fonction $f : C \rightarrow \mathbb{R}$ est convexe, avec C convexe, si et seulement si pour tout $x, y \in C$ et $\alpha \geq 0$ tel que $y + \alpha(y - x) \in C$ on a

$$f(y + \alpha(y - x)) \geq f(y) + \alpha(f(y) - f(x)). \tag{3.3}$$

Preuve. Soient $x, y \in C, t \in (0, 1]$ et considérons $z = tx + (1 - t)y$. On a $x = \frac{1}{t}z - \frac{1-t}{t}y = z + \alpha(z - y)$ avec $\alpha = \frac{1-t}{t}$. Par (3.3)

$$f(x) \geq f(y) + \alpha(f(z) - f(y)),$$


i.e., $tf(x) \geq tf(z) + (1 - t)(f(z) - f(y))$, soit $f(z) \leq tf(x) + (1 - t)f(y)$, d'où la convexité de f . Inversement, pour $t = \alpha/(1 + \alpha)$ et $z = y + \alpha(y - x)$, on a $y = (1 - t)z + tx$, comme f est convexe, on a par l'inégalité de Jensen

$$f(y) \leq tf(x) + (1 - t)f(z) = \frac{\alpha}{1 + \alpha}f(x) + \frac{1}{1 + \alpha}f(z),$$

multipliant par $\alpha + 1$ dans l'inégalité précédente, on obtient

$$(1 + \alpha)f(y) \leq \alpha f(x) + f(z),$$

soit $f(z) = f(y + \alpha(y - x)) \geq f(y) + \alpha(f(y) - f(x))$, qui n'est rien d'autre que (3.3) □

Figure 3.3: Illustration du [Théorème 24](#).

3.1 Caractérisations des fonctions convexes différentiables

3.1.1 Caractérisations du premier ordre

Théorème 24. Soit $f : C \rightarrow \mathbb{R}$ une fonction de classe C^1 . Alors f est convexe si et seulement si

$$f(x) \geq f(y) + \langle \nabla f(y), x - y \rangle \text{ pour tout } x, y \in C. \quad (3.4)$$

Preuve. Supposons que f est convexe et soient $x \neq y \in C$ et $\lambda \in (0, 1)$. On a par définition

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y),$$

ce qui donne

$$\frac{f(\lambda x + (1 - \lambda)y) - f(y)}{\lambda} \leq f(x) - f(y).$$

Quand $\lambda \rightarrow 0^+$, on obtient $f'(y; x - y) \leq f(x) - f(y)$. Comme f est C^1 , $f'(y; x - y) = \langle \nabla f(y), x - y \rangle$ et donc $f(y) + \langle \nabla f(y), x - y \rangle \leq f(x)$. Supposons maintenant que $f(x) \geq f(y) + \langle \nabla f(y), x - y \rangle$ pour tout $x, y \in C$ et montrons que f est convexe. Soient $u, v \in C$ et $\lambda \in (0, 1)$. Posons $w = \lambda u + (1 - \lambda)v$ et montrons que $f(w) \leq \lambda f(u) + (1 - \lambda)f(v)$. On a

$$u - w = \frac{w - (1 - \lambda)v}{\lambda} - w = \frac{\lambda - 1}{\lambda}(v - w).$$

En appliquant (3.4) pour u, w et ensuite v, w on obtient

$$f(w) + \langle \nabla f(w), u - w \rangle \leq f(u), \quad (3.5)$$

et

$$f(w) + \langle \nabla f(w), v - w \rangle = f(w) - \frac{\lambda}{1 - \lambda} \langle \nabla f(w), u - w \rangle \leq f(v),$$

soit

$$(1 - \lambda)f(w) - \lambda \langle \nabla f(w), u - w \rangle \leq (1 - \lambda)f(v). \quad (3.6)$$

En multipliant (3.5) par λ et sommant avec (3.6), on obtient le résultat. $\square$

Remarque 16. Dans la littérature, l'inégalité (3.4) est souvent appelée *the gradient inequality*. Elle affirme que les hyperplans tangents à une fonction convexe minorent la fonction.

Le résultat suivant est une caractérisation de la convexité en terme de la monotonie du gradient "au sens des opérateurs".

Théorème 25 (Monotonie du gradient). Soit $f : C \rightarrow \mathbb{R}$ une fonction de classe C^1 . Alors f est convexe si et seulement si

$$\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq 0, \text{ pour tout } x, y \in C. \quad (3.7)$$

Preuve. Supposons que f est convexe et soient $x, y \in C$. Par (3.4) on a

$$f(x) + \langle \nabla f(x), y - x \rangle \leq f(y), \text{ et } f(y) + \langle \nabla f(y), x - y \rangle \leq f(x).$$

En sommant les deux inégalités on obtient que $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq 0$. Inversement, supposons que (3.7) est vérifiée et montrant que f est convexe. Définissons la fonction $\phi : t \in (0, 1) \mapsto f(x + t(y - x))$. On a

$$\begin{aligned} f(y) &= \phi(1) = \phi(0) + \int_0^1 \phi'(t) dt \\ &= f(x) + \int_0^1 \langle \nabla f(x + t(y - x)), y - x \rangle dt \\ &= f(x) + \langle \nabla f(x), y - x \rangle + \int_0^1 \langle \nabla f(x + t(y - x)) - \nabla f(x), y - x \rangle dt \\ &= f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{t} \int_0^1 \underbrace{\langle \nabla f(x + t(y - x)) - \nabla f(x), x + t(y - x) - x \rangle}_{\geq 0} dt, \end{aligned} \quad (3.8)$$

soit $f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle$, et par Théorème 24 f est convexe. $\square$

Quand la fonction est deux fois différentiable, alors la convexité de f est équivalente au fait que la matrice Hessienne est semi-définie positive.

3.1.2 Caractérisations du second ordre

Théorème 26. Soit $f : C \rightarrow \mathbb{R}$ une fonction de classe C^2 avec C un ouvert convexe de $\mathbb{R}^n$ alors f est convexe si et seulement si la Hessienne $\nabla^2 f(x)$ est semi-définie positive, i.e.,

$$\nabla^2 f(x) \succeq 0 \text{ pour tout } x \in C. \quad (3.9)$$

Preuve. Supposons que f est convexe de classe C^2 et soient $x \in C$ et $d \in \mathbb{R}^n$. Comme C est ouvert, il vient que $x_t := x + td \in C$ pour $t < \varepsilon$ avec $\varepsilon > 0$ suffisamment petit. Comme f est convexe, on a, par monotonie de ∇f

$$0 \leq t^{-1} \langle \nabla f(x_t) - \nabla f(x), x_t - x \rangle = \langle \nabla f(x_t) - \nabla f(x), d \rangle = \int_0^t \langle \nabla^2 f(x_\tau), d, d \rangle d\tau$$

En faisant tendre $t \rightarrow 0^+$ on obtient que $\langle \nabla^2 f(x) d, d \rangle \geq 0$. Comme d est arbitraire, il s'en suit que $\nabla^2 f(x) \succeq 0$ pour tout $x \in C$. Maintenant, supposons que (3.9) est vérifiée, on a pour tout $x, y \in C$

$$\begin{aligned} f(y) &= f(x) + \langle \nabla f(x), y - x \rangle + \int_0^1 \left(\int_0^s \underbrace{\langle \nabla^2 f(x_\tau)(y - x), y - x \rangle}_{\geq 0} ds \right) ds \\ &\geq f(x) + \langle \nabla f(x), y - x \rangle, \end{aligned} \quad (3.10)$$

ce qui implique par Théorème 24 la convexité de f . $\square$

Remarque 17. La condition (3.9) est liée à la notion de courbure. En effet, considérons la surface $\Gamma_f = \{(x, y, z) \in \mathbb{R}^3 : z = f(x, y)\}$ avec f de classe C^2 . La courbure de Gauss au point (x, y)

est égale à

$$\kappa = \frac{\det(\nabla^2 f(x, y))}{(1 + \|\nabla f(x, y)\|^2)^2}.$$

Le signe de $\det(\nabla^2 f(x, y))$ (et donc de κ) donne une classification de la surface: elliptique, parabolique ou hyperbolique.

3.2 Continuité et différentiabilité des fonctions convexes

On commence par un premier résultat quand $C = \mathbb{R}^n$.

Théorème 27. Soit $f : \mathbb{R}^n \rightarrow \mathbb{R}$ une fonction convexe. Alors f est continue en tout point en tout $x \in \mathbb{R}^n$.

Preuve. Sans perte de généralité, on suppose que $x = 0$. Soit $(x_k)_k \geq 0$ telle que $x_k \rightarrow x^* = 0$ quand $k \rightarrow \infty$. On a, par convexité de f

$$f(x_k) \leq (1 - \|x_k\|)f(0) + \|x_k\|f(x_k/\|x_k\|).$$

Comme $(x_k/\|x_k\|)_i \in [-1, 1]$ pour tout $i = 1, \dots, n$, il vient que $x_k/\|x_k\| \in [-1, 1]^n$, donc $x_k/\|x_k\| = \sum_{i=1}^{2^n} \lambda_i e_i$ avec $\lambda \in \Delta_{2^n}$. On déduit par le [Corollaire 3](#) que $f(x_k/\|x_k\|) \leq \max_{i=1, \dots, 2^n} f(\pm e_i) := K$. Il s'en suit que

$$\limsup_{k \rightarrow \infty} f(x_k) \leq (1 - \|x^*\|)f(0) + \|x^*\|K = f(0).$$

De même, en remarquant que

$$f(0) \leq \frac{\|x_k\|}{1 + \|x_k\|} f(-x_k/\|x_k\|) + \frac{1}{1 + \|x_k\|} f(x_k),$$

on déduit que $f(0) \leq \liminf_{k \rightarrow \infty} f(x_k)$, et par la suite $\lim_{k \rightarrow \infty} f(x_k) = f(0)$. D'où la continuité de f en 0. $\square$

Sur un convexe $C \subsetneq \mathbb{R}^n$, on peut obtenir un résultat similaire (meilleur même) à [Théorème 27](#) pour les points intérieurs à C . En effet, on peut démontrer qu'une fonction convexe est localement Lipschitzienne en tout $x \in \text{int}(C)$. La raison de se restreindre aux points intérieurs est le comportement d'une fonction convexe au bords qui peut créer des discontinuités. Pour illustrer ceci, considérons la fonction $f : [0, 1] \rightarrow \mathbb{R}$ définie par $f(0) = 1$ et $f(x) = x^2$ pour $x \in (0, 1]$. Cette fonction est évidemment convexe (faites un dessin) mais n'est pas continue.

On a le résultat suivant.

Théorème 28. Soit $f : C \rightarrow \mathbb{R}$ une fonction convexe définie sur un convexe C de $\mathbb{R}^n$ et soit $x_0 \in \text{int}(C)$. Alors il existe $L > 0$ et $\varepsilon > 0$ tels que $B(x_0, \varepsilon) \subset C$ et

$$|f(x) - f(x_0)| \leq L\|x - x_0\|, \quad \forall x \in B(x_0, \varepsilon). \quad (3.11)$$

Preuve. Soit $x_0 \in \text{int}(C)$, il existe alors $\varepsilon > 0$ tel que $B_\infty(x_0, \varepsilon) \subset C$. On commence par montrer que f est bornée supérieurement sur $B_\infty(x_0, \varepsilon)$. Comme $B_\infty(x_0, \varepsilon)$ est convexe et compact, avec

$$\text{ext}(B_\infty(x_0, \varepsilon)) = \{z_i = x_0 + \varepsilon \theta_i, \text{ avec } \theta_i \in \{\pm 1\}, i = 1, 2, \dots, 2^n\},$$

on déduit par le théorème de Krein-Milman que tout $x \in B_\infty(x_0, \varepsilon)$ s'écrit de la forme $\sum_{i=1}^{2^n} \lambda_i z_i$ avec $\lambda \in \Delta_{2^n}$. Donc par [Corollaire 3](#) $f(x) \leq K := \max_{i=1, 2, \dots, 2^n} f(z_i)$. Comme $B(x_0, \varepsilon) \subset B_\infty(x_0, \varepsilon)$ on en déduit que $f(x) \leq K$ pour tout $x \in B(x_0, \varepsilon)$.

Soit $x \in B(x_0, \varepsilon)$ avec $x \neq x_0$. On définit $z = x_0 + \alpha^{-1}(x - x_0)$ avec $\alpha = \|x - x_0\|/\varepsilon$. On voit que $0 < \alpha \leq 1$ et $\|z - x_0\| = \varepsilon$, i.e., $z \in B(x_0, \varepsilon)$ et donc $f(z) \leq K$. Comme $x = \alpha z + (1 - \alpha)x_0$,

on a par convexité de f

$$f(x) \leq \alpha f(z) + (1 - \alpha)f(x_0) = f(x_0) + \alpha(f(z) - f(x_0)) \leq f(x_0) + \alpha(K - f(x_0)), \quad (3.12)$$

i.e., $f(x) - f(x_0) \leq L\|x - x_0\|$, avec $L = (K - f(x_0))\varepsilon^{-1}$. Pour finir la preuve, montrons que $f(x) - f(x_0) \geq -L\|x - x_0\|$. Définissons $w = x_0 + (x_0 - x)\alpha^{-1}$ et remarquons que $\|w - x_0\| = \varepsilon$ et donc $f(w) \leq K$. Comme $x = x_0 + \alpha(x_0 - w)$, on a par [Lemme 2](#)

$$\begin{aligned} f(x) &= f(x_0 + \alpha(x_0 - w)) \geq f(x_0) + \alpha(f(x_0) - f(w)) \\ &\geq f(x_0) - \alpha(K - f(x_0)), \end{aligned} \quad (3.13)$$

i.e., $f(x) - f(x_0) \geq -L\|x - x_0\|$. En conclusion, on obtient que (3.11) pour tout $x \in B(x, \varepsilon)$ avec $L = (K - f(x_0))\varepsilon^{-1}$. $\square$

Nous avons vu qu'en les points intérieurs à C , une fonction convexe $f : C \rightarrow \mathbb{R}$ est localement Lipschitzienne, i.e., vérifie (3.11). Maintenant, on montrera que les dérivées directionnelles de f en tout point intérieur existent. Rappelons qu'étant donnés $x \in \text{int}(C)$ et $0 \neq d \in \mathbb{R}^n$, on dira que f est différentiable en x dans la direction d si la limite

$$\lim_{t \rightarrow 0^+} t^{-1}(f(x + td) - f(x)) := f'(x; d),$$

existe.

Théorème 29. Soit $f : C \rightarrow \mathbb{R}$ une fonction convexe définie sur un convexe $C \subset \mathbb{R}^n$ et soit $x \in \text{int}(C)$. Alors $f'(x; d)$ existe pour tout $0 \neq d \in \mathbb{R}^n$.

Preuve. Soit $x \in \text{int}(C)$, $d \in \mathbb{R}^n$, $0 < \alpha \leq 1$ et $\varepsilon > 0$ tel que $x + td \in C$ pour tout $0 < t \leq \varepsilon$. On note $h(t) := t^{-1}(f(x + td) - f(x))$. Comme $\alpha t \leq t$ et $x + td = (1 - \alpha)x + \alpha(x + td)$, on a par l'inégalité de Jensen

$$f(x + \alpha td) \leq (1 - \alpha)f(x) + \alpha f(x + td),$$

soit

$$h(t) = t^{-1}(f(x + td) - f(x)) \geq (\alpha)t^{-1}(f(x + \alpha td) - f(x)) = h(\alpha t).$$

Ce qui prouve que h est décroissante. De même, on montre que pour tout $t_0 > 0$ tel que $x - t_0 d \in C$, on a que $h(t) \geq t_0^{-1}(f(x) - f(x - t_0 d))$, i.e., h est bornée inférieurement. Par conséquent $\lim_{t \rightarrow 0^+} h(t)$ existe, i.e., la dérivée directionnelle $f'(x; d)$ existe. $\square$

3.3 Sous-ensembles de niveau de fonctions convexes:

Définition 34. Soit $f : S \subset \mathbb{R}^n \rightarrow \mathbb{R}$ une fonction. Le sous-ensemble de f de niveau $\alpha \in \mathbb{R}$ est l'ensemble

$$\mathbf{Lev}(f, \alpha) = \{x \in S : f(x) \leq \alpha\}.$$

On a le résultat suivant

Théorème 30. Soit $f : C \rightarrow \mathbb{R}$ une fonction convexe et avec C un ensemble convexe. Alors pour tout $\alpha \in \mathbb{R}$, l'ensemble $\mathbf{Lev}(f, \alpha)$ est convexe.

Preuve. Soient $x, y \in \mathbf{Lev}(f, \alpha)$ et $\lambda \in [0, 1]$ avec $\alpha \in \mathbb{R}$. Comme $f(x), f(y) \leq \alpha$, il vient par convexité de f que

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y) \leq \lambda \alpha + (1 - \lambda)\alpha = \alpha.$$

$\square$




Figure 3.4: $f(x) = \sqrt{|x|}$ comme exemple de fonction quasi-convexe.




Figure 3.5: Sous-ensembles de niveau de la fonction $f(x, y) = 1/2(x^2 + 4y^2)$.

Remarque 18. La réciproque dans le [Théorème 30](#) est fausse comme le montre la fonction $f(x) = \sqrt{|x|}$ (voir [Fig. 3.4](#)) qui n'est pas convexe mais dont tout les sous-ensembles de niveau sont convexe. En effet, d'une part, pour $\alpha < 0$, $\text{Lev}(f, \alpha) = \emptyset$. D'autre part, pour $\alpha \geq 0$, on $\text{Lev}(f, \alpha) = [-\alpha^2, \alpha^2]$ qui est convexe. Une telle fonction est dite **quasi-convexe**.

Définition 35. Soit $C \subset \mathbb{R}$ un convexe. On dit qu'une fonction $f : C \rightarrow \mathbb{R}$ est quasi-convexe si pour tout $\alpha \in \mathbb{R}$, l'ensemble $\text{Lev}(f, \alpha)$ est convexe. De même, f est dite quasi-concave si $-f$ est quasi-convexe.

Exemple 11. 1. Évidemment, une fonction convexe est quasi-convexe.

2. L'application $x \in \mathbb{R}^n \mapsto \text{card}(x) = \{\text{nombre des composantes non nuls de } x\}$ est quasi-concave:


$$\text{card}(x + y) \geq \min\{\text{card}(x), \text{card}(y)\}.$$

3. L'application $M \in \mathbb{R}^{n \times n} \mapsto \text{rang}(M)$ est quasi-concave sur $\mathcal{S}_+^n$:

$$\text{rang}(M + N) \geq \min\{\text{rang}(M), \text{rang}(N)\}.$$

4. Un exemple important est celui des fonctions continue sur $\mathbb{R}$. En effet, si $f : \mathbb{R} \rightarrow \mathbb{R}$ est continue alors f est quasi-convexe ssi l'une des propriétés suivantes est vérifiée

- (a) f est croissante;
- (b) f est décroissante;
- (c) il existe $x^* \in \mathbb{R}$ tel que pour tout $x \leq x^*$ f est décroissante, et pour tout $x \geq x^*$ est croissante (cf. [Fig. 3.6](#)).

Figure 3.6: Exemple de fonction quasi-convexe sur $\mathbb{R}$.

3.4 Fonctions à valeurs réelles étendues

Dans la pratique on peut être amené à travailler et considérer des fonctions qui peuvent prendre des valeurs infinies. En effet, considérons une fonction $f : \mathbb{R}^n \rightarrow \bar{\mathbb{R}} = [-\infty, \infty]$. La définition de convexité (33) reste valable pour de telles fonctions tenant compte des opérations arithmétiques classiques

$$\begin{aligned}
 a + \infty &= \infty + a = \infty & (-\infty < a < \infty), \\
 a - \infty &= -\infty + a = -\infty & (-\infty < a < \infty), \\
 a \cdot \infty &= \infty \cdot a = \infty & (0 < a < \infty), \\
 a \cdot (-\infty) &= (-\infty) \cdot a = -\infty & (0 < a < \infty), \\
 a \cdot \infty &= \infty \cdot a = -\infty & (-\infty < a < 0), \\
 a \cdot (-\infty) &= (-\infty) \cdot a = \infty & (-\infty < a < 0),
 \end{aligned} \tag{3.14}$$

ainsi qu'avec la règle "moins usuelle" $0 \cdot \infty = 0 \cdot (-\infty) = 0$. Néanmoins, on s'intéresse plutôt à des fonctions qui ne prennent pas la valeur $-\infty$ et dont le domaine est non vide.

Définition 36 (Domaine effectif). Soit $f : \mathbb{R}^n \rightarrow [-\infty, \infty]$, le domaine (ou domaine effectif) de f est défini par

$$\text{dom}(f) = \{x \in \mathbb{R}^n : f(x) < \infty\}.$$

Exemple 12. Si $C \subset \mathbb{R}^n$, l'indicatrice de C au sens d'analyse convexe est définie par

$$\delta_C(x) = \begin{cases} 0, & \text{si } x \in C, \\ \infty & \text{sinon,} \end{cases}$$

alors $\text{dom}(\delta_C) = C$.

Définition 37. On dit que $f : \mathbb{R}^n \rightarrow [-\infty, \infty]$ est propre si $-\infty \notin f(\mathbb{R}^n)$ et $\text{dom}(f) \neq \emptyset$, i.e., il existe $x_0 \in \mathbb{R}^n$ tel que $f(x_0) < \infty$.

Une autre caractérisation géométrique des fonctions convexes est donnée par l'ensemble suivant.

Définition 38 (Epigraphe). Soit $f : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{\infty\}$, on définit l'épigraphe de f par

$$\text{epi}(f) = \left\{ \begin{pmatrix} x \\ t \end{pmatrix} \in \mathbb{R}^{n+1} : f(x) \leq t \right\}.$$

Clairement, si $\begin{pmatrix} x \\ t \end{pmatrix} \in \text{epi}(f)$, alors $x \in \text{dom}(f)$. Contrairement aux sous-ensembles de niveaux, la convexité de l'épigraphe est équivalente à celle de f .

Théorème 31 (et définition). f est convexe $\Leftrightarrow \text{epi}(f)$ est convexe.

Exemple 13. 1. Si $f(x) = a^T x - \alpha$ avec $a \in \mathbb{R}^n, \alpha \in \mathbb{R}$. On a

$$\text{epi}(f) = \left\{ \begin{pmatrix} x \\ t \end{pmatrix} \in \mathbb{R}^{n+1} : \left\langle \begin{pmatrix} a \\ -1 \end{pmatrix}, \begin{pmatrix} x \\ t \end{pmatrix} \right\rangle \leq \alpha \right\},$$

est un demi-espace donc convexe.

2. Si $f(x) = 1/2\|x\|^2$, alors $\text{epi}(f)$ est la région au dessus de la parabole (cf. Fig. 3.7).

3. Pour l'indicatrice d'un ensemble

$$\text{epi}(\delta_C) = \left\{ \begin{pmatrix} x \\ t \end{pmatrix} \in \mathbb{R}^{n+1} : \delta_C(x) \leq t \right\} = C \times \mathbb{R}^+,$$

qui est donc convexe si et seulement si C est convexe.




Figure 3.7: L'épigraphe de $\frac{1}{2}\|x\|^2$.

Le résultat suivant montre la préservation de la convexité du supremum de fonctions convexe et est à comparer avec [Théorème 21](#).

Théorème 32. Soient $f_i : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{\infty\}$ des fonctions convexes avec $i \in I$ (la famille d'indices I est quelconque). Alors la fonction $f(x) = \sup_{i \in I} f_i(x)$ est convexe.

Preuve. Comme les f_i sont convexes, les épigraphes $\text{epi}(f_i)$ sont aussi convexes pour tout $i \in I$. On conclue en remarquant que $\text{epi}(f) = \bigcap_{i \in I} \text{epi}(f_i)$. $\square$

Définition 39 (Fonction fermée). Une fonction $f : \mathbb{R}^n \rightarrow \overline{\mathbb{R}}$ est dite fermée si $\text{epi}(f)$ est fermé.

Exemple 14. Revenons à l'exemple de la fonction indicatrice δ_C d'un sous-ensemble C de $\mathbb{R}^n$. Comme $\text{epi}(\delta_C) = C \times \mathbb{R}^+$, on a

$$\delta_C \text{ et fermée} \Leftrightarrow C \times \mathbb{R}^+ \text{ et fermé} \Leftrightarrow C \text{ et fermé.}$$

Définition 40 (Semi-continuité inférieure). Une fonction $f : \mathbb{R}^n \rightarrow \overline{\mathbb{R}}$ est dite semi-continue inférieurement (sci) en $x \in \mathbb{R}^n$ si $f(x) \leq \liminf f(x_n)$, pour toute suite $(x_n)_n$ telle que $x_n \rightarrow x$ quand $n \rightarrow \infty$.

Notation. On note par $\Gamma_0(\mathbb{R}^n)$ la classe de fonctions convexes, propres et semi-continuité inférieurement à valeurs dans $\mathbb{R} \cup \{\infty\}$.

Le résultat suivant établit un lien entre la semi-continuité inférieure et la fermeture de son épigraphe et sous-ensembles de niveaux.

Théorème 33. Soit $f : \mathbb{R}^n \rightarrow \overline{\mathbb{R}}$. On a

$$f \text{ est sci} \Leftrightarrow f \text{ est fermée} \Leftrightarrow \mathbf{Lev}(f, \alpha) \text{ est fermé } \forall \alpha \in \mathbb{R}.$$

Preuve. Supposons que f est sci et montrons que $\text{epi}(f)$ est fermé. Soit $\{(x_n, t_n)\}_n \subset \text{epi}(f)$ telle que $(x_n, t_n) \rightarrow (x^*, t^*)$ quand $n \rightarrow \infty$. Comme $f(x_n) \leq t_n$ pour tout $n \geq 1$, il vient par sci de f

$$f(x^*) \leq \liminf_{n \rightarrow \infty} f(x_n) \leq \liminf_{n \rightarrow \infty} t_n = t^*.$$

Donc $(x^*, t^*) \in \text{epi}(f)$ et f est fermée.

Supposons que f est fermée et montrons que $\mathbf{Lev}(f, \alpha)$ est fermé pour tout $\alpha \in \mathbb{R}$. Soit $\alpha \in \mathbb{R}$, si $\mathbf{Lev}(f, \alpha) = \emptyset$ rien à démontrer. Sinon, soit $(x_n)_n \subset \mathbf{Lev}(f, \alpha)$ telle que $x_n \rightarrow x^*$ quand $n \rightarrow \infty$. Alors $(x_n, \alpha) \in \text{epi}(f)$ et $(x_n, \alpha) \rightarrow (x^*, \alpha)$ quand $n \rightarrow \infty$. Comme $\text{epi}(f)$ est fermé, on a que $(x^*, \alpha) \in \text{epi}(f)$, soit $x^* \in \mathbf{Lev}(f, \alpha)$.

Supposons que $\mathbf{Lev}(f, \alpha)$ est fermé pour tout $\alpha \in \mathbb{R}$ et montrons que f est sci. Supposons que f n'est pas sci, i.e., il existe $x^* \in \mathbb{R}^n$ et une suite $(x_n)_n \in \mathbb{R}^n$ telle que $x_n \rightarrow x^*$ quand $n \rightarrow \infty$ et $\liminf_{n \rightarrow \infty} f(x_n) < f(x^*)$. Considérons α tel que

$$\liminf_{n \rightarrow \infty} f(x_n) < \alpha < f(x^*). \quad (3.15)$$

Il existe donc une sous-suite $(x_{n_k})_k$ telle que $f(x_{n_k}) \leq \alpha, \forall k \geq 1$. Comme $\mathbf{Lev}(f, \alpha)$ est fermé, il vient que $x_{n_k} \rightarrow x^*$ quand $k \rightarrow \infty$, i.e., $f(x^*) \leq \alpha$ ce qui contredit (3.15). $\square$

3.5 Inégalités et convexité

On présente ici, comme applications, quelques inégalités qui peuvent se démontrer grâce à la convexité.

Proposition 9 (Inégalité arithmético-géométrique). Pour tous réels $x_1, \dots, x_n \geq 0$, on a

$$\frac{1}{n} \sum_{i=1}^n x_i \geq \sqrt[n]{\prod_{i=1}^n x_i}.$$

Plus généralement, pour tout $\lambda \in \Delta_n$,

$$\sum_{i=1}^n \lambda_i x_i \geq \prod_{i=1}^n x_i^{\lambda_i}.$$

Proposition 10 (Inégalité de Young). Soient $a, b \geq 0$ et $p, q > 1$ avec $\frac{1}{p} + \frac{1}{q} = 1$. On a

$$ab \leq \frac{a^p}{p} + \frac{b^q}{q}.$$

Le résultat suivant est une généralisation de l'inégalité de Cauchy-Schwarz.

Proposition 11 (Inégalité de Hölder). Pour tous $x, y \in \mathbb{R}^n$ et $p, q > 1$ avec $\frac{1}{p} + \frac{1}{q} = 1$, on a

$$|\langle x, y \rangle| \leq \|x\|_p \|y\|_q.$$

Proposition 12 (Inégalité de Minkowski). Soit $p \geq 1$. Alors pour tous $x, y \in \mathbb{R}^n$, on a

$$\|x + y\|_p \leq \|x\|_p + \|y\|_p.$$

Introduction à l'optimisation convexe

4.1 Conditions d'optimalité pour la minimisation sans contraintes

Dans cette section, nous introduisons quelques définitions pour étudier des problèmes d'optimisation de la forme

$$\min_{x \in \mathbb{R}^n} f(x).$$

Commençons par introduire les notions de minimum/global d'une fonction f définie sur une partie S de $\mathbb{R}^n$.

4.1.1 Minimum/Maximum global

Définition 41 (Minimum/Maximum global). Soit $f : S \subset \mathbb{R}^n \rightarrow \mathbb{R}$ et $x^* \in S$. Alors

1. x^* est dit un minimum global de f sur S si $f(x) \geq f(x^*)$ pour tout $x \in S$.
2. x^* est dit un minimum global strict de f sur S si $f(x) > f(x^*)$ pour tout $x^* \neq x \in S$.
3. x^* est dit un maximum global de f sur S si $f(x) \leq f(x^*)$ pour tout $x \in S$.
4. x^* est dit un maximum global strict de f sur S si $f(x) < f(x^*)$ pour tout $x^* \neq x \in S$.

Définition 42. On note par $\operatorname{argmin}_S f$ l'ensemble des minimas globaux de f sur S . De même, on note par $\operatorname{argmax}_S f$ l'ensemble des maximas globaux de f sur S .

Exemple 15. On considère $f : (x, y) \in \mathbb{R}^2 \mapsto x + y$ et $S = B_f(0, 1) = \{(x, y) : x^2 + y^2 \leq 1\}$. On vérifie que $\max_S f = \sqrt{2}$ et que $\operatorname{argmax}_S f = \{(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}})\}$. En effet, pour $(x, y) \in S$, l'inégalité de Cauchy-Schwarz donne

$$f(x, y) = \langle (x, y), (1, 1) \rangle \leq \|(x, y)\|_2 \|(1, 1)\|_2 \leq \sqrt{2}.$$

De même, on a $\min_S f = -\sqrt{2}$ et que $\operatorname{argmax}_S f = \{(\frac{-1}{\sqrt{2}}, \frac{-1}{\sqrt{2}})\}$. On verra plus loin comment résoudre ce type de problèmes grâce aux conditions KKT.

Définition 43. 1. x^* est dit un minimum locale de f sur S s'il existe $\varepsilon > 0$ tel que $f(x) \geq f(x^*)$ pour tout $x \in S \cap B(x^*, \varepsilon)$.

2. x^* est dit un minimum locale strict de f sur S s'il existe $\varepsilon > 0$ tel que $f(x) > f(x^*)$ pour tout $x^* \neq x \in S \cap B(x^*, \varepsilon)$.

3. x^* est dit un maximum global de f sur S s'il existe $\varepsilon > 0$ tel que $f(x) \leq f(x^*)$ pour tout $x \in S \cap B(x^*, \varepsilon)$.

4. x^* est dit un maximum global strict de f sur S s'il existe $\varepsilon > 0$ tel que $f(x) < f(x^*)$ pour tout $x^* \neq x \in S \cap B(x^*, \varepsilon)$.

4.1.2 Condition d'optimalité du premier ordre

On rappelle le résultat suivant, souvent connu sous la **règle de Fermat** (c.f Fig. 4.1).




Figure 4.1: Illustration de la règle de Fermat: la fonction f a un minimum (respectivement maximum) local en x_* (respectivement x^*). La dérivée de f s'annule en ces deux points. Géométriquement, la tangente de f en ces deux points est horizontale.

Proposition 13 (Règle de Fermat). Soit $f : (a, b) \subset \mathbb{R} \rightarrow \mathbb{R}$ une fonction différentiable. Si $x^* \in (a, b)$ est un minimum/maximum local de f alors $f'(x^*) = 0$.

Preuve. Supposons que x^* est un minimum local de f (le cas du maximum se démontre de façon analogue). Il existe $\delta > 0$ tel que pour tout h avec $0 < |h| < \delta$ et $x^* + h \in (a, b)$ on a $f(x^* + h) - f(x^*) \geq 0$.

Comme f est différentiable en x^* , on peut écrire pour $h \neq 0$ petit :

$$f(x^* + h) - f(x^*) = (f'(x^*) + \varepsilon(h))h,$$

avec $\varepsilon(h) \rightarrow 0$ quand $h \rightarrow 0$. Pour $h > 0$ suffisamment petit, l'inégalité $f(x^* + h) - f(x^*) \geq 0$ donne

$$f'(x^*) + \varepsilon(h) \geq 0,$$

et pour $h < 0$ suffisamment petit (donc $-h > 0$ petit) l'inégalité $f(x^* + h) - f(x^*) \geq 0$ devient

$$f'(x^*) + \varepsilon(h) \leq 0.$$

En faisant tendre $h \rightarrow 0^+$ puis $h \rightarrow 0^-$, on obtient $f'(x^*) \geq 0$ et $f'(x^*) \leq 0$, d'où $f'(x^*) = 0$. $\square$

Le résultat suivant est une généralisation de la règle de Fermat.

Théorème 34. Soit $f : S \rightarrow \mathbb{R}$ une fonction définie sur un ensemble $S \subset \mathbb{R}^n$. Supposons que $x^* \in \text{int}(S)$ est un extremum local et que toutes les dérivées partielles de f en x^* existent. Alors $\nabla f(x^*) = 0$.

Preuve. On définit, pour $i \in \llbracket 1, n \rrbracket$, la fonction de la variable réelle $\phi(t) = f(x^* + te_i)$ (e_i étant le i ème vecteur de la base canonique de $\mathbb{R}^n$). On remarquera que ϕ est différentiable en 0 et $\phi'(0) = \partial_{x_i} f(x^*)$. Comme x^* est un extremum local de f , il vient que $t = 0$ est un extremum local de ϕ , et par la suite $\phi'(0) = 0$. Il s'en suit que $\partial_{x_i} f(x^*) = 0$, pour tout $i \in \llbracket 1, n \rrbracket$, i.e., $\nabla f(x^*) = 0$. $\square$

Le [Théorème 34](#) donne une condition nécessaire d'optimalité, à savoir que le gradient d'une fonction en les extrema locaux intérieurs au domaine de la fonction est nul. La réciproque est fausse. Il existe des points (lesquelles ?) qui ne sont pas des extrema locaux et pourtant le gradient de la fonction en ses points est nul. Cela motive la définition suivante.

Définition 44 (Point critique). Soit $f : S \rightarrow \mathbb{R}$ une fonction définie sur un ensemble $S \subset \mathbb{R}^n$. Supposons que $x^* \in \text{int}(S)$ et que f est différentiable au voisinage de x^* . Alors x^* est un point stationnaire (ou critique) de f si $\nabla f(x^*) = 0$.

Remarque 19. Le [Théorème 34](#) affirme que les extrema locaux sont des points critiques.

Exemple 16. Considérons $f(x) = x^3$. On a que $f'(x) = 3x^2$ et donc $f'(0) = 0$ pourtant 0 n'est ni un minimum ni un maximum de f .

4.1.3 Conditions d'optimalité du second ordre

Théorème 35 (Conditions nécessaires). Soit $f : S \rightarrow \mathbb{R}$ une fonction définie sur un ouvert $S \subset \mathbb{R}^n$. Supposons que f est deux fois continûment différentiable sur S et soit x^* un point stationnaire de f . Alors

1. Si x^* est un minimum local de f sur S alors $\nabla^2 f(x^*) \succeq 0$.
2. Si x^* est un maximum local de f sur S alors $\nabla^2 f(x^*) \preceq 0$.

Preuve. Comme x^* est un minimum local, on a $\nabla f(x^*) = 0$, et pour $\varepsilon > 0$ suffisamment petit

$$f(x) = f(x^*) + \frac{1}{2} \langle \nabla^2 f(x^*)(x - x^*), x - x^* \rangle + o(\|x - x^*\|^2) \geq f(x^*), \text{ pour tout } x \in B(x^*, \varepsilon).$$

Posons $v = \frac{x - x^*}{\|x - x^*\|}$, on obtient en divisant par $\|x - x^*\|^2$ dans l'inégalité précédente

$$\langle \nabla^2 f(x^*)v, v \rangle + o(1) \geq 0.$$

En prenant la limite quand x tend vers x^* on obtient que $\langle \nabla^2 f(x^*)v, v \rangle \geq 0$ pour tout v tel que $\|v\| = 1$. Ainsi, $\nabla^2 f(x^*)$ est semi-définie positive. On conclut en appliquant le même raisonnement à $-f$. $\square$

Le résultat suivant donne une condition suffisante d'optimalité locale stricte.

Théorème 36 (Condition suffisante). Soit $f : S \rightarrow \mathbb{R}$ une fonction définie sur un ouvert $S \subset \mathbb{R}^n$. Supposons que f est deux fois différentiable sur S et soit $x^* \in \text{int}(S)$ un point stationnaire de f . Alors

1. Si $\nabla^2 f(x^*) \succ 0$, alors x^* est un minimum local strict de f sur S .
2. Si $\nabla^2 f(x^*) \prec 0$, alors x^* est un maximum local strict de f sur S .

Preuve. D'une part, comme $\nabla^2 f(x^*) \succ 0$, sa plus petite valeur propre $\lambda_{\min} > 0$ et on a $\nabla^2 f(x^*) \succeq \lambda_{\min} \text{Id}$. D'autre part, comme f est deux fois différentiable et $\nabla f(x^*) = 0$, on a par ??

$$\begin{aligned} f(x) &= f(x^*) + \frac{1}{2} \langle \nabla^2 f(x^*)(x - x^*), x - x^* \rangle + o(\|x - x^*\|^2) \\ &\geq f(x^*) + \frac{1}{2} \lambda_{\min} \|x - x^*\|^2 + o(\|x - x^*\|^2) \end{aligned} \quad (4.1)$$

Comme $o(r)/r \rightarrow 0$, il existe $r^* > 0$ tel que pour tout $r \in (0, r^*]$ on ait $o(r) \leq \frac{1}{4} r \lambda_{\min}$. Il s'en

suit que pour tout $x \in B(x^*, r)$ on a $|o(\|x - x^*\|^2)| \leq \frac{1}{4}\lambda_{\min}\|x - x^*\|^2$ et par la suite

$$\begin{aligned} f(x) &= f(x^*) + \frac{1}{2}\langle \nabla^2 f(x^*)(x - x^*), x - x^* \rangle + o(\|x - x^*\|^2) \\ &\geq f(x^*) + \frac{1}{2}\lambda_{\min}\|x - x^*\|^2 + o(\|x - x^*\|^2) \\ &\geq f(x^*) + \frac{1}{4}\lambda_{\min}\|x - x^*\|^2 > f(x^*). \end{aligned} \quad (4.2)$$

□

Une preuve alternative est la suivante.

Preuve. Soit x^* un point stationnaire tel que $\nabla^2 f(x^*) \succ 0$, comme f est de classe C^2 , sa Hessienne est continue, et il existe donc un boule $B(x^*, r) \subset S$ telle que $\nabla^2 f(x) \succ 0$ pour tout $x \in B(x^*, r)$. Par ??, il existe $z_x \in [x, x^*]$ tel que

$$f(x) = f(x^*) + \frac{1}{2} \underbrace{\langle \nabla^2 f(z_x)(x - x^*), x - x^* \rangle}_{>0},$$

donc $f(x) > f(x^*)$ pour tout $x \in B(x^*, r), x \neq x^*$. Donc x^* est un minimum local stricte de f sur S . □

Les conditions d'optimalité que nous venons de présenter garantissent seulement l'optimalité **locale** des points stationnaires, puisqu'elles reposent sur une information locale — à savoir les valeurs du gradient et de la hessienne en un point donné. Le résultat suivant montre que, lorsque la hessienne est semi-définie positive partout (ça vous rappelle quelque chose ? :)), tout point stationnaire est en réalité un **minimum global**.

Théorème 37 (Condition d'optimalité globale). Soit $f \in C^2(\mathbb{R}^n)$ telle que $\nabla^2 f(x) \succeq 0$ pour tout $x \in \mathbb{R}^n$. Si x^* est un point stationnaire de f , alors x^* est un minimum global de f .

Preuve. Soit $x \in \mathbb{R}^n$. D'après ?? il existe $y_x \in [x^*, x]$ tel que

$$f(x) - f(x^*) = \frac{1}{2} \langle \nabla^2 f(y_x)(x - x^*), x - x^* \rangle.$$

Puisque $\nabla^2 f(y_x) \succeq 0$, il vient $f(x) - f(x^*) \geq 0$, ce qui montre que $f(x) \geq f(x^*)$ pour tout $x \in \mathbb{R}^n$. Ainsi, x^* est un **minimum global** de f . □

Avant de finir cette section, on introduit un autre type de points critiques évoqués par exemple dans l'Exemple 16 et Fig. 4.2.

Définition 45 (Point selle). Soit $f : S \rightarrow \mathbb{R}$ une fonction définie sur un ouvert $S \subseteq \mathbb{R}^n$, supposée continûment différentiable sur S . Un point stationnaire $x^* \in S$ est appelé *point selle* de f sur S s'il n'est ni un minimum local ni un maximum local de f sur S .

Théorème 38 (Condition suffisante pour un point selle). Soit $f : S \rightarrow \mathbb{R}$ une fonction définie sur un ouvert $S \subseteq \mathbb{R}^n$, supposée deux fois continûment différentiable sur S . Soit $x^* \in S$ un point stationnaire de f . Si la matrice Hessienne $\nabla^2 f(x^*)$ est indéfinie, alors x^* est un point selle de f sur S .

Preuve. □

4.1.4 Résultats d'existence

Jusqu'ici, nous avons défini les notions de minimum et de maximum comme s'ils existaient toujours. Il est pourtant fondamental de savoir si un problème du type

$$\min_{x \in C} f(x),$$




Figure 4.2: Points critiques de la fonction $f(x, y) = (x^2 + y^2 - 1)^2 + (y^2 - 1)^2$. Le point $(0, 0)$ est un maximum local, les points $(0, 1)$ et $(0, -1)$ sont des minimas locaux stricts et aussi des minimas globaux tandis que $(1, 0)$ et $(-1, 0)$ sont des points-selles.

avec $C = \mathbb{R}^n$ ou une partie de $\mathbb{R}^n$, admet effectivement une solution. Commençons par rappeler le résultat classique suivant.

Théorème 39 (Weierstrass). Soit $f : S \subset \mathbb{R}^n \rightarrow \mathbb{R}$ une fonction continue avec S un compact. Alors f est bornée et atteint ses bornes, i.e., $\exists x_* x^* \in S$ tels que

$$f(x^*) = \sup_{x \in S} f(x) \text{ et } f(x_*) = \inf_{x \in S} f(x).$$

Quand l'ensemble S n'est pas compact, on requiert la coercivité de f .

Définition 46 (Coercivité). Soit $f : \mathbb{R}^n \rightarrow \mathbb{R}$ une fonction continue. On dit que f est coercive si

$$\lim_{\|x\| \rightarrow \infty} f(x) = \infty.$$

Théorème 40. Soit $f : \mathbb{R}^n \rightarrow \mathbb{R}$ une fonction continue et coercive et $S \subset \mathbb{R}^n$ un fermé non vide. Alors f admet un minimum global sur S .

Preuve. Soit $x_0 \in S$. Par coercivité, il existe $K > 0$ tel qu'on ait $f(x) > f(x_0)$ pour tout $\|x\| > K$. Si x^* est un minimum global de f sur S , alors $f(x^*) \leq f(x_0)$ pour tout $x \in S$ et en particulier pour tout $x \in S \cap B(0, K)$. Comme S est un fermé non vide, $S \cap B(0, K)$ est un compact non vide et **Théorème 39** assure l'existence d'un minimum global de f sur $S \cap B(0, K)$, et donc sur S . $\square$

En combinant la coercivité (**Définition 46**) et la semi-continuité inférieure (**Définition 40**) on peut étendre le résultat de Weierstrass:

Théorème 41 (Existence d'un minimum). Soit $f : \mathbb{R}^n \rightarrow]-\infty, +\infty]$ une fonction **propre, semi-continue inférieurement** et **coercive**. Alors f admet un minimiseur, c'est-à-dire qu'il existe $x^* \in \mathbb{R}^n$ tel que

$$f(x^*) = \min_{x \in \mathbb{R}^n} f(x).$$

4.2 Optimisation convexe

4.2.1 Définitions et premières propriétés

Avant de finir ce chapitre, on va dégager quelques propriétés des problèmes d'optimisation convexe dans le sens suivant.

Définition 47 (Problème convexe). Le problème d'optimisation

$$\min_{x \in C} f(x) \quad (4.3)$$

est dit convexe si $C \subset \mathbb{R}^n$ un convexe et f une fonction convexe sur C .

Généralement, on rencontre des problèmes où l'ensemble des contraintes C combine à la fois des **contraintes d'égalité** et des **contraintes d'inégalité**. En effet, dans de nombreux problèmes pratiques, on cherche à déterminer un minimiseur $x^* \in \mathbb{R}^n$ parmi tous les $x \in \mathbb{R}^n$ vérifiant

$$g_i(x) = 0 \quad \text{et} \quad h_j(x) \leq 0,$$

où $g_i : \mathbb{R}^n \rightarrow \mathbb{R}$ sont des fonctions **affines**, et $h_j : \mathbb{R}^n \rightarrow \mathbb{R}$ des fonctions **convexes**.

L'ensemble C , appelé **ensemble des contraintes** (ou **ensemble des solutions admissibles**), s'écrit alors

$$C = \bigcap_{j=1}^m \text{Lev}(h_j, 0) \cap \bigcap_{i=1}^p g_i^{-1}(0),$$

c'est-à-dire comme l'intersection de sous-ensembles convexes, et est donc lui-même **convexe**.

Le résultat suivant affirme que pour les problèmes convexes, un minimum local est en réalité un minimum global.

Théorème 42. Soit $f : C \rightarrow \mathbb{R}$ une fonction convexe définie sur un convexe C . Soit $x^* \in C$ est un minimum local de f sur C . Alors x^* est un minimum global de f sur C .

Preuve. Soit x^* un minimum local de f sur C , il existe alors $r > 0$ tel que $f(x^*) \leq f(x)$ pour tout $y \in C$ avec $\|x^* - x\| \leq r$. Pour montrer que $f(x^*) \leq f(y)$ pour tout $y \in C \setminus \{x^*\}$, on considère un $\bar{x} = (1 - t)x^* + ty$ pour un certain $t \in (0, 1]$ de telle façon que $\|\bar{x} - x^*\| \leq r$. On peut prendre par exemple $t = r/\|x^* - y\|$. Comme x^* est minimum local, il s'ensuit, par convexité de f

$$f(x^*) \leq f(\bar{x}) = f(ty + (1 - t)x^*) \leq tf(y) + (1 - t)f(x^*),$$

soit $tf(x^*) \leq tf(y)$ et donc $f(x^*) \leq f(y)$. □

De même on démontre que

Théorème 43. Soit $f : C \rightarrow \mathbb{R}$ une fonction strictement convexe définie sur un convexe C . Soit $x^* \in C$ est un minimum local de f sur C . Alors x^* est un minimum global stricte de f sur C .

Notation. On note par $\underset{x \in C}{\operatorname{argmin}} f(x)$ (des fois $\mathcal{S}$) l'ensemble des minimiseurs de f , i.e., les solutions de (4.3).

Théorème 44. Soit $f : C \rightarrow \mathbb{R}$ une fonction convexe, alors $\mathcal{S}$ est convexe. Si f est strictement convexe, alors $\mathcal{S}$ contient au plus un élément.

Preuve. Si $\mathcal{S} = \emptyset$, rien à démontrer. Sinon, soient $x, y \in \mathcal{S}$ et $\lambda \in [0, 1]$. Alors

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y) = \lambda f^* + (1 - \lambda)f^* = f^*.$$

Ce qui prouve la convexité. Maintenant, si f est strictement convexe et supposons qu'il existe $x, y \in \mathcal{S}$ avec $x \neq y$. Par convexité de C on a $\frac{1}{2}x + \frac{1}{2}y \in C$ et par convexité de f :

$$f\left(\frac{1}{2}x + \frac{1}{2}y\right) < \frac{1}{2}f(x) + \frac{1}{2}f(y) = f^*,$$

cela contredit le fait que f^* est la valeur optimale. □

Remarque 20. Pour la convexité de $\mathcal{S}$, on peut remarquer que $\mathcal{S} = \{x : f(x) \leq f^*\} \cap C = \text{Lev}(f, f^*) \cap C$ qui est convexe comme intersection de convexes.

4.2.2 Stationnarité

Nous avons introduit, dans la [Définition 44](#), la notion de **point critique** (ou **stationnaire**) dans le cas des problèmes **sans contraintes**, c'est-à-dire les zéros du gradient. Nous avons vu que cette condition constituait une **condition nécessaire d'optimalité**.

Nous allons maintenant étendre cette notion aux problèmes **avec contraintes** du type

$$\min_{x \in C} f(x), \quad (4.4)$$

où $f \in C^1(C)$ et $C \subset \mathbb{R}^n$ est un ensemble convexe fermé.

Définition 48 (Point stationnaire pour (4.4)). Soit $f \in C^1(C)$ avec $C \subset \mathbb{R}^n$ convexe fermé. On dit qu'un point $x^* \in C$ est un **point stationnaire** du problème (4.4) si

$$\langle \nabla f(x^*), x - x^* \rangle \geq 0, \quad \forall x \in C.$$

Remarque 21. Lorsque $C = \mathbb{R}^n$, la condition de stationnarité s'écrit simplement

$$\langle \nabla f(x^*), x - x^* \rangle \geq 0, \quad \forall x \in \mathbb{R}^n.$$

En choisissant en particulier $x = x^* - \nabla f(x^*)$, on obtient

$$-\|\nabla f(x^*)\|^2 \geq 0,$$

ce qui impose $\nabla f(x^*) = 0$. Autrement dit, on retrouve la condition de stationnarité classique du cas non contraint, introduite en [Définition 44](#).

La notion de stationnarité introduite en [Définition 48](#) constitue en fait une **condition nécessaire d'optimalité** pour le problème (4.4).

Théorème 45 (Condition de stationnarité). Soit $f \in C^1(C)$ avec $C \subset \mathbb{R}^n$ convexe fermé, et soit $x^* \in C$ un minimum local du problème (4.4). Alors x^* est un point stationnaire de (4.4).

De plus, si f est **convexe**, alors x^* est un point stationnaire de (4.4) si et seulement si x^* est une solution optimale du problème.

Preuve. Exercice. □




Figure 4.3: Projection orthogonale.

4.3 Projection orthogonale

Soit $C \subset \mathbb{R}^n$ un convexe fermé non vide.

Définition 49. L'opérateur de projection orthogonale sur C est l'application $P_C : \mathbb{R}^n \rightarrow C$ qui à $x \in \mathbb{R}^n$ associe

$$P_C(x) = \operatorname{argmin}_{y \in C} \|y - x\|^2 \quad (4.5)$$

On a le résultat

Théorème 46 (Premier théorème de la projection). Soit C un ensemble convexe, fermé et non vide. Alors le problème (4.5) admet une unique solution.

Preuve. La fonction $y \mapsto \|y - x\|^2$ est coercive, et comme C est fermé et non vide, le théorème [Théorème 40](#) garantit l'existence d'au moins une solution. De plus, la fonction $y \mapsto \|y - x\|^2$ est strictement convexe, ce qui assure l'unicité du minimiseur d'après [Théorème 44](#). $\square$

Grâce au [Théorème 45](#), on obtient la caractérisation géométrique suivante de la projection.

Théorème 47 (Deuxième théorème de la projection). Soit $C \subset \mathbb{R}^n$ un ensemble convexe, fermé et non vide, et soit $x \in \mathbb{R}^n$. Alors $z = P_C(x)$ si et seulement si

$$\langle x - z, y - z \rangle \leq 0, \quad \forall y \in C.$$

Preuve. Soit $x \in \mathbb{R}^n$. On sait que $P_C(x)$ est la solution du problème convexe

$$\min_{y \in C} \phi(y) := \|y - x\|^2.$$

Comme $\nabla \phi(P_C(x)) = 2(P_C(x) - x)$, il résulte du [Théorème 45](#) que $z = P_C(x)$ si et seulement si

$$\langle \nabla \phi(P_C(x)), y - P_C(x) \rangle \geq 0, \quad \forall y \in C,$$

ce qui revient à écrire

$$\langle x - z, y - z \rangle \leq 0, \quad \forall y \in C.$$

$\square$

Le [Théorème 47](#) affirme que, pour tout $x \in \mathbb{R}^n$, l'angle entre $x - P_C(x)$ et $y - P_C(x)$, pour tout $y \in C$, est supérieur ou égal à $\pi/2$. Cette propriété est illustrée sur la [Fig. 4.3](#).

On termine ce chapitre avec le résultat suivant, qui rassemble quelques propriétés fondamentales du projecteur orthogonal sur un convexe fermé.

Théorème 48. Soit $C \subset \mathbb{R}^n$ un ensemble convexe fermé. Alors le projecteur orthogonal P_C est 1-cocoercif, c'est-à-dire que pour tout $x, y \in \mathbb{R}^n$,

$$\langle P_C(x) - P_C(y), x - y \rangle \geq \|P_C(x) - P_C(y)\|^2. \quad (4.6)$$

En particulier, P_C est une application 1-lipschitzienne :


$$\|P_C(x) - P_C(y)\| \leq \|x - y\|, \quad \forall x, y \in \mathbb{R}^n. \quad (4.7)$$

Preuve. Par le [Théorème 47](#), on a

$$\langle x - P_C(x), y - P_C(x) \rangle \leq 0, \quad \forall y \in C.$$

En particulier, en prenant $y = P_C(y)$, on obtient

$$\langle x - P_C(x), P_C(y) - P_C(x) \rangle \leq 0.$$

Figure 4.4: L'opérateur P_C est non-expansive.

De même,

$$\langle y - P_C(y), P_C(x) - P_C(y) \rangle \leq 0.$$

En sommant les deux inégalités, on obtient

$$\langle P_C(y) - P_C(x), x - y + P_C(y) - P_C(x) \rangle \leq 0.$$

En réarrangeant, cela donne

$$\langle P_C(x) - P_C(y), x - y \rangle \geq \|P_C(x) - P_C(y)\|^2,$$

ce qui prouve la 1-cocoercivité. Pour établir la propriété de 1-Lipschitz continuité, le résultat est évident si $P_C(x) = P_C(y)$. Sinon, l'inégalité précédente et l'inégalité de Cauchy-Schwarz donnent

$$\|P_C(x) - P_C(y)\| \|x - y\| \geq \langle P_C(x) - P_C(y), x - y \rangle \geq \|P_C(x) - P_C(y)\|^2.$$

En divisant des deux côtés par $\|P_C(x) - P_C(y)\| > 0$, on obtient

$$\|P_C(x) - P_C(y)\| \leq \|x - y\|, \quad \forall x, y \in \mathbb{R}^n.$$

□

4.4 Théorèmes de séparation par un hyperplan affine

Les résultats sur la projection présentés dans [Section 4.3](#) permettent d'obtenir des résultats de séparation d'ensembles. On commence par la définition suivante.

Définition 50. Deux ensembles $S_1, S_2 \subset \mathbb{R}^n$ sont dits séparables s'il existe un hyperplan qui les sépare, i.e., s'il existe $a \in \mathbb{R}^n \setminus \{0\}$ et $\alpha \in \mathbb{R}$ tels que

$$\langle a, x \rangle \geq \alpha, \quad \forall x \in S_1 \quad \text{et} \quad \langle a, x \rangle \leq \alpha, \quad \forall x \in S_2. \quad (4.8)$$

On dira que $S_1, S_2 \subset \mathbb{R}^n$ sont strictement séparables s'il existe un hyperplan qui les sépare strictement, i.e., s'il existe $a \in \mathbb{R}^n \setminus \{0\}$ et $\alpha_1, \alpha_2 \in \mathbb{R}$ avec $\alpha_1 > \alpha_2$ tels que

$$\langle a, x \rangle \geq \alpha_1, \quad \forall x \in S_1 \quad \text{et} \quad \langle a, x \rangle \leq \alpha_2, \quad \forall x \in S_2. \quad (4.9)$$

On dit qu'un hyperplan $H = \{x \in \mathbb{R}^n : \langle a, x \rangle = \alpha\}$ sépare $S \subset \mathbb{R}^n$ de $x_0 \notin S$ si $\langle a, x \rangle \leq \alpha$ pour tout $x \in S$ et $\langle a, x_0 \rangle > \alpha$ (Voir [Fig. 4.5](#)).

Théorème 49. Soient $S_1, S_2 \subset \mathbb{R}^n$ deux convexes fermés disjoints. Supposons que S_2 soit borné. Alors S_1 et S_2 sont strictement séparables.

Preuve. On note $D(x) = \|x - P_{S_1}(x)\|$. La fonction D étant continue (car la projection P_{S_1} est 1-lipschitzienne cf. Eq. (4.7)), elle atteint son minimum sur le compact S_2 (voir Théorème 39). Soit $z_2 \in \operatorname{argmin}_{x \in S_2} D(x)$ et $z_1 = P_{S_1}(z_2)$. Comme S_1 et S_2 sont disjoints, on a $z_1 \neq z_2$ et donc

$$\|z_1 - z_2\| = \min_{x \in S_1, y \in S_2} \|x - y\| > 0.$$

Puisque le couple (z_1, z_2) minimise la distance entre les deux ensembles, on a également $z_2 = P_{S_2}(z_1)$. Par la caractérisation de la projection sur S_1 (Théorème 47), on a :

$$\langle z_2 - z_1, x - z_1 \rangle \leq 0 \Rightarrow \langle z_1 - z_2, x \rangle \geq \langle z_1 - z_2, z_1 \rangle := \alpha_1, \quad \forall x \in S_1,$$

et par caractérisation de la projection sur S_2 , on a :

$$\langle z_1 - z_2, y - z_2 \rangle \leq 0 \Rightarrow \langle z_1 - z_2, y \rangle \leq \langle z_1 - z_2, z_2 \rangle := \alpha_2, \quad \forall y \in S_2.$$

On obtient alors $\alpha_1 - \alpha_2 = \langle z_1 - z_2, z_1 \rangle - \langle z_1 - z_2, z_2 \rangle = \|z_1 - z_2\|^2 > 0$. Ainsi, S_1 et S_2 sont strictement séparables par le vecteur normal $a = z_1 - z_2$. $\square$

Le résultat suivant montre qu'on peut toujours séparer un point d'un convexe fermé auquel il n'appartient pas.

Théorème 50. Soit $S \subset \mathbb{R}^n$ un convexe fermé et $x_0 \notin S$. Alors il existe un hyperplan séparant strictement x_0 de S .

Preuve. Par caractérisation de la projection (Théorème 47), $x^* = P_S(x_0) \in S$ vérifie $\langle x_0 - P_S(x_0), x - P_S(x_0) \rangle \leq 0$ pour tout $x \in S$. En développant, cela s'écrit encore $\langle x_0 - P_S(x_0), x \rangle \leq \langle x_0 - P_S(x_0), P_S(x_0) \rangle$ pour tout $x \in S$.

Comme $x_0 \notin S$, on a $p := x_0 - P_S(x_0) \neq 0$. Notons $\alpha = \langle x_0 - P_S(x_0), P_S(x_0) \rangle$. Alors on a $\langle p, x \rangle \leq \alpha$ pour tout $x \in S$.

D'autre part, évaluons la position de x_0 par rapport à p :

$$\begin{aligned} \langle p, x_0 \rangle &= \langle x_0 - P_S(x_0), x_0 \rangle \\ &= \langle x_0 - P_S(x_0), x_0 - P_S(x_0) + P_S(x_0) \rangle \\ &= \|x_0 - P_S(x_0)\|^2 + \langle x_0 - P_S(x_0), P_S(x_0) \rangle \\ &= \|p\|^2 + \alpha > \alpha. \end{aligned}$$

Ainsi, l'hyperplan $H = \{x \in \mathbb{R}^n : \langle p, x \rangle = \alpha\}$ sépare strictement x_0 de l'ensemble S . $\square$

Définition 51 (Hyperplan d'appui). Soit $S \subset \mathbb{R}^n$. Un hyperplan $H = \{x \in \mathbb{R}^n : \langle a, x \rangle = \alpha\}$ (avec $a \neq 0$ et $\alpha \in \mathbb{R}$) est appelé hyperplan d'appui de S en $x_0 \in S$ si :

$$\langle a, x_0 \rangle = \alpha \quad \text{et} \quad \langle a, x \rangle \leq \alpha, \quad \forall x \in S.$$

Théorème 51 (Hahn Banach - version géométrique). Soit $S \subset \mathbb{R}^n$ un convexe fermé et $x_0 \in \partial S$. Il existe un hyperplan d'appui de S en x_0 .

Preuve. Comme $x_0 \in \partial S$, il existe une suite $(x_k)_{k \geq 1} \subset \mathbb{R}^n \setminus S$ convergeant vers x_0 . D'après le théorème de séparation (cf. Théorème 50), chaque x_k peut être séparé strictement de S . Posons $z_k = \frac{x_k - P_S(x_k)}{\|x_k - P_S(x_k)\|}$ et $\alpha_k = \langle z_k, P_S(x_k) \rangle$. Alors pour tout $k \geq 1$, l'hyperplan $H_k := \{x \in \mathbb{R}^n : \langle z_k, x \rangle = \alpha_k\}$ sépare x_k de S , c'est-à-dire :

$$\langle z_k, x \rangle \leq \alpha_k \leq \langle z_k, x_k \rangle, \quad \forall x \in S. \quad (4.10)$$




Figure 4.5: Illustration géométrique du théorème de séparation stricte d'un point x_0 et d'un convexe fermé S par un hyperplan affine H .

Comme $\|z_k\| = 1$ pour tout k , la suite $(z_k)_{k \geq 1}$ est bornée. Par le théorème de Bolzano-Weierstrass, on peut en extraire une sous-suite $(z_{\phi(k)})_{k \geq 1}$ qui converge vers un certain vecteur z^* . Puisque la norme est continue, $\|z^*\| = 1$, ce qui garantit que $z^* \neq 0$.

De plus, par continuité de la projection sur le fermé S , on a $\lim_{k \rightarrow \infty} P_S(x_{\phi(k)}) = P_S(x_0) = x_0$ (car $x_0 \in S$). Ainsi, la sous-suite $\alpha_{\phi(k)} = \langle z_{\phi(k)}, P_S(x_{\phi(k)}) \rangle$ converge vers $\alpha^* = \langle z^*, x_0 \rangle$.

En passant à la limite quand $k \rightarrow \infty$ le long de cette sous-suite dans l'inégalité (4.10), on obtient

$$\langle z^*, x \rangle \leq \alpha^* = \langle z^*, x_0 \rangle, \quad \forall x \in S.$$

L'hyperplan $H_\infty := \{x \in \mathbb{R}^n : \langle z^*, x \rangle = \alpha^*\}$ est donc bien un hyperplan d'appui de S en x_0 . $\square$

Le résultat suivant, connu sous le nom de lemme de Farkas (ou de Farkas-Minkowski), présente un résultat d'alternative fondamental concernant les systèmes linéaires.

Théorème 52 (Lemme de Farkas). Soient $A \in \mathbb{R}^{m \times n}$ et $b \in \mathbb{R}^m$. Les deux assertions suivantes sont équivalentes :

1. $Ax \leq 0 \Rightarrow \langle b, x \rangle \leq 0$.
2. Il existe $y \in \mathbb{R}_+^m$ tel que $A^\top y = b$.

Preuve. Supposons que l'Item 2 est vérifiée : il existe $y \in \mathbb{R}_+^m$ tel que $A^\top y = b$. Si $Ax \leq 0$ pour un certain $x \in \mathbb{R}^n$, comme $y \geq 0$, il vient que $y^\top Ax \leq 0$. Or $A^\top y = b$, on obtient donc $b^\top x = y^\top Ax \leq 0$, ce qui prouve l'Item 1.

Inversement, supposons que l'Item 1 est vraie et montrons que l'Item 2 est vérifiée. Définissons le cône $S = \{x \in \mathbb{R}^n : x = A^\top y, y \in \mathbb{R}_+^m\}$. L'ensemble S est un convexe fermé (d'accords ?).

Si l'Item 2 n'est pas vérifiée, alors $b \notin S$. Par le théorème de séparation stricte (Théorème 50), il existe $a \in \mathbb{R}^n \setminus \{0\}$ et $\alpha \in \mathbb{R}$ tels que :

$$\langle a, b \rangle > \alpha \quad \text{et} \quad \langle a, x \rangle \leq \alpha \quad \forall x \in S. \quad (4.11)$$

Comme $0 \in S$, on a nécessairement $\alpha \geq 0$ et donc $\langle a, b \rangle > 0$.

De plus, comme les éléments de S s'écrivent sous la forme $A^\top y$ pour $y \in \mathbb{R}_+^m$, on en déduit que :

$$\langle a, A^\top y \rangle = \langle Aa, y \rangle \leq \alpha, \quad \forall y \in \mathbb{R}_+^m. \quad (4.12)$$

Cela implique que $Aa \leq 0$. En effet, s'il existait un indice $k \in \{1, \dots, m\}$ tel que $(Aa)_k > 0$, on pourrait prendre $y = \eta e_k$ (où e_k est le k -ème vecteur de la base canonique et $\eta > 0$). On obtiendrait alors $\langle Aa, y \rangle = \eta(Aa)_k \rightarrow +\infty$ quand $\eta \rightarrow +\infty$, ce qui contredit (4.12).

Nous avons donc trouvé un vecteur $a \in \mathbb{R}^n$ tel que $Aa \leq 0$. Puisque l'hypothèse [Item 1](#) est vérifiée, cela implique que $\langle b, a \rangle \leq 0$. Or, cela contredit directement le fait que $\langle a, b \rangle > 0$ obtenu à partir de (4.11). L'assertion [Item 2](#) est donc nécessairement vraie. $\square$

On termine cette section avec un résultat d'alternative fondamental, souvent utilisé pour démontrer les conditions d'optimalité, et qui s'obtient comme un corollaire direct du Lemme de Farkas.

Théorème 53 (Théorème de Gordan). Soit $A \in \mathbb{R}^{m \times n}$. Exactement l'un des deux systèmes suivants admet une solution :

1. Il existe $x \in \mathbb{R}^n$ tel que $Ax < 0$.
2. Il existe $y \in \mathbb{R}_+^m \setminus \{0\}$ tel que $A^\top y = 0$.

Preuve. Commençons par montrer que les deux assertions ne peuvent être vraies simultanément. Supposons par l'absurde qu'il existe x solution de [Item 1](#) et y solution de [Item 2](#). Alors on aurait :

$$0 = \langle A^\top y, x \rangle = \langle y, Ax \rangle.$$

Or, puisque $y \in \mathbb{R}_+^m \setminus \{0\}$ et $Ax < 0$ (toutes composantes strictement négatives), on a nécessairement

$$\langle y, Ax \rangle = \sum_{i=1}^m y_i (Ax)_i < 0,$$

ce qui contredit $\langle y, Ax \rangle = 0$.

Montrons maintenant que si [Item 1](#) n'admet pas de solution, alors [Item 2](#) en admet une. Dire qu'il n'existe aucun $x \in \mathbb{R}^n$ tel que $Ax < 0$ équivaut à dire qu'il n'existe aucun couple $(x, s) \in \mathbb{R}^n \times \mathbb{R}$ tel que

$$Ax + s\mathbb{1}_m \leq 0 \quad \text{et} \quad s > 0,$$

où $\mathbb{1}_m = (1, \dots, 1)^\top \in \mathbb{R}^m$. Autrement dit, pour tout $(x, s) \in \mathbb{R}^{n+1}$:

$$Ax + s\mathbb{1}_m \leq 0 \Rightarrow s \leq 0.$$

Posons $\tilde{x} = \begin{pmatrix} x \\ s \end{pmatrix} \in \mathbb{R}^{n+1}$, $\tilde{A} = \begin{pmatrix} A & \mathbb{1}_m \end{pmatrix} \in \mathbb{R}^{m \times (n+1)}$ et $b = \begin{pmatrix} 0_{\mathbb{R}^n} \\ 1 \end{pmatrix} \in \mathbb{R}^{n+1}$. L'implication ci-dessus se réécrit alors sous la forme


$$\tilde{A}\tilde{x} \leq 0 \Rightarrow \langle b, \tilde{x} \rangle \leq 0,$$

qui est exactement l'hypothèse du lemme de Farkas ([Théorème 52](#)). Ce dernier garantit donc l'existence de $y \in \mathbb{R}_+^m$ tel que $\tilde{A}^\top y = b$, c'est-à-dire

$$\begin{pmatrix} A^\top \\ \mathbb{1}_m^\top \end{pmatrix} y = \begin{pmatrix} 0_{\mathbb{R}^n} \\ 1 \end{pmatrix} \Leftrightarrow \begin{cases} A^\top y = 0, \\ \mathbb{1}_m^\top y = 1. \end{cases}$$

La condition $\mathbb{1}_m^\top y = \sum_{i=1}^m y_i = 1$ combinée à $y \in \mathbb{R}_+^m$ garantit que $y \neq 0$. Nous avons donc trouvé $y \in \mathbb{R}_+^m \setminus \{0\}$ tel que $A^\top y = 0$, ce qui établit [Item 2](#). $\square$

Algorithmes d'optimisation



Descente de gradient

Minimisation de $f(x)$ par itérations successives

Considérons un problème de la forme

$$\min_{x \in \mathbb{R}^n} f(x), \quad (\text{P})$$

avec $f : \mathbb{R}^n \rightarrow \mathbb{R}$. L'objectif est de construire une suite $(x_k)_k$ telle que $f(x_k) \rightarrow f^* := \min_{\mathbb{R}^n} f$ quand $k \rightarrow \infty$ et, si possible, $x_k \rightarrow x^* \in \operatorname{argmin}_{\mathbb{R}^n} f$ dans un sens à préciser. Une façon de générer une telle suite est de considérer

$$x_{k+1} = x_k + t_k \mathbf{d}_k,$$

où $\mathbf{d}_k \in \mathbb{R}^n$ est un vecteur de $\mathbb{R}^n$ et $t_k \geq 0$ est un pas de déplacement. Dans un premier temps, on s'intéressera donc à $(t_k, \mathbf{d}_k)$.

5.1 Directions de descente

Définition 52. Soit $f : \mathbb{R}^n \rightarrow \mathbb{R}$ une fonction de classe C^1 . On dit qu'un vecteur non nul $\mathbf{d}$ de $\mathbb{R}^n$ est une direction de descente de f en x si

$$f'(x; \mathbf{d}) = \nabla f(x)^T \mathbf{d} < 0.$$

Il se trouve qu'en suivant des directions de descente avec un pas suffisamment petit, on arrive à décroître la fonction objectif. On a le résultat suivant :

Lemme 3. Soit $f : \mathbb{R}^n \rightarrow \mathbb{R}$ une fonction de classe C^1 et $\mathbf{d}$ une direction de descente de f en $x \in \mathbb{R}^n$. Alors, il existe $\eta > 0$ tel que

$$f(x + t\mathbf{d}) < f(x),$$

pour tout $t \in (0, \eta]$.

Preuve. Soit $x \in \mathbb{R}^n$ et $\mathbf{d}$ une direction de descente en x . On a $f(x + t\mathbf{d}) = f(x) + t\langle \nabla f(x), \mathbf{d} \rangle + o(t\|\mathbf{d}\|)$. On sait que pour tout $\varepsilon > 0$, il existe $\eta > 0$ tel que $\frac{|o(t\|\mathbf{d}\|)|}{t} \leq \varepsilon$ pour tout $t \in (0, \eta]$. En prenant $\varepsilon = -\langle \nabla f(x), \mathbf{d} \rangle$ qui est strictement positif puisque $\mathbf{d}$ est une direction de descente en x , on obtient que

$$o(t\|\mathbf{d}\|)/t \leq |o(t\|\mathbf{d}\|)|/t \leq -\langle \nabla f(x), \mathbf{d} \rangle,$$

donc $f(x + t\mathbf{d}) < f(x), \forall t \in (0, \eta]$. □

D'une façon générale, une méthode de descente s'écrit comme suit :

Méthode de descente

- Initialisation : On se donne un $x_0 \in \mathbb{R}^n$.
- Pour $k \geq 0$
 - Choisir une direction de descente $\mathbf{d}_k$.
 - Choisir un pas t_k tel que : $f(x_k + t_k \mathbf{d}_k) < f(x_k)$.
 - Prendre $x_{k+1} = x_k + t_k \mathbf{d}_k$.
 - Si un critère d'arrêt est vérifié, renvoyer x_{k+1} .

Remarque 22. • Le choix de la direction de descente donne lieu à des méthodes différentes de descente (e.g., gradient, gradient conjugué, Newton, quasi-Newton etc).

- Il existe plusieurs critères d'arrêt ; le plus utilisé est $\|\nabla f(x_{k+1})\| \leq \varepsilon$ pour une tolérance $\varepsilon > 0$ donnée.
- Le procédé permettant de trouver le pas t_k s'appelle **recherche linéaire** (line search en anglais). L'appellation vient du fait que trouver un tel t_k revient à minimiser la restriction de f sur la ligne $x_k + t\mathbf{d}_k$, i.e., la fonction $g(t) = f(x_k + t\mathbf{d}_k)$. On discute ici quelques choix populaires.

1. **Pas constant** : dans ce cas $t_k = \bar{t}$ pour tout k . Bien que ce soit un choix simple, un pas trop petit peut donner lieu à une convergence lente de l'algorithme tandis qu'avec un pas trop grand on peut perdre la décroissance de la fonction objectif (cf. TP).
2. **Recherche linéaire exacte** : dans ce cas on cherche à minimiser exactement la fonction $g(t)$ définie ci-dessus. On choisit donc $t_k \in \operatorname{argmin}_{t \geq 0} f(x_k + t\mathbf{d}_k)$. Il se trouve qu'en général, on ne peut pas trouver le minimiseur exact de g .
3. **Rebroussement (ou Backtracking)** : cette approche permet d'éviter une recherche linéaire exacte en choisissant convenablement un pas assurant la décroissance de la fonction objectif. L'approche requiert trois paramètres $s > 0$ et $\alpha, \beta \in (0, 1)$. Dans un premier temps on prend $t_k = s$ et tant que

$$f(x_k) - f(x_k + t_k \mathbf{d}_k) < -\alpha t_k \nabla f(x_k)^T \mathbf{d}_k,$$

(i.e., $f(x_{k+1}) > f(x_k)$) on met à jour t_k par $t_k \beta$. Dans ce cas, le pas choisi serait $t_k = s\beta^{i_k}$ où i_k est le plus petit entier tel que

$$f(x_k) - f(x_k + t_k \mathbf{d}_k) \geq -\alpha s \beta^{i_k} \nabla f(x_k)^T \mathbf{d}_k. \quad (5.1)$$

Comme $\mathbf{d}_k$ est une direction de descente de f en x_k , l'inégalité (5.1) assure la décroissance de la suite $(f(x_k))_k$.

Il s'avère que (5.1) est toujours vérifiée pour des pas t_k suffisamment petits.

Lemme 4. Soit $f : \mathbb{R}^n \rightarrow \mathbb{R}$ une fonction de classe C^1 et $\mathbf{d}$ une direction de descente de f en $x \in \mathbb{R}^n$, et soit $\alpha \in (0, 1)$. Alors, il existe $\eta > 0$ tel que

$$-\alpha t \langle \nabla f(x), \mathbf{d} \rangle < f(x) - f(x + t\mathbf{d}),$$

pour tout $t \in (0, \eta]$.

Preuve. Soit $x \in \mathbb{R}^n$ et $\mathbf{d}$ une direction de descente en x . On a $f(x + t\mathbf{d}) = f(x) + t\langle \nabla f(x), \mathbf{d} \rangle + o(t\|\mathbf{d}\|)$. Par définition :

$$\forall \varepsilon > 0, \exists \eta > 0 : \frac{|o(t\|\mathbf{d}\|)|}{t} \leq \varepsilon, \forall t \in (0, \eta].$$

En prenant $\varepsilon = -(\alpha - 1)\langle \nabla f(x), \mathbf{d} \rangle$ qui est strictement positif puisque $\mathbf{d}$ est une direction de descente en x , on obtient que

$$o(t\|\mathbf{d}\|)/t \leq |o(t\|\mathbf{d}\|)|/t \leq (\alpha - 1)\langle \nabla f(x), \mathbf{d} \rangle,$$

soit

$$o(t\|\mathbf{d}\|) + t\langle \nabla f(x), \mathbf{d} \rangle < \alpha t\langle \nabla f(x), \mathbf{d} \rangle$$

donc $-\alpha t\langle \nabla f(x), \mathbf{d} \rangle < f(x) - f(x + t\mathbf{d}), \forall t \in (0, \eta]$. $\square$

L'exemple suivant présente le cas d'une recherche linéaire exacte pour une fonction quadratique.

Exemple 17. On considère $f(x) = x^T A x + 2b^T x + c$ avec $A \in \mathcal{S}_n^{++}, b \in \mathbb{R}^n, c \in \mathbb{R}$. Soit $x \in \mathbb{R}^n$ et $\mathbf{d} \in \mathbb{R}^n \setminus \{0\}$ une direction de descente de f en x . Effectuer une recherche linéaire exacte revient à résoudre

$$\min_{t \geq 0} f(x + t\mathbf{d}) := g(t).$$

On a $g'(t) = \mathbf{d}^T \nabla f(x + t\mathbf{d})$ et comme $\nabla f(x) = 2(Ax + b)$, on trouve que $g'(t) = 2(\mathbf{d}^T A \mathbf{d})t + 2\mathbf{d}^T \nabla f(x)$. Donc

$$g'(t) = 0 \Leftrightarrow t = -\frac{\mathbf{d}^T \nabla f(x)}{2\mathbf{d}^T A \mathbf{d}} > 0.$$

Comme $g''(t) = 2(\mathbf{d}^T A \mathbf{d}) > 0$ alors le pas donné par la méthode de recherche linéaire exacte est $t^* = -\frac{\mathbf{d}^T \nabla f(x)}{2\mathbf{d}^T A \mathbf{d}}$.

Comme son nom l'indique, le choix de la direction de descente dans la méthode du gradient est $\mathbf{d}_k = -\nabla f(x_k)$. Ce choix est bien une direction de descente au sens de la Définition 52. En effet, pour $\nabla f(x_k) \neq 0$:

$$f'(x_k; -\nabla f(x_k)) = -\nabla f(x_k)^T \nabla f(x_k) = -\|\nabla f(x_k)\|^2 < 0.$$

Au-delà du fait que $\mathbf{d} = -\nabla f(x_k)$ est une direction de descente, le vecteur unitaire $\mathbf{d}^* = \mathbf{d}/\|\mathbf{d}\|$ est celui de la plus forte pente, i.e., il minimise la dérivée directionnelle $f'(x_k; \mathbf{d})$ parmi tous les vecteurs unitaires $\mathbf{d}$. Plus formellement, on a le résultat suivant.

Proposition 14. Soit $f \in C^1(\mathbb{R}^n)$ et $x \in \mathbb{R}^n$ tel que $\nabla f(x) \neq 0$. Alors une solution du problème

$$\min_{\mathbf{d} \in \mathbb{R}^n : \|\mathbf{d}\|=1} f'(x; \mathbf{d}), \quad (5.2)$$

est $\mathbf{d}^* = -\nabla f(x)/\|\nabla f(x)\|$.

Preuve. Le problème (5.2) s'écrit aussi

$$\min_{\mathbf{d} : \|\mathbf{d}\|=1} \langle \nabla f(x), \mathbf{d} \rangle,$$

et grâce à l'inégalité de Cauchy-Schwarz, on a

$$\langle \nabla f(x), \mathbf{d} \rangle \geq -\|\mathbf{d}\|\|\nabla f(x)\| = -\|\nabla f(x)\|,$$

donc $-\|\nabla f(x)\|$ est une borne inférieure de la valeur optimale de (5.2). Cette valeur est atteinte

en particulier en $\mathbf{d}^*$. En effet

$$f'(x; \mathbf{d}^*) = \langle \nabla f(x), \frac{-\nabla f(x)}{\|\nabla f(x)\|} \rangle = -\|\nabla f(x)\|,$$

d'où le résultat. $\square$

On présente ci-dessous les étapes de la méthode, avec comme critère d'arrêt $\|\nabla f(x_{k+1})\| \leq \varepsilon$ pour une tolérance ε donnée.

Méthode du gradient

- Initialisation : On se donne un $x_0 \in \mathbb{R}^n$.
- Pour $k \geq 0$
 - Choisir un pas t_k par recherche linéaire sur $g(t) = f(x_k - t\nabla f(x_k))$.
 - Prendre $x_{k+1} = x_k - t_k \nabla f(x_k)$.
 - Si $\|\nabla f(x_{k+1})\| \leq \varepsilon$, s'arrêter et renvoyer x_{k+1} .

5.2 Analyse de convergence

Avant de commencer notre analyse, rappelons qu'une fonction $f : \mathbb{R}^n \rightarrow \mathbb{R}$ est dans $C_L^{1,1}(\mathbb{R}^n)$ si elle est de classe C^1 et que son gradient $\nabla f : \mathbb{R}^n \rightarrow \mathbb{R}^n$ est L -Lipschitz, i.e.,

$$\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\| \quad \text{pour tout } x, y \in \mathbb{R}^n.$$

Exemple 18. • On vérifie facilement que $f(x) = a^T x + b \in C_0^{1,1}(\mathbb{R}^n)$.

- Une fonction quadratique $f(x) = x^T A x + 2b^T x + c$ avec $A \in \mathcal{S}_n, b \in \mathbb{R}^n$ et $c \in \mathbb{R}$ est $2\|A\|$ -Lipschitz. En effet, comme $\nabla f(x) = 2Ax + 2b$ on a

$$\|\nabla f(x) - \nabla f(y)\| = 2\|(Ax + b) - (Ay + b)\| \leq 2\|A\|\|x - y\|.$$

Si la fonction est C^2 , alors la régularité Lipschitz du gradient est équivalente au fait que la Hessienne est bornée :

Théorème 54. Soit $f \in C^2(\mathbb{R}^n)$. Alors

$$f \in C_L^{1,1}(\mathbb{R}^n) \Leftrightarrow \|\nabla^2 f(x)\| \leq L \quad \text{pour tout } x \in \mathbb{R}^n.$$

Le résultat suivant joue un rôle important dans la suite.

Lemme 5 (Lemme de descente). Soit $f \in C_L^{1,1}(\mathbb{R}^n)$. Alors pour tout $x, y \in \mathbb{R}^n$

$$f(y) \leq f(x) + \nabla f(x)^T (y - x) + \frac{L}{2} \|x - y\|^2.$$

Preuve. Soient $x, y \in \mathbb{R}^n$. Par le théorème fondamental de l'analyse

$$f(y) = f(x) + \int_0^1 \langle \nabla f(x + t(y - x)), y - x \rangle dt,$$

donc

$$f(y) - f(x) = \langle \nabla f(x), y - x \rangle + \int_0^1 \langle \nabla f(x + t(y - x)) - \nabla f(x), y - x \rangle dt.$$

Il s'ensuit que

$$\begin{aligned}
 |f(y) - f(x) - \langle \nabla f(x), y - x \rangle| &= \left| \int_0^1 \langle \nabla f(x + t(y - x)) - \nabla f(x), y - x \rangle dt \right|, \\
 &\leq \int_0^1 |\langle \nabla f(x + t(y - x)) - \nabla f(x), y - x \rangle| dt, \\
 &\stackrel{C.S.}{\leq} \int_0^1 \|\nabla f(x + t(y - x)) - \nabla f(x)\| \|y - x\| dt, \\
 &\stackrel{f \in C_L^{1,1}}{\leq} \int_0^1 Lt \|y - x\|^2 dt = \frac{L}{2} \|x - y\|^2.
 \end{aligned} \tag{5.3}$$

□




Figure 5.1: La fonction quadratique h_x majore f et la touche en x .

Fixons $x \in \mathbb{R}^n$ et considérons $h_x(y) = f(x) + \nabla f(x)^T(y - x) + \frac{L}{2}\|x - y\|^2$ qui est quadratique en y et majore f : $f(y) \leq h_x(y)$ pour tout $y \in \mathbb{R}^n$. De plus, le minimum de h_x est atteint en $x^* = x - \frac{1}{L}\nabla f(x)$ (voir Fig. 5.1). Comme conséquence du Lemme 5, on a

Lemme 6. Soit $f \in C_L^{1,1}(\mathbb{R}^n)$. Alors pour tout $x \in \mathbb{R}^n$ et $t > 0$

$$f(x) - f(x - t\nabla f(x)) \geq t \left(1 - \frac{tL}{2}\right) \|\nabla f(x)\|^2. \tag{5.4}$$

Preuve. On applique le Lemme de descente avec $y = x - t\nabla f(x)$ pour un $x \in \mathbb{R}^n$. On a donc

$$f(x - t\nabla f(x)) \leq f(x) - t\|\nabla f(x)\|^2 + \frac{Lt^2}{2}\|\nabla f(x)\|^2,$$

d'où le résultat en réarrangeant. □

Si nous optons pour une stratégie avec un pas constant, i.e., $t_k = t^* \in (0, 2/L)$ pour tout k , on a alors d'après le Lemme 6

$$f(x_k) - f(x_{k+1}) \geq t^* \left(1 - \frac{t^*L}{2}\right) \|\nabla f(x_k)\|^2.$$

La fonction $t \mapsto t(1 - \frac{tL}{2})$ sur $(0, 2/L)$ atteint un maximum en $t^* = 1/L$. Pour ce choix on a $x_{k+1} = x_k - \frac{1}{L}\nabla f(x_k)$ et

$$f(x_k) - f(x_{k+1}) \geq \frac{1}{2L} \|\nabla f(x_k)\|^2.$$

Pour une recherche linéaire exacte, i.e., $x_{k+1} = x_k - t_k \nabla f(x_k)$ avec

$$t_k \in \operatorname{argmin}_{t \geq 0} f(x_k - t \nabla f(x_k)),$$

on remarque que $f(x_k - t_k \nabla f(x_k)) \leq f(x_k - \frac{1}{L} \nabla f(x_k))$ soit

$$f(x_k) - f(x_{k+1}) \geq f(x_k) - f(x_k - \frac{1}{L} \nabla f(x_k)) \geq \frac{1}{2L} \|\nabla f(x_k)\|^2.$$

Dans le cadre de backtracking, on cherche pour $\alpha \in (0, 1)$, un pas t_k suffisamment petit tel que

$$f(x_k) - f(x_{k+1}) \geq \alpha t_k \|\nabla f(x_k)\|^2.$$

Dans ce cas deux options se présentent : prendre $t_k = s$ où $s > 0$ est la valeur initiale du pas, soit prendre t_k avec la méthode de backtracking comme décrit dans la [Remarque 22](#), et dans ce cas, le choix t_k/β ne serait pas admissible, i.e.,

$$f(x_k) - f(x_k - \frac{t_k}{\beta} \nabla f(x_k)) < \frac{\alpha t_k}{\beta} \|\nabla f(x_k)\|^2. \quad (5.5)$$

En appliquant (5.4) avec $x = x_k$ et $t = \frac{t_k}{\beta}$ on obtient

$$f(x_k) - f(x_k - \frac{t_k}{\beta} \nabla f(x_k)) \geq \frac{t_k}{\beta} \left(1 - \frac{t_k L}{2\beta}\right) \|\nabla f(x_k)\|^2. \quad (5.6)$$

Les équations (5.5)–(5.6) impliquent que $\frac{t_k}{\beta} \left(1 - \frac{t_k L}{2\beta}\right) < \frac{\alpha t_k}{\beta}$, soit $t_k > \frac{2(\alpha-1)\beta}{L}$. Finalement, pour la méthode de backtracking, on a

$$f(x_k) - f(x_k - t_k \nabla f(x_k)) \geq \alpha \min\left(s, \frac{2(\alpha-1)\beta}{L}\right) \|\nabla f(x_k)\|^2.$$

On récapitule cette discussion dans le résultat suivant :

Proposition 15. Soit $f \in C_L^{1,1}(\mathbb{R}^n)$ et $(x_k)_k$ la suite générée par la méthode du gradient pour résoudre

$$\min_{x \in \mathbb{R}^n} f(x),$$

avec pas constant, recherche linéaire exacte ou backtracking de paramètres $s > 0, \alpha, \beta \in (0, 1)$. Alors

$$f(x_k) - f(x_{k+1}) \geq M \|\nabla f(x_k)\|^2, \quad (5.7)$$

avec

$$M = \begin{cases} t^* \left(1 - \frac{t^* L}{2}\right) & \text{pas constant,} \\ \frac{1}{2L} & \text{recherche linéaire exacte,} \\ \alpha \min\left(s, \frac{2(\alpha-1)\beta}{L}\right) & \text{backtracking.} \end{cases}$$

On démontre maintenant que $\|\nabla f(x_k)\| \rightarrow 0$ quand $k \rightarrow \infty$.

Théorème 55. Soit $f \in C_L^{1,1}(\mathbb{R}^n)$ et $(x_k)_k$ la suite générée par la méthode du gradient pour résoudre

$$\min_{x \in \mathbb{R}^n} f(x),$$

avec pas constant, recherche linéaire exacte ou backtracking de paramètres $s > 0, \alpha, \beta \in (0, 1)$. Supposons que f est minorée, i.e., il existe $c \in \mathbb{R}$ tel que $f(x) \geq c$ pour tout $x \in \mathbb{R}^n$. Alors

1. La suite $(f(x_k))_k$ est décroissante, avec $f(x_{k+1}) < f(x_k)$ sauf si $\|\nabla f(x_k)\| = 0$.
2. $\|\nabla f(x_k)\| \rightarrow 0$ quand $k \rightarrow \infty$.

Preuve. 1. On a grâce à (5.7)

$$f(x_k) - f(x_{k+1}) \geq M \|\nabla f(x_k)\|^2 \geq 0, \quad (5.8)$$

pour $M > 0$. Donc $(f(x_k))_k$ est décroissante et $f(x_k) = f(x_{k+1})$ ne peut avoir lieu que si $\nabla f(x_k) = 0$.

2. Comme la suite $(f(x_k))_k$ est décroissante et f minorée, alors elle est convergente, i.e., $f(x_k) - f(x_{k+1}) \xrightarrow{k \rightarrow \infty} 0$. Cela implique avec (5.8) que $\|\nabla f(x_k)\| \rightarrow 0$ quand $k \rightarrow \infty$.

□

On termine cette section avec le résultat suivant permettant d'avoir des taux de convergence de la norme du gradient.

Théorème 56. Sous les mêmes hypothèses, on a pour tout $n \geq 0$

$$\min_{k=0,\dots,n} \|\nabla f(x_k)\| \leq \sqrt{\frac{f(x_0) - f^*}{M(n+1)}}, \quad (5.9)$$

où f^* est la limite de la suite $(f(x_k))_k$ et la constante M est donnée dans Proposition 15.

Preuve. En sommant de 0 à n dans l'inégalité (5.7), on obtient

$$f(x_0) - f(x_{n+1}) = \sum_{k=0}^n (f(x_k) - f(x_{k+1})) \geq M \sum_{k=0}^n \|\nabla f(x_k)\|^2.$$

Par définition, $f^* \leq f(x_{n+1})$, et par suite

$$f(x_0) - f^* \geq M \sum_{k=0}^n \|\nabla f(x_k)\|^2 \geq M \min_{k=0,\dots,n} \|\nabla f(x_k)\|^2 \sum_{k=0}^n 1,$$

soit

$$f(x_0) - f^* \geq M(n+1) \min_{k=0,\dots,n} \|\nabla f(x_k)\|^2.$$

Finalement $\min_{k=0,\dots,n} \|\nabla f(x_k)\| \leq \sqrt{\frac{f(x_0) - f^*}{M(n+1)}}$, comme voulu. □

Remarque 23. On note $\nabla f_n^* = \min_{k=0,\dots,n} \|\nabla f(x_k)\|$, on vient de démontrer que $\nabla f_n^* = \mathcal{O}(1/\sqrt{n})$. Au-delà du fait qu'il s'agisse d'un taux de convergence peu satisfaisant, le résultat ne donne aucune information sur les quantités $f(x_k) - f^*$ et $\|x_k - x^*\|$. Nous verrons plus tard que dans le cas convexe, le taux démontré précédemment peut être amélioré en $\mathcal{O}(1/n)$ et des taux de convergence de la fonction objectif et des itérées $(x_k)_k$ peuvent être démontrés.

5.3 Méthode de Newton

Avant de présenter la méthode de Newton comme une méthode de descente, rappelons la méthode de Newton pour trouver les zéros d'une fonction réelle. Soit donc $f : \mathbb{R} \rightarrow \mathbb{R}$, on cherche à résoudre l'équation $f(t) = 0$. L'idée est de remplacer f par son approximation de premier ordre en un point t_0 , i.e., résoudre $\tilde{f}(t) = f(t_0) + (t - t_0)f'(t_0) = 0$ au lieu de $f(t) = 0$. Si $f'(t_0) \neq 0$, on obtient $t = t_0 - \frac{f(t_0)}{f'(t_0)}$. Les itérations de Newton s'écrivent

$$t_{k+1} = t_k - \frac{f(t_k)}{f'(t_k)}.$$

Maintenant, soit $g : \mathbb{R}^n \rightarrow \mathbb{R}^n$. On s'intéresse au système $g(x) = 0$. De la même manière, en approchant g à l'ordre un autour d'un point $x_0 \in \mathbb{R}^n$, i.e., $g(x_0) + \nabla g(x_0)(x - x_0) = 0$. On obtient

$$\tilde{g}(x) := g(x_0) + \nabla g(x_0)(x - x_0) = 0 \Rightarrow x = x_0 - \left(\nabla g(x_0)\right)^{-1} g(x_0).$$

L'équation ci-dessus suppose évidemment que $\det(\nabla g(x_0)) \neq 0$. De même, on peut construire une suite $(x_k)_k$ qui approchera, a priori, le zéro de g , en définissant

$$x_{k+1} = x_k - \left(\nabla g(x_k)\right)^{-1} g(x_k). \quad (5.10)$$

Maintenant, revenons à notre problème d'optimisation

$$\min_{x \in \mathbb{R}^n} f(x). \quad (5.11)$$

On s'intéresse ici au système $\nabla f(x) = 0$. Rappelons que lorsque f est convexe, la condition $\nabla f(x^*) = 0$ est nécessaire et suffisante pour dire que x^* minimise f . On applique (5.10) avec $g = \nabla f$, pour trouver

$$x_{k+1} = x_k - \left(\nabla^2 f(x_k)\right)^{-1} \nabla f(x_k). \quad (5.12)$$

Ceci est une façon de faire le lien entre Newton et Newton...

Une autre façon de retrouver (5.12) est la suivante. Supposons que f est C^2 et que $\nabla^2 f(x) \in \mathcal{S}_{++}^n$ pour tout $x \in \mathbb{R}^n$. On cherchera donc à minimiser l'approximation d'ordre deux de f autour d'un certain $x_0 \in \mathbb{R}^n$, i.e., remplacer f par

$$\tilde{f}(x) = f(x_0) + (x - x_0)^T \nabla f(x_0) + \frac{1}{2} (x - x_0)^T \nabla^2 f(x_0) (x - x_0) \quad (5.13)$$

dans le problème (5.11). Donc étant donnée une itérée x_k , x_{k+1} est obtenue comme suit

$$x_{k+1} = \operatorname{argmin}_{x \in \mathbb{R}^n} \left\{ f(x_k) + (x - x_k)^T \nabla f(x_k) + \frac{1}{2} (x - x_k)^T \nabla^2 f(x_k) (x - x_k) \right\}. \quad (5.14)$$

L'unique minimiseur de (5.14) est en fait l'unique point stationnaire, et on a

$$\nabla \tilde{f}(x_{k+1}) = 0 \Leftrightarrow \nabla f(x_k) + \nabla^2 f(x_k)(x_{k+1} - x_k) = 0,$$

ce qui donne

$$x_{k+1} = x_k - \left(\nabla^2 f(x_k)\right)^{-1} \nabla f(x_k). \quad (5.15)$$

La méthode de Newton est donc une méthode de descente avec comme direction $\mathbf{d}_k = -\left(\nabla^2 f(x_k)\right)^{-1} \nabla f(x_k)$.

Méthode de Newton

- Initialisation : On se donne un $x_0 \in \mathbb{R}^n$ et une tolérance $\varepsilon > 0$.
- Pour $k \geq 0$
 - On calcule la direction de Newton $\mathbf{d}_k$ comme solution du système linéaire
$$\nabla^2 f(x_k) \mathbf{d}_k = -\nabla f(x_k).$$
 - Prendre $x_{k+1} = x_k + \mathbf{d}_k$.
 - Si $\|\nabla f(x_{k+1})\| \leq \varepsilon$, s'arrêter et renvoyer x_{k+1} .

Il se trouve que sous certaines conditions de régularité sur la Hessienne, on peut obtenir autour de la solution optimale un taux de convergence quadratique.

Théorème 57. Soit $f \in C^2(\mathbb{R}^n)$ et supposons que :

1. il existe $m > 0$ tel que $\nabla^2 f(x) \succeq mI_n$ pour tout $x \in \mathbb{R}^n$,
2. il existe $L > 0$ tel que

$$\|\nabla^2 f(x) - \nabla^2 f(y)\| \leq L\|x - y\|$$

pour tout $x, y \in \mathbb{R}^n$.

Alors

$$\|x_{k+1} - x^*\| \leq \frac{L}{2m} \|x_k - x^*\|^2,$$

où $(x_k)_k$ est la suite générée par la méthode de Newton et x^* l'unique minimiseur de f sur $\mathbb{R}^n$. De plus, si $\|x_0 - x^*\| \leq m/L$, alors

$$\|x_k - x^*\| \leq \frac{2m}{L} \left(\frac{1}{2}\right)^{2^k}, \quad k \geq 0.$$

Preuve. On a pour tout $k \geq 0$

$$\begin{aligned} x_{k+1} - x^* &= x_k - (\nabla^2 f(x_k))^{-1} \nabla f(x_k) - x^* \\ &= x_k - x^* + (\nabla^2 f(x_k))^{-1} (\nabla f(x^*) - \nabla f(x_k)) \\ &= x_k - x^* + (\nabla^2 f(x_k))^{-1} \int_0^1 [\nabla^2 f(x_k + t(x^* - x_k))] (x^* - x_k) dt \\ &= (\nabla^2 f(x_k))^{-1} \int_0^1 [\nabla^2 f(x_k + t(x^* - x_k)) - \nabla^2 f(x_k)] (x^* - x_k) dt. \end{aligned} \quad (5.16)$$

Comme $\nabla^2 f(x) \succeq mI_n$, il vient que $\|(\nabla^2 f(x_k))^{-1}\| \leq 1/m$. En utilisant la Lipschitz-continuité de la Hessienne, on obtient que

$$\begin{aligned} \|x_{k+1} - x^*\| &\leq \|(\nabla^2 f(x_k))^{-1}\| \left\| \int_0^1 [\nabla^2 f(x_k + t(x^* - x_k)) - \nabla^2 f(x_k)] (x^* - x_k) dt \right\| \\ &\leq \frac{1}{m} \int_0^1 \|\nabla^2 f(x_k + t(x^* - x_k)) - \nabla^2 f(x_k)\| \|x^* - x_k\| dt \\ &\leq \frac{1}{m} \int_0^1 Lt \|x^* - x_k\|^2 dt = \frac{L}{2m} \|x^* - x_k\|^2. \end{aligned} \quad (5.17)$$

On conclut par récurrence. □

5.4 Méthode de gradient projeté

5.4.1 Cas général

On s'intéresse ici à des problèmes du type

$$\min_{x \in C} f(x), \quad (5.18)$$

où $C \subset \mathbb{R}^n$ est un convexe fermé et $f : C \rightarrow \mathbb{R}$ de classe C^1 . Il se trouve qu'on peut caractériser les points stationnaires de (5.18) en termes de l'opérateur de projection orthogonale.

Théorème 58. Soit $f : C \rightarrow \mathbb{R}$ de classe C^1 où C est un convexe fermé et $s > 0$. Alors x^* est

un point stationnaire de (5.18) si et seulement si

$$x^* = P_C(x^* - s\nabla f(x^*)). \quad (5.19)$$

Preuve. Laissée en exercice. $\square$

L'équation (5.19) affirme que x^* est point fixe de l'application $x \mapsto P_C(x - s\nabla f(x))$. Cela suggère des algorithmes du type point fixe pour résoudre (5.19), et donc (5.18).

Méthode du gradient projeté

On se donne une tolérance $\varepsilon > 0$.

- Initialisation : On se donne un $x_0 \in C$.
- Pour $k \geq 0$
 - Choisir un pas t_k par recherche linéaire.
 - Prendre $x_{k+1} = P_C(x_k - t_k \nabla f(x_k))$.
 - Si $\|x_k - x_{k+1}\| \leq \varepsilon$, renvoyer x_{k+1} .

On démontre un résultat similaire au Lemme 6.

Lemme 7. Soit $f \in C_L^{1,1}(\mathbb{R}^n)$. Alors pour tout $x \in \mathbb{R}^n$ et $t > 0$

$$f(x) - f(P_C(x - t\nabla f(x))) \geq t \left(1 - \frac{tL}{2}\right) \left\| \frac{1}{t}(x - P_C(x - t\nabla f(x))) \right\|^2. \quad (5.20)$$

Preuve. Il suffit d'appliquer le lemme de descente Lemme 5 avec $y = P_C(x - t\nabla f(x))$ et utiliser le fait que

$$\langle x - t\nabla f(x) - y, x - y \rangle \leq 0.$$

$\square$

Remarque 24. Quand $C = \mathbb{R}^n$, la méthode du gradient projeté n'est rien d'autre que la méthode de descente de gradient classique présentée en Section ??.

Notation. Par la suite, on note, pour $M > 0$

$$G_M(x) = M \left(x - P_C \left(x - \frac{1}{M} \nabla f(x) \right) \right).$$

On note que pour $C = \mathbb{R}^n$, $G_M(x) = \nabla f(x)$. L'opérateur servira comme une mesure d'optimalité. Avec cette notation, le Lemme 7 se réécrit

$$f(x) - f(P_C(x - t\nabla f(x))) \geq t \left(1 - \frac{tL}{2}\right) \|G_{1/t}(x)\|^2.$$

On peut démontrer sans difficultés un résultat similaire à la Proposition 15 et au Théorème 55 pour la méthode du gradient projeté ; on changera $\nabla f(x)$ par $G_M(x)$.

5.4.2 Cas convexe

On s'intéresse ici à des problèmes du type

$$\min_{x \in C} f(x), \quad (5.21)$$

où $C \subset \mathbb{R}^n$ est un convexe fermé et $f \in C_L^{1,1}(C)$ est **convexe**. Dans ce cas, on peut démontrer à la fois la convergence de $(f(x_k))_k$ vers f^* ainsi que celle de la suite $(x_k)_k$.

Théorème 59. Soit $f \in C_L^{1,1}(C)$ une fonction convexe avec C un convexe fermé de $\mathbb{R}^n$. Soit $(x_k)_k$ la suite générée par la méthode du gradient projeté avec un pas $t_k = t^* \in (0, 1/L]$. Supposons que $\operatorname{argmin}_C f \neq \emptyset$. Alors

1. Pour tout $k \geq 0$ et $x^* \in \operatorname{argmin}_C f$

$$f(x_k) - f^* \leq \frac{\|x_0 - x^*\|^2}{2t^*k}.$$

2. $x_k \rightarrow x^* \in \operatorname{argmin}_C f$ lorsque $k \rightarrow \infty$.

Remarque 25. • **Amélioration du taux de convergence :** Dans le cas convexe, on obtient un taux de convergence $f(x_k) - f^* = \mathcal{O}(1/k)$ pour la fonction objectif, ce qui est significativement meilleur que le taux $\|\nabla f(x_k)\| = \mathcal{O}(1/\sqrt{k})$ obtenu dans le cas général non-convexe (voir [Théorème 55](#)). De plus, on obtient ici une information directe sur la décroissance de la fonction objectif, et non seulement sur son gradient.

- **Choix optimal du pas :** Le pas optimal est $t^* = 1/L$, qui maximise la vitesse de convergence tout en garantissant la décroissance. Ce choix donne

$$f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|^2}{2k}.$$

Notons que contrairement au cas non contraint où on pouvait prendre $t^* \in (0, 2/L)$, ici la contrainte $t^* \leq 1/L$ assure que la projection reste bien définie et que l'algorithme converge.

- **Convergence des itérées :** Le point (2) du théorème garantit la convergence de la suite $(x_k)_k$ elle-même vers un minimiseur, et pas seulement la convergence de $(f(x_k))_k$ vers f^* . Ceci est une conséquence directe de la convexité de f et de la structure du problème contraint. Si $\operatorname{argmin}_C f$ est un singleton, alors la convergence est vers l'unique minimiseur. Sinon, la suite $(x_k)_k$ converge vers un élément de $\operatorname{argmin}_C f$, qui dépend du point initial x_0 .
- **Comparaison avec le cas non contraint :** Lorsque $C = \mathbb{R}^n$, la méthode du gradient projeté se réduit à la méthode du gradient classique, et on retrouve $G_M(x) = \nabla f(x)$. Le théorème ci-dessus généralise donc les résultats de convergence de la Section ?? au cas contraint, avec les mêmes garanties de convergence sous l'hypothèse de convexité.
- **Dépendance en la condition initiale :** La borne sur $f(x_k) - f^*$ dépend de $\|x_0 - x^*\|^2$, c'est-à-dire de la distance entre le point initial et un minimiseur. Cela signifie qu'un bon choix de x_0 (proche d'un minimiseur) peut accélérer significativement la convergence. En pratique, on ne connaît évidemment pas x^* , mais cette borne théorique donne une estimation du nombre d'itérations nécessaires pour atteindre une précision donnée.
- **Complexité algorithmique :** Pour obtenir une solution ε -optimale, i.e., $f(x_k) - f^* \leq \varepsilon$, il suffit de prendre

$$k \geq \frac{\|x_0 - x^*\|^2}{2t^*\varepsilon} = \frac{L\|x_0 - x^*\|^2}{2\varepsilon}.$$

Le nombre d'itérations nécessaires est donc linéaire en $1/\varepsilon$, ce qui caractérise les méthodes de gradient du premier ordre pour les fonctions convexes lisses.

Conditions KKT

Dans ce chapitre, nous introduisons une condition d'optimalité pour des problème du type

$$\min_{x \in C} f(x),$$

avec C un convexe fermé non vide, qui soit plus pratique et facile à vérifier que celle la notion de stationnarité introduite dans [Chapter 4](#). Les résultat reposent sur les théorèmes de séparation de convexes par un hyperplan qu'on a rappelé dans [Chapter 1](#).

On commence par le cas "simple" suivant.

6.1 Contraintes linéaires

Soit $f \in C^1(\mathbb{R}^n)$ et $a_1, \dots, a_m \in \mathbb{R}^n, b_1, \dots, b_m \in \mathbb{R}$. Considérons le problème d'optimisation:

$$\min_{x \in \mathbb{R}^n} \{f(x) : a_i^\top x \leq b_i, \quad i = 1, \dots, m\}. \quad (\text{P})$$

Le résultat suivant donne une condition nécessaire d'optimalité pour (P). Lorsque la fonction objectif f est convexe, ces conditions deviennent également suffisantes.

Théorème 60 (Conditions de Karush-Kuhn-Tucker). Soit x^* un minimum local de (P). Alors il existe des multiplicateurs $\lambda_1, \dots, \lambda_m \geq 0$ tels que :

$$\nabla f(x^*) + \sum_{i=1}^m \lambda_i a_i = 0, \quad (6.1a)$$

$$\lambda_i (a_i^\top x^* - b_i) = 0, \quad i = 1, \dots, m. \quad (6.1b)$$

Inversement, si f est de plus convexe et si x^* est un point admissible pour (P) pour lequel il existe $\lambda_1, \dots, \lambda_m \geq 0$ vérifiant (6.1a) et (6.1b), alors x^* est un minimum global de (P).

Preuve. Condition nécessaire : Soit x^* un minimum local de (P). C'est donc un point stationnaire de (P) au sens de la [Définition 48](#). Ainsi, pour tout $x \in \mathbb{R}^n$ admissible (vérifiant $a_i^\top x \leq b_i$ pour tout i), on a :

$$\langle \nabla f(x^*), x - x^* \rangle \geq 0. \quad (6.2)$$

Notons $I_{x^*} = \{i \in \{1, \dots, m\} : a_i^\top x^* = b_i\}$ l'ensemble des indices des contraintes *actives*. En posant $y = x - x^*$, la condition (6.2) stipule que $\langle \nabla f(x^*), y \rangle \geq 0$ pour tout vecteur $y \in \mathbb{R}^n$ tel que $a_i^\top (y + x^*) \leq b_i$ pour tout i .

Si $i \in I_{x^*}$, la contrainte se réduit à $a_i^\top y \leq 0$. Si $i \notin I_{x^*}$, elle s'écrit $a_i^\top y \leq b_i - a_i^\top x^*$.

Considérons une direction y vérifiant uniquement $a_i^\top y \leq 0$ pour tout $i \in I_{x^*}$. Comme $b_i > a_i^\top x^*$ pour tout $i \notin I_{x^*}$, on peut choisir un scalaire strictement positif $\eta > 0$ suffisamment petit pour que le déplacement ηy respecte les contraintes inactives. Précisément, on pose :

$$\eta = \min_{\substack{i \notin I_{x^*} \\ a_i^\top y > 0}} \frac{b_i - a_i^\top x^*}{a_i^\top y} > 0$$

(Si l'ensemble sur lequel on minimise est vide, on prend arbitrairement $\eta = 1$). Pour ce choix de $\eta > 0$, la direction ηy vérifie $a_i^\top (\eta y) \leq b_i - a_i^\top x^*$ pour $i \notin I_{x^*}$, et bien sûr $a_i^\top (\eta y) \leq 0$ pour

$i \in I_{x^*}$. Le point $x = x^* + \eta y$ est donc admissible. Par (6.2), on obtient $\langle \nabla f(x^*), \eta y \rangle \geq 0$. Puisque $\eta > 0$, cela implique $\langle \nabla f(x^*), y \rangle \geq 0$.

Nous venons de démontrer l'implication suivante :

$$\forall y \in \mathbb{R}^n, \quad (a_i^\top y \leq 0, \forall i \in I_{x^*}) \Rightarrow \langle -\nabla f(x^*), y \rangle \leq 0.$$

Par le Lemme de Farkas (Théorème 52), il existe des scalaires $\lambda_i \geq 0$ pour $i \in I_{x^*}$ tels que :

$$-\nabla f(x^*) = \sum_{i \in I_{x^*}} \lambda_i a_i.$$

En posant $\lambda_i = 0$ pour les contraintes inactives ($i \notin I_{x^*}$), on garantit la condition de complémentarité $\lambda_i(a_i^\top x^* - b_i) = 0$ pour tout $i = 1, \dots, m$, et on obtient bien $\nabla f(x^*) + \sum_{i=1}^m \lambda_i a_i = 0$.

Condition suffisante : Supposons que f est convexe et soit x^* un point admissible vérifiant les conditions (6.1). Considérons le Lagrangien :

$$h(x) = f(x) + \sum_{i=1}^m \lambda_i (a_i^\top x - b_i).$$

Par (6.1a), on a $\nabla h(x^*) = 0$. Comme f est convexe et que les termes linéaires le sont aussi, h est une fonction convexe. Ainsi, x^* est un minimiseur global de h sur $\mathbb{R}^n$.

Soit x un point admissible quelconque de (P). On a :

$$f(x^*) = h(x^*) \leq h(x) = f(x) + \sum_{i=1}^m \lambda_i (a_i^\top x - b_i).$$

(La première égalité vient de la complémentarité (6.1b) en x^*). Puisque x est admissible, on a $a_i^\top x - b_i \leq 0$ pour tout i . Comme $\lambda_i \geq 0$, la somme est négative ou nulle. On conclut donc que :

$$f(x^*) \leq f(x).$$

Le point x^* est donc bien un minimum global. $\square$

Remarque 26. On appelle λ_i le *multiplicateur de Lagrange* associé à la contrainte $a_i^\top x \leq b_i$. Les conditions (6.1b) sont appelées les conditions de complémentarité. On remarque que les multiplicateurs associés aux contraintes d'inégalité $a_i^\top x \leq b_i$ sont toujours positifs ou nuls.

On peut généraliser le résultat du théorème précédent aux cas de contraintes d'égalité en remarquant qu'un point x vérifiant $a^\top x = b$ vérifie à la fois $a^\top x \leq b$ et $-a^\top x \leq -b$. En effet, considérons le problème d'optimisation :

$$\min_{x \in \mathbb{R}^n} \{f(x) : a_i^\top x \leq b_i, \quad i = 1, \dots, m, \quad c_j^\top x = d_j, \quad j = 1, \dots, p\}, \quad (\text{P}')$$

avec $a_i, c_j \in \mathbb{R}^n$ et $b_i, d_j \in \mathbb{R}$.

Théorème 61. Soit x^* un minimum local de (P'). Alors il existe des multiplicateurs $\lambda_1, \dots, \lambda_m \geq 0$ et $\mu_1, \dots, \mu_p \in \mathbb{R}$ tels que :

$$\nabla f(x^*) + \sum_{i=1}^m \lambda_i a_i + \sum_{j=1}^p \mu_j c_j = 0, \quad (6.3a)$$

$$\lambda_i (a_i^\top x^* - b_i) = 0, \quad i = 1, \dots, m. \quad (6.3b)$$

Inversement, si f est de plus convexe et si x^* est un point admissible pour (P') pour lequel il existe $\lambda_1, \dots, \lambda_m \geq 0$ et $\mu_1, \dots, \mu_p \in \mathbb{R}$ vérifiant (6.3a) et (6.3b), alors x^* est un minimum global

de (P').

Preuve. Condition nécessaire : On commence par remarquer que les contraintes d'égalité $c_j^\top x = d_j$ pour $j = 1, \dots, p$ se réécrivent :

$$c_j^\top x \leq d_j \quad \text{et} \quad -c_j^\top x \leq -d_j, \quad j = 1, \dots, p.$$

Donc si x^* est solution de (P'), alors x^* est également solution de :

$$\min_{x \in \mathbb{R}^n} \{f(x) : a_i^\top x \leq b_i, \quad \forall i, \quad c_j^\top x \leq d_j, \quad -c_j^\top x \leq -d_j, \quad \forall j\}. \quad (\text{P''})$$

Ce problème ne contient que des inégalités. D'après le théorème précédent, il existe donc des multiplicateurs de Lagrange $\lambda_1, \dots, \lambda_m \geq 0$ et $\eta_1, \nu_1, \dots, \eta_p, \nu_p \geq 0$ tels que :

$$\nabla f(x^*) + \sum_{i=1}^m \lambda_i a_i + \sum_{j=1}^p \eta_j c_j - \sum_{j=1}^p \nu_j c_j = 0, \quad (6.4a)$$

$$\lambda_i (a_i^\top x^* - b_i) = 0, \quad i = 1, \dots, m, \quad (6.4b)$$

$$\eta_j (c_j^\top x^* - d_j) = 0, \quad j = 1, \dots, p, \quad (6.4c)$$

$$\nu_j (-c_j^\top x^* + d_j) = 0, \quad j = 1, \dots, p. \quad (6.4d)$$

En posant $\mu_j = \eta_j - \nu_j \in \mathbb{R}$, l'équation (6.4a) donne exactement (6.3a). Les conditions (6.3b) sont données par (6.4b).

Condition suffisante : Supposons que f est convexe et soit x^* un point admissible pour (P') vérifiant (6.3a) et (6.3b). Posons $\eta_j = \max(\mu_j, 0) \geq 0$ et $\nu_j = -\min(\mu_j, 0) \geq 0$. On a bien $\mu_j = \eta_j - \nu_j$. De plus, comme x^* est admissible pour (P'), on a $c_j^\top x^* = d_j$, ce qui implique que les conditions de complémentarité (6.4c) et (6.4d) sont trivialement satisfaites en x^* . Ainsi, x^* vérifie toutes les conditions suffisantes de KKT pour le problème (P''). Il est donc un minimum global de (P''), et par conséquent de (P'). $\square$

Définition 53 (Point KKT). Soit x^* un point admissible pour le problème (P'). On dit que x^* est un *point KKT* (ou *point de Karush-Kuhn-Tucker*) s'il existe des multiplicateurs $\lambda_1, \dots, \lambda_m \geq 0$ et $\mu_1, \dots, \mu_p \in \mathbb{R}$ tels que les conditions (6.3a) et (6.3b) soient vérifiées.

Remarque 27. Les conditions de KKT jouent le même rôle pour l'optimisation sous contraintes que l'équation $\nabla f(x) = 0$ pour l'optimisation sans contrainte. La recherche de minima locaux passe donc en pratique par la résolution du système d'équations (souvent non-linéaire) formé par les conditions KKT afin de trouver les points KKT candidats.

Plus souvent, on formule la condition (6.3a) en introduisant le Lagrangien du problème (P').

Définition 54 (Lagrangien). On appelle **Lagrangien** associé au problème (P') la fonction $\mathcal{L} : \mathbb{R}^n \times \mathbb{R}^m \times \mathbb{R}^p \rightarrow \mathbb{R}$ définie par :

$$\mathcal{L}(x, \lambda, \mu) = f(x) + \sum_{i=1}^m \lambda_i (a_i^\top x - b_i) + \sum_{j=1}^p \mu_j (c_j^\top x - d_j),$$

où $\lambda = (\lambda_1, \dots, \lambda_m) \in \mathbb{R}^m$ et $\mu = (\mu_1, \dots, \mu_p) \in \mathbb{R}^p$.

De façon plus compacte, en introduisant les notations matricielles :

$$A = \begin{pmatrix} a_1^\top \\ \vdots \\ a_m^\top \end{pmatrix} \in \mathbb{R}^{m \times n}, \quad C = \begin{pmatrix} c_1^\top \\ \vdots \\ c_p^\top \end{pmatrix} \in \mathbb{R}^{p \times n}, \quad b = \begin{pmatrix} b_1 \\ \vdots \\ b_m \end{pmatrix} \in \mathbb{R}^m, \quad d = \begin{pmatrix} d_1 \\ \vdots \\ d_p \end{pmatrix} \in \mathbb{R}^p,$$

les contraintes du problème (P') se réécrivent simplement $Ax \leq b$ et $Cx = d$.

Le Lagrangien du problème prend alors la forme vectorielle suivante :

$$\mathcal{L}(x, \lambda, \mu) = f(x) + \lambda^\top (Ax - b) + \mu^\top (Cx - d).$$

L'intérêt principal de cette fonction est de réécrire la condition de stationnarité (6.3a) de manière plus élégante. Évaluée en un point KKT x^* , elle correspond exactement à l'annulation du gradient du Lagrangien par rapport à la variable primale x :

$$\nabla_x \mathcal{L}(x^*, \lambda, \mu) = \nabla f(x^*) + A^\top \lambda + C^\top \mu = 0.$$

6.2 Applications et exemples

Dans cette section, on présente quelques exemples élémentaires pour résoudre des problèmes d'optimisation avec contraintes en utilisant les conditions KKT.

Exemple 19. On considère l'exemple simple suivant où l'on cherche à minimiser la distance (au carré) à l'origine, définie par la fonction $f(x, y, z) = \frac{1}{2} \|(x, y, z)\|^2 = \frac{1}{2}(x^2 + y^2 + z^2)$ sous la contrainte d'égalité $x + y + z = a$, avec $a \in \mathbb{R}^*$.

Comme f est une fonction strictement convexe et que la contrainte est affine, le problème admet un unique minimum global, et les conditions KKT sont à la fois nécessaires et suffisantes.

Introduisons le Lagrangien associé au problème:

$$\mathcal{L}(x, y, z; \lambda) = f(x, y, z) + \lambda(x + y + z - a), \quad \lambda \in \mathbb{R}.$$

La condition d'annulation du gradient du Lagrangien par rapport aux variables primales donne:

$$\begin{aligned} \partial_x \mathcal{L}(x, y, z, \lambda) &= x + \lambda = 0, \\ \partial_y \mathcal{L}(x, y, z, \lambda) &= y + \lambda = 0, \\ \partial_z \mathcal{L}(x, y, z, \lambda) &= z + \lambda = 0. \end{aligned}$$

Cela implique directement $x = y = z = -\lambda$. En injectant ces valeurs dans la contrainte primale $x + y + z = a$, on obtient $-3\lambda = a$, ce qui donne $\lambda = -a/3$.

L'unique point KKT, qui est donc la solution globale de notre problème d'optimisation, est:

$$(x^*, y^*, z^*) = (a/3, a/3, a/3).$$

Exemple 20. Considérons le problème d'optimisation suivant:

$$\min_{x, y} f(x, y) = x^2 + 2y^2 + 4xy \quad \text{sous les contraintes} \quad \begin{cases} x + y = 1 \\ x \geq 0, y \geq 0 \end{cases}$$

On remarque que $f(x, y) = \left\langle A \begin{pmatrix} x \\ y \end{pmatrix}, \begin{pmatrix} x \\ y \end{pmatrix} \right\rangle$, où la matrice associée à f est $A = \begin{pmatrix} 1 & 2 \\ 2 & 2 \end{pmatrix}$. Puisque son déterminant est strictement négatif ($\det(A) = -2$), la matrice n'est pas semi-définie positive, et donc la fonction f n'est pas convexe. Les conditions de KKT sont donc uniquement des conditions nécessaires.

Introduisons le Lagrangien associé au problème:

$$\mathcal{L}(x, y; \lambda_1, \lambda_2, \mu) = x^2 + 2y^2 + 4xy + \mu(x + y - 1) - \lambda_1 x - \lambda_2 y,$$

où $\mu \in \mathbb{R}$ est le multiplicateur associé à la contrainte d'égalité, et $\lambda_1, \lambda_2 \geq 0$ sont associés aux contraintes d'inégalité. Les conditions de stationnarité et de complémentarité de KKT s'écrivent:

$$\partial_x \mathcal{L} = 2x + 4y + \mu - \lambda_1 = 0 \tag{6.5}$$

$$\partial_y \mathcal{L} = 4x + 4y + \mu - \lambda_2 = 0 \quad (6.6)$$

$$\lambda_1 x = 0, \quad \lambda_2 y = 0 \quad (6.7)$$

avec $x + y = 1$. Nous étudions les différents cas possibles:

- **Cas 1 :** $x > 0$ et $y > 0$. La complémentarité impose $\lambda_1 = \lambda_2 = 0$. Le système (6.5)-(6.6) donne alors $2x + 4y + \mu = 0$ et $4x + 4y + \mu = 0$. En soustrayant ces deux équations, on obtient $2x = 0$, soit $x = 0$, ce qui contredit notre hypothèse initiale. Ce cas n'est donc pas possible.
- **Cas 2 :** $x = 0$ et $y > 0$. Puisque $x + y = 1$, on a $y = 1$. La complémentarité impose $\lambda_2 = 0$. En injectant dans (6.6), on trouve $\mu = -4$. Puis, via (6.5), on trouve $\lambda_1 = 0$. Le point $(0, 1)$ est donc un point KKT.
- **Cas 3 :** $x > 0$ et $y = 0$. De même, on trouve $x = 1$. La complémentarité impose $\lambda_1 = 0$. En injectant dans (6.5), on a $\mu = -2$. Puis via (6.6), on trouve $\lambda_2 = 2 \geq 0$. Le point $(1, 0)$ est également un point KKT.
- **Cas 4 :** $x = y = 0$. Ce cas n'est pas possible puisque $(x, y) = (0, 0)$ n'est pas admissible.

L'ensemble des contraintes $C = \{(x, y) \in \mathbb{R}^2 : x + y = 1, x \geq 0, y \geq 0\}$ est un compact. D'après le théorème de Weierstrass (Théorème 39), la fonction continue f y atteint son minimum global. Les deux candidats sont les points KKT évalués : $f(1, 0) = 1$ et $f(0, 1) = 2$. Le minimum global est donc atteint au point $(x^*, y^*) = (1, 0)$ (cf. Fig. 6.1).




Figure 6.1: Contours de f et les points KKT

Les conditions KKT permettent de retrouver élégamment les formules de projection sur des ensembles convexes classiques. Soit $y \in \mathbb{R}^n$.

Exemple 21 (Projections orthogonales via KKT). Chercher son projeté $P_C(y)$ revient à minimiser la distance $\|x - y\|^2$ sous la contrainte $x \in C$.

1. **Projection sur un sous-espace affine:** Soit $C = \{x \in \mathbb{R}^n : Ax = b\}$ où $A \in \mathbb{R}^{m \times n}$ est supposée de rang plein. Le Lagrangien est $\mathcal{L}(x, \lambda) = \|x - y\|^2 + 2\lambda^\top (Ax - b)$. L'annulation du gradient donne:

$$\nabla_x \mathcal{L} = 2(x - y) + 2A^\top \lambda = 0 \Rightarrow x = y - A^\top \lambda.$$

En injectant x dans la contrainte primale $Ax = b$, on obtient $A(y - A^\top \lambda) = b$, soit $AA^\top \lambda = Ay - b$. Puisque A est de rang plein, $AA^\top$ est inversible, et on déduit $\lambda = (AA^\top)^{-1}(Ay - b)$.

L'expression de la projection est donc:

$$P_C(y) = y - A^\top (AA^\top)^{-1} (Ay - b).$$

2. **Projection sur un demi-espace:** Soit $C = \{x \in \mathbb{R}^n : \langle a, x \rangle \leq b\}$ avec $a \neq 0$. Le Lagrangien est $\mathcal{L}(x, \lambda) = \|x - y\|^2 + 2\lambda(\langle a, x \rangle - b)$. La condition de stationnarité donne :

$$2(x - y) + 2\lambda a = 0 \Rightarrow x = y - \lambda a.$$

La condition de complémentarité est $\lambda(\langle a, x \rangle - b) = 0$ avec $\lambda \geq 0$. Si $y \in C$ (i.e., $\langle a, y \rangle \leq b$), alors $\lambda = 0$ et $x = y$. Si $y \notin C$ (i.e., $\langle a, y \rangle > b$), alors pour avoir $x \in C$, la contrainte doit être active, donc $\lambda > 0$ et $\langle a, x \rangle = b$. On a alors :

$$\langle a, y - \lambda a \rangle = b \Rightarrow \langle a, y \rangle - \lambda \|a\|^2 = b \Rightarrow \lambda = \frac{\langle a, y \rangle - b}{\|a\|^2}.$$

En synthétisant ces deux cas, la projection s'écrit de manière compacte:

$$P_C(y) = y - \frac{(\langle a, y \rangle - b)_+}{\|a\|^2} a.$$

Introduction au calcul sous-différentiel

7.1 Définitions et propriétés

Définition 55 (Sous-gradient). Soit $f : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{\infty\}$ une fonction propre et $x \in \text{dom}(f)$. On dit que $g \in \mathbb{R}^n$ est un sous-gradient de f en x si

$$f(y) \geq f(x) + \langle g, y - x \rangle, \quad \forall y \in \text{dom}(f). \quad (7.1)$$

Définition 56 (Sous-différentiel). On appelle sous-différentiel de f en x , noté $\partial f(x)$, la collection des sous-gradients de f en x :

$$\partial f(x) = \{g \in \mathbb{R}^n : f(y) \geq f(x) + \langle g, y - x \rangle, \quad \forall y \in \text{dom}(f)\}. \quad (7.2)$$

On dira que f est sous-différentiable en $x \in \text{dom}(f)$ si $\partial f(x) \neq \emptyset$.

La Définition 55 exprime le fait que f est globalement sous-estimée par la fonction affine $y \mapsto f(x) + \langle g, y - x \rangle$. Géométriquement, cela correspond à un hyperplan affine qui supporte le graphe de f par le bas au point $(x, f(x))$ (voir Fig. 7.1).

On remarque que la notion de sous-gradient est une propriété globale, contrairement à celle du gradient qui est une notion purement locale. L'inégalité (7.1) devrait rappeler l'inégalité du premier ordre pour les fonctions convexes (3.4). En effet, le sous-différentiel généralise le gradient : en particulier, si f est convexe et différentiable en x , alors son unique sous-gradient est son gradient classique, i.e., $\partial f(x) = \{\nabla f(x)\}$.




Figure 7.1: La fonction f est différentiable en x_0 , dans ce cas le sous-différentiel en x_0 est réduit au gradient en x_0 . Tandis que x_1 est un point de non différentiabilité et donc $\partial f(x_1)$ est un faisceau de minorantes affines.

Exemple 22. On commence par l'exemple classique suivant. On considère la fonction $f(x) = |x|$ sur $\mathbb{R}$, qui est dérivable partout sauf en 0. Pour $x > 0$, $f'(x) = 1$ et donc $\partial f(x) = \{1\}$. De même, $\partial f(x) = \{-1\}$ pour $x < 0$.

On montrera que $\partial f(0) = [-1, 1]$. Supposons que $g \in \partial f(0)$. Par définition, on a $|y| \geq \langle g, y \rangle$ pour tout $y \in \mathbb{R}$. En prenant le maximum sur la boule unité $\{y \in \mathbb{R} : |y| \leq 1\}$ des deux côtés de l'inégalité, on obtient :

$$1 = \max_{|y| \leq 1} |y| \geq \max_{|y| \leq 1} \langle g, y \rangle = |g|,$$

c'est-à-dire $g \in [-1, 1]$. Inversement, si $g \in [-1, 1]$, alors par l'inégalité de Cauchy-Schwarz, on a pour tout $y \in \mathbb{R}$:

$$\langle g, y \rangle \leq |g||y| \leq 1 \cdot |y| = |y|.$$

On a donc bien $g \in \partial f(0)$. En conclusion (cf. Fig. 7.2):

$$\partial|x| = \begin{cases} \{1\} & \text{si } x > 0, \\ [-1, 1] & \text{si } x = 0, \\ \{-1\} & \text{si } x < 0. \end{cases}$$




Figure 7.2: À gauche : graphe de la fonction $f(x) = |x|$. À droite : graphe de son sous-différentiel $\partial f(x)$, qui est une application multivoque en $x = 0$.

Exemple 23. Soit $I \subset \mathbb{R}$ un intervalle, $f : I \rightarrow \mathbb{R}$ une fonction convexe et $x, y \in \overset{\circ}{I}$ avec $x < y$. Alors les dérivées à droite $f'_d(x)$ et à gauche $f'_g(y)$ existent, et on a :

$$f'_d(x) \leq \frac{f(y) - f(x)}{y - x} \leq f'_g(y).$$

De plus, pour tout $x \in \overset{\circ}{I}$, le sous-différentiel est un intervalle fermé donné par les dérivées directionnelles :

$$\partial f(x) = [f'_g(x), f'_d(x)].$$

On voit d'après la Définition 56 que le sous-différentiel $\partial f(x)$ d'une fonction f en un point x est un ensemble, qui peut éventuellement être vide. C'est le cas, par exemple, en $x = 0$ pour les deux fonctions suivantes :

$$f(x) = \begin{cases} -\sqrt{x} & \text{si } x \geq 0, \\ \infty & \text{sinon,} \end{cases} \quad \text{et} \quad g(x) = \begin{cases} 0 & \text{si } x > 0, \\ 1 & \text{si } x = 0, \\ \infty & \text{sinon.} \end{cases} \quad (7.3)$$

Ces deux fonctions ne sont pas sous-différentiables en 0 ($\partial f(0) = \emptyset$ et $\partial g(0) = \emptyset$).

Le résultat suivant récapitule les propriétés fondamentales du sous-différentiel.

Théorème 62. Soit $f : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{\infty\}$ une fonction propre. Alors $\partial f(x)$ est un convexe fermé pour tout $x \in \mathbb{R}^n$. Si de plus f est convexe, $\partial f(x)$ est un ensemble borné et non vide pour tout $x \in \text{int}(\text{dom}(f))$.

Preuve. Pour démontrer le premier point, il suffit de remarquer que pour tout $x \in \mathbb{R}^n$

$$\partial f(x) = \bigcap_{y \in \mathbb{R}^n} H_y,$$

où $H_y = \{g \in \mathbb{R}^n : \langle g, y - x \rangle + f(x) \leq f(y)\}$. Chaque H_y étant un demi-espace fermé, c'est un ensemble convexe et fermé. Une intersection quelconque d'ensembles fermés convexes étant elle-même fermée et convexe, on en déduit que $\partial f(x)$ est un convexe fermé.

Montrons à présent que $\partial f(x)$ est non vide pour $x \in \text{int}(\text{dom}(f))$. Dans un premier temps, remarquons que $(x, f(x))$ est sur la frontière de l'épigraphe de f . Le [Théorème 51](#) garantit l'existence d'un hyperplan séparant $(x, f(x))$ et $\text{epi}(f)$, i.e., il existe donc un vecteur non nul $(p, -\alpha) \in \mathbb{R}^n \times \mathbb{R}$ tel que :

$$\langle p, x \rangle - \alpha f(x) \geq \langle p, y \rangle - \alpha t \quad \text{pour tout } (y, t) \in \text{epi}(f). \quad (7.4)$$

Comme $(x, f(x) + 1) \in \text{epi}(f)$, en l'injectant dans (7.4) on obtient que $0 \geq -\alpha$, soit $\alpha \geq 0$.

Puisque $x \in \text{int}(\text{dom}(f))$, la fonction convexe f est localement lipschitzienne autour de x (cf. [Théorème 28](#)). Il existe donc $\varepsilon > 0$ et $L > 0$ tels que $B(x, \varepsilon) \subset \text{dom}(f)$ et :

$$|f(y) - f(x)| \leq L\|y - x\| \quad \text{pour tout } y \in B(x, \varepsilon). \quad (7.5)$$

Puisque $(y, f(y)) \in \text{epi}(f)$ pour tout $y \in B(x, \varepsilon)$, on peut l'injecter dans (7.4) pour obtenir :

$$\langle p, y - x \rangle \leq \alpha(f(y) - f(x)) \leq \alpha L\|y - x\| \quad \text{pour tout } y \in B(x, \varepsilon). \quad (7.6)$$

Prenons le vecteur $y = x + \varepsilon \frac{p}{\|p\|}$ (si $p \neq 0$). En l'injectant dans (7.6), on obtient $\varepsilon\|p\| \leq \alpha L\varepsilon$. On déduit de cela que $\alpha > 0$. Dans le cas contraire ($\alpha = 0$), on aurait $\|p\| \leq 0$, soit $p = 0$, ce qui est impossible car le vecteur normal $(p, -\alpha)$ est non nul.

Puisque $\alpha > 0$, on peut évaluer (7.4) pour $t = f(y)$ et diviser par α pour obtenir :

$$f(y) \geq f(x) + \langle g, y - x \rangle \quad \text{pour tout } y \in \text{dom}(f),$$

où $g = p/\alpha$. Ainsi, $g \in \partial f(x)$, ce qui établit que le sous-différentiel est non vide.

Enfin, montrons que $\partial f(x)$ est borné. Soit $g \in \partial f(x)$. Par définition, $f(y) \geq f(x) + \langle g, y - x \rangle$. En prenant $y = x + \varepsilon \frac{g}{\|g\|} \in B(x, \varepsilon)$ (si $g \neq 0$) et en utilisant la propriété lipschitzienne (7.5), on obtient :

$$\varepsilon\|g\| = \langle g, y - x \rangle \leq f(y) - f(x) \leq L\|y - x\| = L\varepsilon.$$

En divisant par ε , on trouve $\|g\| \leq L$. Ainsi, $\partial f(x)$ est inclus dans la boule fermée de centre 0 et de rayon L , ce qui prouve qu'il est borné. $\square$

Le résultat suivant établit le lien entre la sous-différentiabilité et la convexité.

Théorème 63. Soit $f : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{\infty\}$ une fonction propre et supposons que $\text{dom}(f)$ est convexe. Si pour tout $x \in \text{dom}(f)$, $\partial f(x) \neq \emptyset$, alors f est convexe.

Preuve. Soient $x, y \in \text{dom}(f)$ et $\lambda \in [0, 1]$. Notons $z = \lambda x + (1 - \lambda)y$. Comme $\text{dom}(f)$ est convexe, on a $z \in \text{dom}(f)$. Soit $g \in \partial f(z)$. Remarquons d'abord que :

$$x - z = (1 - \lambda)(x - y) \quad \text{et} \quad y - z = -\lambda(x - y).$$

Par définition du sous-gradient en z , on peut écrire les inégalités pour les points x et y :

$$f(x) \geq f(z) + \langle g, x - z \rangle = f(z) + (1 - \lambda)\langle g, x - y \rangle,$$

$$f(y) \geq f(z) + \langle g, y - z \rangle = f(z) - \lambda \langle g, x - y \rangle.$$

En multipliant la première inégalité par $\lambda \geq 0$ et la seconde par $(1 - \lambda) \geq 0$, puis en les sommant, les termes contenant le produit scalaire s'annulent exactement. On obtient ainsi :

$$\lambda f(x) + (1 - \lambda)f(y) \geq \lambda f(z) + (1 - \lambda)f(z) = f(z),$$

ce qui prouve que f est convexe. $\square$

Une conséquence immédiate est le résultat suivant.

Corollaire 4. Soit $f : \mathbb{R}^n \rightarrow \mathbb{R}$ une fonction convexe. Alors f est sous-différentiable sur tout $\mathbb{R}^n$.

À la lumière du [Corollaire 4](#) et de l'exemple présenté en (7.3), on voit que le défaut de sous-différentiabilité d'une fonction convexe n'arrive qu'aux points de dégénérescence (sur la frontière du domaine). En particulier, à l'intérieur de son domaine, une fonction convexe est toujours sous-différentiable.

Le résultat suivant établit le lien fondamental entre le sous-différentiel et le gradient d'une fonction convexe.

Théorème 64 (Sous-différentiel aux points de différentiabilité). Soit $f : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{\infty\}$ une fonction propre et convexe, et soit $x \in \text{int}(\text{dom}(f))$. Si f est différentiable en x , alors son sous-différentiel se réduit à son gradient : $\partial f(x) = \{\nabla f(x)\}$.

Réciproquement, si f admet un unique sous-gradient en x , alors f est différentiable en x et $\partial f(x) = \{\nabla f(x)\}$.

Preuve. Admise. $\square$

On termine cette section par le résultat fondamental suivant qui fait le lien entre la dérivée directionnelle d'une fonction et son sous-différentiel.

Théorème 65. Soit $f : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{\infty\}$ une fonction propre et convexe. Alors pour tout $x \in \text{int}(\text{dom}(f))$ et $d \in \mathbb{R}^n$, on a :

$$f'(x; d) = \max_{g \in \partial f(x)} \langle g, d \rangle. \quad (7.7)$$

7.2 Règles de calcul

Proposition 16 (Somme de fonctions). Soient $f_1, f_2 : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{\infty\}$ deux fonctions propres et convexes.

1. Pour tout $\lambda \geq 0$ et $x \in \text{dom}(f)$, $\partial(\lambda f)(x) = \lambda \partial f(x)$.
2. Pour tout $x \in \text{dom}(f_1) \cap \text{dom}(f_2)$, on a l'inclusion :

$$\partial f_1(x) + \partial f_2(x) \subset \partial(f_1 + f_2)(x).$$

3. Si $\text{int}(\text{dom}(f_1)) \cap \text{int}(\text{dom}(f_2)) \neq \emptyset$, alors l'égalité est vérifiée : $\partial(f_1 + f_2)(x) = \partial f_1(x) + \partial f_2(x)$.

Plus généralement, pour m fonctions convexes f_i , on a $\sum_{i=1}^m \partial f_i(x) \subset \partial(\sum_{i=1}^m f_i)(x)$, avec égalité sous des conditions de qualification d'intérieur similaires. La preuve du résultat est laissée comme exercice. Le troisième point repose essentiellement sur le [Théorème 65](#).

Exemple 24 (Sous-différentiel de la norme ℓ_1). Considérons la fonction $f(x) = \|x\|_1 = \sum_{i=1}^n |x_i|$ sur $\mathbb{R}^n$. Puisque c'est une somme de fonctions séparables, i.e., $f(x) = \sum_{i=1}^n f_i(x)$, où $f_i : \mathbb{R}^n \rightarrow \mathbb{R}$ associe $x \mapsto |x_i|$, son sous-différentiel s'écrit $\partial f(x) = \sum_{i=1}^n \partial f_i(x)$. Comme :

$$\partial f_i(x) = \begin{cases} \{\text{sign}(x_i)e_i\} & \text{si } x_i \neq 0, \\ [-e_i, e_i] & \text{si } x_i = 0, \end{cases}$$

avec e_i le i -ème vecteur de la base canonique de $\mathbb{R}^n$. On a donc :

$$\partial f(x) = \sum_{i \in I^*(x)} \text{sign}(x_i)e_i + \sum_{i \notin I^*(x)} [-e_i, e_i], \quad (7.8)$$

où $I^*(x) = \{i : x_i \neq 0\}$.

Proposition 17 (Composition avec une fonction affine). Soit $g : \mathbb{R}^m \rightarrow \mathbb{R} \cup \{\infty\}$ une fonction propre convexe, $A \in \mathbb{R}^{m \times n}$ une matrice et $b \in \mathbb{R}^m$. On définit la fonction $f(x) = g(Ax + b)$. Supposons que f est propre. Alors pour tout $x \in \text{dom}(f)$:

$$A^T \partial g(Ax + b) \subset \partial f(x).$$

Si $x \in \text{int}(\text{dom}(f))$ et $Ax + b \in \text{int}(\text{dom}(g))$, on a :

$$\partial f(x) = A^T \partial g(Ax + b).$$

Exemple 25. On considère la fonction $f(x) = \|Ax + b\|_1$ avec $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$. Alors $f(x) = g(Ax + b)$ avec $g(x) = \|x\|_1$. On a donc :

$$\partial f(x) = A^T \partial g(Ax + b).$$

En utilisant (7.8), et en notant a_i^T les vecteurs lignes de A , on obtient :

$$\partial f(x) = \sum_{i \in I^*(x)} \text{sign}(a_i^T x + b_i) a_i + \sum_{i \notin I^*(x)} [-a_i, a_i],$$

où $I^*(x) = \{i : a_i^T x + b_i \neq 0\}$.

7.3 Sous-différentiel et optimisation

On commence par cette généralisation du [Théorème 34](#).

Théorème 66 (Règle de Fermat). Soit $f : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{\infty\}$ une fonction convexe et propre. Alors :

$$x \in \underset{y \in \mathbb{R}^n}{\text{argmin}} f(y) \Leftrightarrow 0 \in \partial f(x). \quad (7.9)$$

Preuve. La preuve est immédiate. En effet, x minimise f sur $\mathbb{R}^n$ si et seulement si $f(y) \geq f(x) + \langle 0, y - x \rangle$ pour tout $y \in \text{dom}(f)$. Autrement dit, $0 \in \partial f(x)$. $\square$

Avant d'énoncer un résultat similaire dans le cas avec contraintes, on présente l'ensemble fondamental suivant.

Définition 57 (Cône normal). Soit $S \subset \mathbb{R}^n$ un ensemble non vide et $x \in S$. On note $N_S(x)$ le

cône normal de S en x , qui est défini par :

$$N_S(x) = \{v \in \mathbb{R}^n : \langle v, z - x \rangle \leq 0, \quad \forall z \in S\}.$$

Géométriquement, le cône normal $N_S(x)$ représente l'ensemble des directions pointant "vers l'extérieur" de S depuis x (voir Fig. 7.3).




Figure 7.3: Exemples de cônes normaux $N_S(x)$ selon la géométrie locale de S au point x .

Le cône normal apparaît de façon naturelle quand on calcule le sous-différentiel de l'indicatrice d'un ensemble.

Exemple 26. Soit $S \subset \mathbb{R}^n$ un ensemble non vide. On rappelle que la fonction indicatrice (au sens de l'analyse convexe) est définie par :

$$\delta_S(x) = \begin{cases} 0 & \text{si } x \in S, \\ \infty & \text{sinon.} \end{cases}$$

Alors pour tout $x \in S$, $g \in \partial \delta_S(x)$ si et seulement si :

$$\delta_S(y) \geq \delta_S(x) + \langle g, y - x \rangle, \quad \forall y \in S.$$

Puisque $\delta_S(y) = \delta_S(x) = 0$ pour tout $y \in S$, cela se simplifie en :

$$\langle g, y - x \rangle \leq 0, \quad \forall y \in S.$$

Donc $\partial \delta_S(x) = N_S(x)$.

Nous avons le résultat fondamental suivant.

Théorème 67. Soit $f : \mathbb{R}^n \rightarrow \mathbb{R}$ une fonction convexe et $C \subset \mathbb{R}^n$ un convexe non vide. Alors :

$$x \in \operatorname{argmin}_{y \in C} f(y) \Leftrightarrow 0 \in \partial f(x) + N_C(x). \quad (7.10)$$

Remarque 28. Le résultat du [Théorème 67](#) est à comprendre dans le sens où il existe $g \in \partial f(x)$ tel que $-g \in N_C(x)$. Si f est différentiable en x , alors par le [Théorème 64](#), $\partial f(x) = \{\nabla f(x)\}$. Dans ce cas, la condition devient :

$$x \in \operatorname{argmin}_{y \in C} f(y) \Leftrightarrow -\nabla f(x) \in N_C(x).$$

Par définition du cône normal, cela signifie que :

$$\langle -\nabla f(x), y - x \rangle \leq 0, \quad \forall y \in C.$$

En multipliant par -1 (ce qui inverse le sens de l'inégalité), on obtient :

$$\langle \nabla f(x), y - x \rangle \geq 0, \quad \forall y \in C,$$

ce qui n'est rien d'autre que la condition de stationnarité des problèmes avec contraintes présentée dans la [Définition 48](#).

Remarque 29. Le résultat reste vrai lorsque $f : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{\infty\}$ sous une condition de qualification du type $\operatorname{int}(\operatorname{dom}(f)) \cap \operatorname{int}(C) \neq \emptyset$ (ou plus faible, en utilisant l'intérieur relatif). Dans ce cas minimiser f sur C revient à minimiser $\tilde{f} := f + \delta_C$ sur $\mathbb{R}^n$. En appliquant les règles de calcul (voir [Proposition 16](#)) et le [Théorème 66](#), on a :

$$\partial \tilde{f}(x) = \partial(f + \delta_C)(x) = \partial f(x) + N_C(x).$$

Méthodes proximales

Dans ce chapitre, nous introduisons des algorithmes d'optimisation qui peuvent être vus comme une généralisation de la descente de gradient et de la descente de gradient projeté introduites dans le [Chapter 5](#). Cette méthode repose sur un outil mathématique fondamental, à savoir l'opérateur proximal, qui a été introduit par Jean-Jacques Moreau et qui joue un rôle central en analyse convexe et en optimisation moderne.

8.1 L'opérateur proximal

Définition 58 (Opérateur proximal). Soit $f : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{\infty\}$. On définit l'opérateur proximal de f évalué en un point $x \in \mathbb{R}^n$ par :

$$\mathbf{Prox}_f(x) = \operatorname{argmin}_{y \in \mathbb{R}^n} \left\{ f(y) + \frac{1}{2} \|y - x\|^2 \right\}.$$

D'après la définition ci-dessus, $\mathbf{Prox}_f$ est un ensemble, donc peut être vide, un singleton ou contient plusieurs éléments. Le résultat suivant assure que pour la classe $\Gamma_0(\mathbb{R}^n)$, le prox est un singleton.

Théorème 68 (Premier théorème du prox). Soit $f \in \Gamma_0(\mathbb{R}^n)$ (i.e., propre, convexe, sci). Alors $\mathbf{Prox}_f(x)$ est un singleton pour tout $x \in \mathbb{R}^n$.

Preuve. Admise. □

En relaxant les hypothèses sur f , on peut s'assurer encore que l'opérateur proximal de f est non vide.

Théorème 69. Soit $f : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{\infty\}$ une fonction propre et fermée et supposons que $y \mapsto g_x(y) = f(y) + \frac{1}{2} \|y - x\|^2$ est coercive pour tout $x \in \mathbb{R}^n$. Alors $\mathbf{Prox}_f(x) \neq \emptyset$ pour tout $x \in \mathbb{R}^n$.

Preuve. Admise. □

Voici le calcul de l'opérateur proximal pour quelques fonctions classiques :

Exemple 27. 1. Si $f(x) = 0$, la minimisation de $\frac{1}{2} \|y - x\|^2$ donne trivialement $\mathbf{Prox}_f(x) = x$. Plus généralement, si $f(x) \equiv c \in \mathbb{R}$, alors $\mathbf{Prox}_f$ est l'identité.

2. Si $f(x) = \langle a, x \rangle + b$. On cherche à minimiser $g_x(y) = \langle a, y \rangle + b + \frac{1}{2} \|y - x\|^2$. En annulant le gradient par rapport à y , on obtient $\nabla g_x(y) = a + (y - x) = 0$, ce qui donne $\mathbf{Prox}_f(x) = x - a$.

3. Si $f(x) = \frac{1}{2} \langle Ax, x \rangle + \langle b, x \rangle + c$, avec A symétrique semi-définie positive. Dans ce cas, on cherche le minimum de $g_x(y) = \frac{1}{2} \langle Ay, y \rangle + \langle b, y \rangle + c + \frac{1}{2} \|y - x\|^2$. On obtient en annulant le gradient que $\nabla g(y) = Ay + b + (y - x) = 0$, soit $(A + I)y = x - b$. La matrice $(A + I)$ étant inversible, on conclut : $\mathbf{Prox}_f(x) = (A + I)^{-1}(x - b)$.

4. On considère la fonction de la variable réelle f , définie par $f(x) = \mu x$ pour $x \geq 0$, et ∞ pour $x < 0$ avec $\mu \in \mathbb{R}$. On note $g_x(y) = \mu y + \frac{1}{2} (y - x)^2$. On a $g'_x(y) = 0$ ssi $y = x - \mu$. Donc si $y > 0$, i.e., $x > \mu$, on a $\mathbf{Prox}_f(x) = x - \mu$. Si $y \leq 0$, i.e., $x \leq \mu$, le minimum est

donc atteint en le seul point de non-différentiabilité de f , à savoir 0. En conclusion

$$\mathbf{Prox}_f(x) = \max(x - \mu, 0) = [x - \mu]_+.$$

Dans les exemples ci-dessus, nous avons utilisé les faits suivants pour calculer le prox. Dans un premier temps, si $f'(x) = 0$ avec f convexe, alors x est un minimiseur de f . Deuxièmement, si le minimum d'une fonction convexe existe et n'est pas atteint en un point de différentiabilité de f , alors il est atteint en un point de non-différentiabilité de f . De façon générale, nous pourrions appliquer la règle de Fermat [Théorème 66](#) et les règles du calcul sous-différentiel présentées dans [Proposition 16](#) comme illustré dans l'exemple suivant.

Exemple 28. Soit $f(x) = \mu|x|$ avec $\mu \in \mathbb{R}_+$. On a

$$\begin{aligned} y^* = \operatorname{argmin}_y \left\{ \mu|y| + \frac{1}{2}(y - x)^2 \right\} &\Leftrightarrow 0 \in \partial \left(\mu|y^*| + \frac{1}{2}(y^* - x)^2 \right) \\ &\Leftrightarrow 0 \in \mu\partial|y^*| + y^* - x \\ &\Leftrightarrow y^* = \begin{cases} x - \mu, & \text{si } y^* > 0, \\ x + \mu, & \text{si } y^* < 0, \\ 0, & \text{si } |x| \leq \mu \end{cases} \\ &\Leftrightarrow y^* = [|x| - \mu]_+ \operatorname{sign}(x). \end{aligned} \quad (8.1)$$

8.2 Règles de calcul

On commence par le résultat où la fonction est séparable en ses variables.

Théorème 70. Soit $f : \prod_{i=1}^m \mathbb{R}^{n_i} \rightarrow \mathbb{R} \cup \{\infty\}$ définie par

$$f(x_1, \dots, x_m) = \sum_{i=1}^m f_i(x_i), \quad \forall x_i \in \mathbb{R}^{n_i}, \quad i = 1, \dots, m.$$

Alors pour tout $x_i \in \mathbb{R}^{n_i}$ avec $i = 1, \dots, m$, on a

$$\mathbf{Prox}_f(x_1, \dots, x_m) = \mathbf{Prox}_{f_1}(x_1) \times \dots \times \mathbf{Prox}_{f_m}(x_m).$$

Preuve. Laissée en exercice. □

Corollaire 5. Si $f \in \Gamma_0(\mathbb{R}^n)$ est séparable, i.e., $f(x) = \sum_{i=1}^n f_i(x_i)$ où $f_i \in \Gamma_0(\mathbb{R})$. Alors

$$\mathbf{Prox}_f(x) = \left(\mathbf{Prox}_{f_i}(x_i) \right)_{i=1}^n.$$

Exemple 29. On considère la fonction $f(x) = \mu\|x\|_1$ avec $\mu > 0$. On voit que $f(x) = \sum_{i=1}^n g(x_i)$ avec $g(s) = \mu|s|$. Comme $\mathbf{Prox}_g(x) = [|x| - \mu]_+ \operatorname{sign}(x)$, il vient que $\mathbf{Prox}_f(x) = \left(\mathcal{T}_\mu(x_i) \right)_{i=1}^n$, avec $\mathcal{T}_\mu(x) = [|x| - \mu]_+ \operatorname{sign}(x)$ qui est la fonction de seuillage doux (soft-thresholding cf. [Fig. 8.1](#)).

Le résultat suivant montre le comportement de l'opérateur proximal vis-à-vis des translations et des changements d'échelle.




Figure 8.1: L'opérateur de seuillage doux (soft-thresholding) $\mathcal{T}_\mu(x)$ pour différentes valeurs du paramètre μ . La fonction écrase à zéro toutes les valeurs dans la "zone morte" $[-\mu, \mu]$ et translate les autres valeurs vers l'origine.

Théorème 71. Soit $g : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{\infty\}$ une fonction propre, $\lambda \neq 0$ et $a \in \mathbb{R}^n$. On définit $f_1(x) = g(\lambda x + a)$. Alors :

$$\mathbf{Prox}_{f_1}(x) = \frac{1}{\lambda} (\mathbf{Prox}_{\lambda^2 g}(\lambda x + a) - a).$$

De plus, si $\lambda > 0$ et que l'on définit $f_2(x) = \lambda g(x/\lambda)$, alors :

$$\mathbf{Prox}_{f_2}(x) = \lambda \mathbf{Prox}_{\lambda^{-1} g}(x/\lambda).$$

Le théorème suivant est extrêmement utile pour calculer le proximal d'une fonction composée avec un opérateur linéaire, sous réserve que cet opérateur possède des propriétés d'orthogonalité.

Théorème 72. Soit $g \in \Gamma_0(\mathbb{R}^m)$ et $f(x) = g(Ax + b)$ avec $A \in \mathbb{R}^{m \times n}$ et $b \in \mathbb{R}^m$. Supposons que $AA^\top = \alpha \text{Id}$ avec $\alpha > 0$ (ce qui implique que A est surjective). Alors, pour tout $x \in \mathbb{R}^n$:

$$\mathbf{Prox}_f(x) = x + \frac{1}{\alpha} A^\top (\mathbf{Prox}_{\alpha g}(Ax + b) - (Ax + b)).$$

8.3 Retour à la projection

Dans cette section, nous faisons le lien entre l'opérateur proximal et l'opérateur de projection orthogonale. Soit $S \subset \mathbb{R}^n$ un ensemble convexe et fermé non vide. On a le résultat fondamental suivant.

Théorème 73. On a $\mathbf{Prox}_{\delta_S}(x) = P_S(x)$ pour tout $x \in \mathbb{R}^n$.

Preuve. La preuve est immédiate : pour tout $x \in \mathbb{R}^n$,

$$\mathbf{Prox}_{\delta_S}(x) = \operatorname{argmin}_{y \in \mathbb{R}^n} \left\{ \frac{1}{2} \|y - x\|^2 + \delta_S(y) \right\} = \operatorname{argmin}_{y \in S} \frac{1}{2} \|y - x\|^2 = P_S(x).$$

□

Le résultat suivant, souvent appelé "deuxième théorème du prox", repose de manière directe sur la règle de Fermat.

Théorème 74 (2ème théorème du prox). Soit $f \in \Gamma_0(\mathbb{R}^n)$. Alors pour tout $x, y \in \mathbb{R}^n$, les propriétés suivantes sont équivalentes :

1. $y = \mathbf{Prox}_f(x)$;
2. $x - y \in \partial f(y)$;
3. $\langle x - y, z - y \rangle \leq f(z) - f(y)$ pour tout $z \in \mathbb{R}^n$.

En particulier, $x \in \operatorname{argmin}_{\mathbb{R}^n} f$ si et seulement si $x = \mathbf{Prox}_f(x)$.

Preuve. Laissée en exercice. □

Pour finir, nous énonçons un résultat de stabilité similaire à celui connu pour la projection sur un convexe (Théorème 48).

Théorème 75. Soit $f \in \Gamma_0(\mathbb{R}^n)$. Alors pour tous $x, y \in \mathbb{R}^n$,

$$\langle \mathbf{Prox}_f(x) - \mathbf{Prox}_f(y), x - y \rangle \geq \|\mathbf{Prox}_f(x) - \mathbf{Prox}_f(y)\|^2. \quad (8.2)$$

En particulier, $\mathbf{Prox}_f$ est une application non-expansive (ou 1-lipschitzienne) :

$$\|\mathbf{Prox}_f(x) - \mathbf{Prox}_f(y)\| \leq \|x - y\|, \quad \forall x, y \in \mathbb{R}^n. \quad (8.3)$$

La propriété (8.2) s'appelle la ferme non-expansivité (ou cocoercivité de paramètre 1). La non-expansivité (8.3) découle de (8.2) en utilisant l'inégalité de Cauchy-Schwarz.

8.4 Méthode du gradient proximal

Dorénavant, on s'intéressera à une classe de problèmes d'optimisation dits *composites*, c'est-à-dire de la forme :

$$\min_{x \in \mathbb{R}^n} \Phi(x) := f(x) + g(x), \quad (8.4)$$

où $g \in \Gamma_0(\mathbb{R}^n)$ et $f : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{\infty\}$ est propre, semi-continue inférieurement (s.c.i.) et de domaine fermé. On fera les hypothèses suivantes :

- Hypothèse 1.**
1. $\operatorname{dom}(g) \subset \operatorname{int}(\operatorname{dom}(f))$;
 2. $f \in C_{L_f}^{1,1}(\operatorname{int}(\operatorname{dom}(f)))$ (i.e., f est différentiable et son gradient est L_f -lipschitzien);
 3. $\operatorname{argmin}_{\mathbb{R}^n} \Phi \neq \emptyset$.

Considérons d'abord le cas où $g = \delta_C$, avec $C \subset \mathbb{R}^n$ un ensemble convexe fermé non vide. Le problème (8.4) devient alors un problème d'optimisation sous contraintes classique :

$$\min_{x \in C} f(x). \quad (8.5)$$

Nous avons vu qu'une façon de résoudre ce problème consiste à générer une suite $(x_k)_{k \geq 0}$ via la méthode du gradient projeté : $x_{k+1} = P_C(x_k - t_k \nabla f(x_k))$. Autrement dit :

$$x_{k+1} = \operatorname{argmin}_{x \in C} \frac{1}{2} \|x - (x_k - t_k \nabla f(x_k))\|^2 + \delta_C(x).$$

En développant la norme au carré et en divisant par t_k , on peut réécrire le terme quadratique (à une constante additive près qui ne dépend pas de x) comme suit :

$$x_{k+1} = \operatorname{argmin}_{x \in C} \left\{ f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2t_k} \|x - x_k\|^2 \right\}.$$

Les itérations sont donc calculées en minimisant sur C le développement de Taylor à l'ordre 1 de f autour de x_k , pénalisé par un terme quadratique $\frac{1}{2t_k} \|x - x_k\|^2$ qui empêche de trop s'éloigner du point courant.

Par analogie, pour approcher la solution du problème composite général (8.4), on propose de générer les itérations en remplaçant la contrainte $\delta_C(x)$ par la fonction $g(x)$ dans ce modèle local :

$$x_{k+1} = \operatorname{argmin}_{x \in \mathbb{R}^n} \left\{ f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + g(x) + \frac{1}{2t_k} \|x - x_k\|^2 \right\}.$$

En factorisant à nouveau le terme quadratique, on aboutit au problème équivalent suivant :

$$x_{k+1} = \operatorname{argmin}_{x \in \mathbb{R}^n} \left\{ t_k g(x) + \frac{1}{2} \|x - (x_k - t_k \nabla f(x_k))\|^2 \right\}.$$

Par définition de l'opérateur proximal, cette mise à jour s'écrit de façon très compacte :

$$x_{k+1} = \mathbf{Prox}_{t_k g}(x_k - t_k \nabla f(x_k)). \quad (8.6)$$

Pour $L > 0$, on note $T_L^{f,g}$ l'opérateur *prox-grad* défini par :

$$T_L^{f,g}(x) = \mathbf{Prox}_{\frac{1}{L}g} \left(x - \frac{1}{L} \nabla f(x) \right), \quad \forall x \in \operatorname{int}(\operatorname{dom}(f)).$$

La méthode du *gradient proximal* pour résoudre (8.4) s'écrit:

Algorithme : Méthode du gradient proximal

- **Initialisation** : Choisir un point de départ $x_0 \in \operatorname{int}(\operatorname{dom}(f))$.
- **Pour** $k \geq 0$:
 - Choisir un pas $t_k = 1/L_k > 0$.
 - Mettre à jour $x_{k+1} = T_{L_k}^{f,g}(x_k) = \mathbf{Prox}_{t_k g}(x_k - t_k \nabla f(x_k))$.

Exemple 30. 1. **Minimisation sans contrainte lisse**: Dans le cas où $g \equiv 0$, l'opérateur proximal est l'identité et on a :

$$T_L^{f,0}(x) = x - \frac{1}{L} \nabla f(x).$$

Les itérations de la méthode du gradient proximal se réduisent exactement aux itérations d'une descente de gradient classique.

2. **Optimisation sous contraintes**: Si $g = \delta_C$ avec $C \subset \mathbb{R}^n$ un convexe fermé, l'opérateur proximal est la projection orthogonale P_C , et on obtient :

$$T_L^{f,\delta_C}(x) = \mathbf{Prox}_{\frac{1}{L}\delta_C} \left(x - \frac{1}{L} \nabla f(x) \right) = P_C \left(x - \frac{1}{L} \nabla f(x) \right).$$

On retrouve l'algorithme du gradient projeté.

3. **Régularisation parcimonieuse**: Si $g(x) = \mu \|x\|_1$, avec $\mu > 0$, alors :

$$T_L^{f,\mu\|\cdot\|_1}(x) = \mathbf{Prox}_{\frac{\mu}{L}\|\cdot\|_1} \left(x - \frac{1}{L} \nabla f(x) \right) = \mathcal{T}_{\mu/L} \left(x - \frac{1}{L} \nabla f(x) \right),$$

où $\mathcal{T}_{\mu/L}$ est l'opérateur de seuillage doux (soft-thresholding, voir [Exemple 29](#)). Cet algorithme est populaire en traitement du signal et en machine learning sous le nom de méthode **ISTA** (*Iterative Shrinkage-Thresholding Algorithm*).

En dérivant des résultats similaires à ceux utilisés pour la descente de gradient ([Lemme 5](#) and [7](#)), on peut démontrer le résultat de convergence global suivant.

Théorème 76 (Convergence du gradient proximal). Supposons que les conditions de l'[Hypothèse 1](#) sont vérifiées et que f est convexe. Soit $(x_k)_{k \geq 0}$ la suite générée par la méthode du gradient proximal pour résoudre (8.4) avec un pas constant $t_k = 1/L_f$ pour tout $k \geq 0$. Alors, pour tout point de minimum $x^* \in \operatorname{argmin}_{\mathbb{R}^n} \Phi$ et pour tout $k \geq 1$, on a :

$$\Phi(x_k) - \Phi(x^*) \leq \frac{L_f}{2k} \|x_0 - x^*\|^2.$$

Références Bibliographiques

- [1] Jean-Baptiste Hiriart-Urruty and Claude Lemaréchal. *Fundamentals of Convex Analysis*. Springer, 2001. (p. 1)
- [2] R. Tyrrell Rockafellar and Roger J-B Wets. *Variational Analysis*. Springer, 1998. (p. 1)
- [3] Stephen Boyd and Lieven Vandenberghe. *Convex Optimization*. Cambridge University Press, 2004. (p. 1)
- [4] Amir Beck. *Introduction to Nonlinear Optimization: Theory, Algorithms, and Applications with MATLAB*. MOS-SIAM Series on Optimization. SIAM, 2014. (p. 1)
- [5] Yurii Nesterov. *Lectures on Convex Optimization*. Springer, 2018. (p. 1)
- [6] Sébastien Bubeck. “Convex optimization: Algorithms and complexity”. In: *Foundations and trends in Machine Learning* 8.3-4 (2015), pp. 231–357. (p. 1)
- [7] Hamza Ennaji. *Bases d’analyse convexe et optimisation*. Notes de cours, ENSIMAG. 2026. URL: <https://enhamza.github.io/files/BACO/index.html>. (p. 1)